Optimisation de la gestion des données

Ventes, Stocks et Performances - CODIR Bottleneck

Anthony Rake
Data Analyst
08/08/2025

Analyses Exploratoires des Données

1) Datasets

- erp.xlsx : stock, prix de vente, prix d'achat, statut produit
- web.xlsx : ventes, descriptions, type de produit, statuts
- liaison.xlsx : correspondance entre ERP et Web
- Aucun de ces dataset ne contient de données personnelles et sont donc conformes au RGPD

2) Caractéristiques, traitements réalisés et points d'attention (approche par dataset)

- **Dataset ERP :**

  a) Caractéristiques

  ✓ 825 lignes, 6 colonnes
  ✓ Clé primaire : *product_id*
  ✓ Variables quantitatives : *price, purchase_price, stock_quantity*
  ✓ Variables catégorielles : *stock_status, onsale_web*

  b) Nettoyage

  ✓ Contrôle globale du dataset : dimensions, nature des données, présence de valeurs nulles..
  ✓ Contrôle de doublons sur product_id

Analyses Exploratoires des Données

2) Caractéristiques, traitements réalisés et points d'attention (approche par dataset)

- **Dataset ERP (suite) :**

  b) Nettoyage

  ✓ Comparaison et correction des statuts de stock (stock_status vs stock_quantity)
  ✓ Nettoyage des prix négatifs (remplacés par leur valeur absolue après validation)
  ✓ Nettoyage des stocks négatifs (valeurs absolues après validation)
  ✓ Filtrage des produits non vendus en ligne (onsale_web = 0)

  c) Feature engineering

  ✓ Calcul du stock réel à partir de stock_quantity

  d) Points d'attention

  ✓ Présence de valeurs incohérentes (stock_status, valeurs négatives)

Analyses Exploratoires des Données

2) Caractéristiques, traitements réalisés et points d'attention (approche par dataset)

- **Dataset Web :**

  a) Caractéristiques

  ✓ 1 513 lignes, 29 colonnes avant nettoyage
  ✓ Clé primaire : sku
  ✓ Le dataset a été épuré pour ne garder que les colonnes utiles à la jointure et à l'analyse : sku (renommé id_web), produits, prix et ventes, et libellé du produit
  ✓ 713 lignes et 7 colonnes après nettoyage

  b) Nettoyage

  ✓ Suppression après validation hierarchique des colonnes non pertinentes à l'analyse (contenus, status, etc.) après contrôle global du dataset
  ✓ SKU : Identification et filtrage des valeurs ne respectant pas les règles de codification (NaN, non integer)
  ✓ Après validation, suppression des doublons via post_type = attachment pour conserver uniquement les lignes post_type = product

Analyses Exploratoires des Données

2) Caractéristiques, traitements réalisés et points d'attention (approche par dataset)

- **Dataset Web (suite) :**

  c) Feature engineering

  ✓ Contrôle d'unicité des valeurs et du type de données

  ✓ Renommer sku → id_web pour matcher directement la colonne de liaison

  d) Points d'attention

  ✓ Présence de colonnes non pertinentes à l'analyse

  ✓ Présence de doublons et de valeurs manquantes

- **Dataset Liaison :**

  a) Caractéristiques

  ✓ 825 lignes, 2 colonnes (713 lignes après nettoyage)

  ✓ Table de liaison reliant ERP et Web

  b) Nettoyage et points d'attention

  ✓ Suppression après validation hiérarchique des lignes vides de la colonne id_web.

Fusion ou consolidations des données

1) Choix des attributs

- Variables retenues : price, purchase_price, stock_quantity, total_sales, product_type, post_name

2) Clés utilisées

Deux étapes de jointure pour obtenir une base consolidée (df_merge_vf) avec 713 produits valides :

- Jointure 1 (ERP ↔ Liaison) : clé *product_id*
- Jointure 2 (ERP-Liaison ↔ Web) : clé *id_web*

3) Vigilances particulières au cours du traitement

- Vérification d'unicité des clés (*product_id, id_web*)
- Filtrage des lignes corrompues : sku manquant, non entier, ou incohérent
- Choix du type de jointure :

  a) Jointure interne pour relier ERP à Liaison, pour ne conserver que les produits présents dans les deux fichiers, garantissant une liaison valide vers les données web.

  b) Jointure gauche pour relier ERP-Liaison à Web, pour garder toutes les lignes 'produits' issues de l'ERP (base principale) même si certaines n'ont pas d'équivalent dans le Web.

Fusion ou consolidations des données

4) Difficultés ou pièges rencontrés

- Doublons sur les sku : souvent liés à des attibuts *attachment* → suppression nécessaire
- Sku atypiques (libellés cadeaux, formats non numériques) → exclusion manuelle
- Articles sans correspondance dans la table Liaison → filtrés pour éviter les ruptures de jointure

Analyses univariées du prix

1) Méthodes statistiques employées

a) Méthode graphique : Boxplot de la répartition des prix :

- Permet de repérer d'un coup d'œil les produits très chers ou très peu chers par rapport à l'ensemble.

- La plupart des produits sont vendus à des prix moyens **(boîte centrale entre 20 € et 50 €),** et seuls quelques-uns sont vraiment très haut de gamme (**points isolés au-delà de 80 €).**

- **La médiane (entre 25 et 30 €)** confirme que la plupart des produits tournent autour d'un prix moyen, tandis que l'étendue des moustaches (10 € à 80 €) révèle la diversité des tarifs pratiqués.

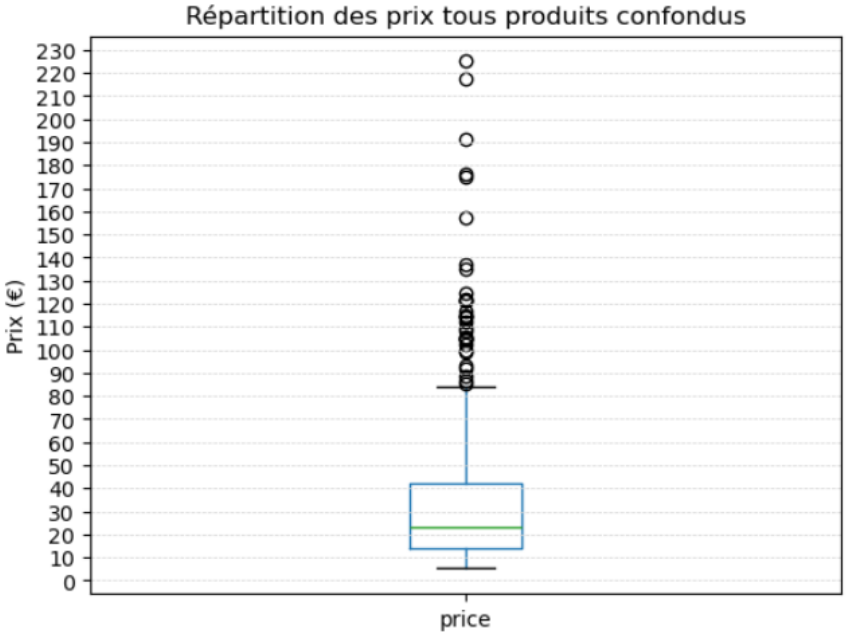

Analyses univariées du prix

1) Méthodes statistiques employées

b) Identification par le Z-index :

- Permet de standardiser chaque prix par rapport à la moyenne et à l'écart-type, et de repérer les valeurs extrêmes.

- Une première étape de calcul du **prix moyen, médian et de l'écart-type** montre une distribution asymétrique à droite, avec quelques produits très chers.

- Le calcul du **Z-index > 3** nous permet d'identifier le prix seuil de **116,40 €** , à partir duquel tout produit vendu plus cher que ce montant est considéré comme un outlier.

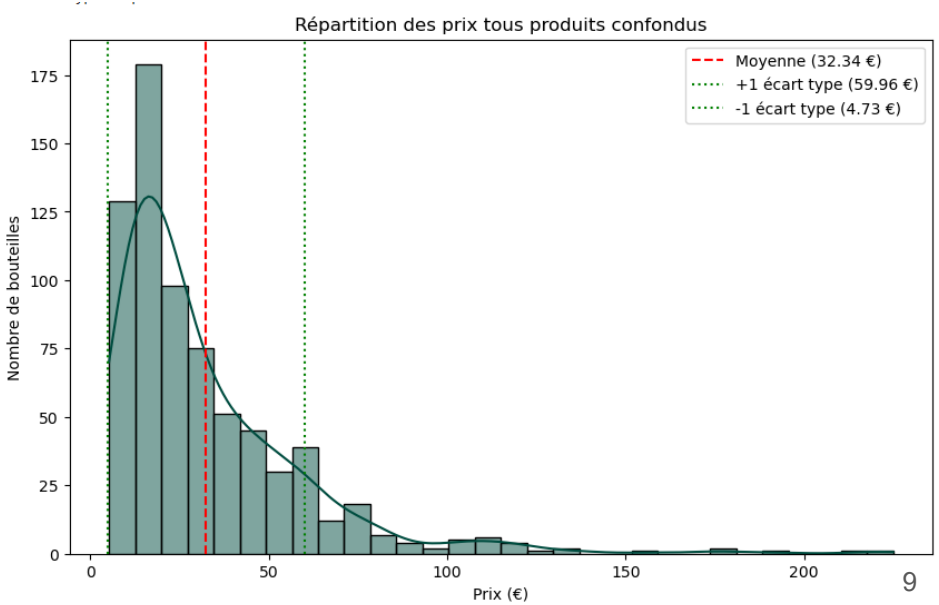

Analyses univariées du prix

1) Méthodes statistiques employées

c) Identification par l'intervalle interquartile :

- Permet de repérer les produits dont le prix est anormalement élevé par rapport au reste du catalogue.
- Le calcul montre ici un seuil haut de **84,18 €.**
- 31 produits dépassent 84,18 €, soit **4,35 % du catalogue**. Il s'agit principalement de grands crus, champagnes millésimés, cognacs et whiskys d'exception.
- Les cas atypiques (prix élevé avec faible vente ou stock nul) doivent être revus commercialement : cela peut signaler une erreur de saisie ou un mauvais positionnement produit.

Analyses univariées du prix

2) Limites éventuelles de l'analyse

- Vision partielle du contexte :

  L'analyse univariée traite chaque variable indépendamment. Elle ne tient pas compte des interactions entre prix, ventes, stock, etc., ce qui peut masquer des corrélations ou causalités importantes.

- Données commerciales non qualifiées

  Le fait qu'un produit soit cher (Z-score > 3) n'est pas nécessairement un problème. L'analyse ne tient pas compte du positionnement marketing, de la rareté du produit ou de la stratégie de pricing.

- Analyse limitée à un seul mois

  Les données ne couvrent que le mois d'octobre. On ne peut pas voir les variations selon les saisons ou les tendances sur l'année.

Analyses complémentaires
CA, quantités, stocks, taux de marge et correlations

1) Analyse du chiffre d'affaires (CA)

- Méthode employée :
  CA = price × total_sales

- L'ensemble montre que **les produits haut de gamme**, notamment champagnes et grands crus, dominent nettement le chiffre d'affaires du catalogue.

- Les champagnes millésimés et grands crus ont naturellement des prix plus élevés. Un **classement par chiffre d'affaires va donc privilégier les produits coûteux**, même s'ils se vendent en faible quantité.

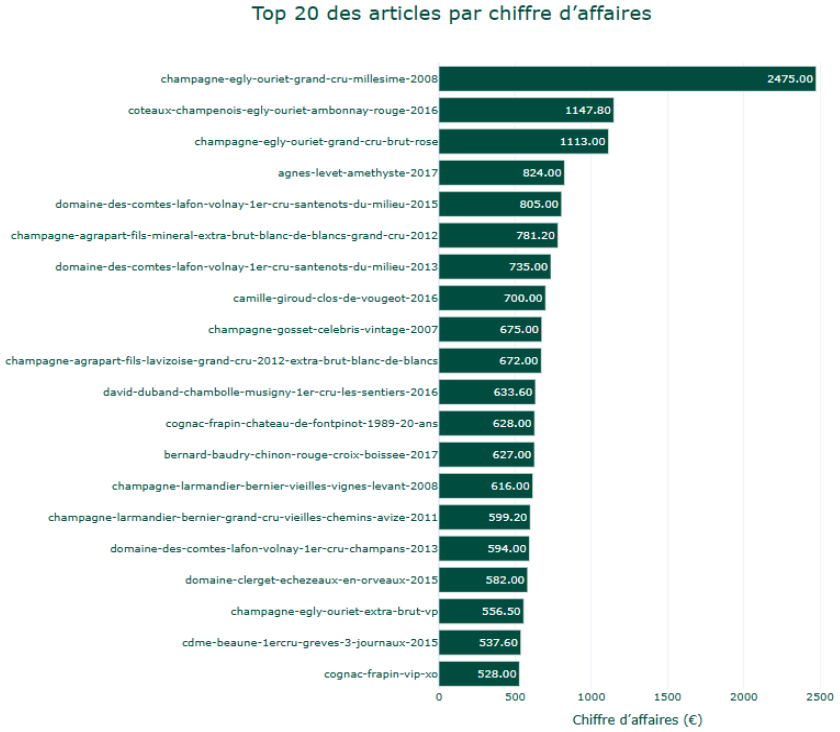

Analyses complémentaires
CA, quantités, stocks, taux de marge et correlations

2) Analyse des ventes en quantité

- Méthode employée :
total_sales = quantités vendues par produit

- Les produits abordables, comme le Maguelonne Rosé 2019 (36 bouteilles vendues) ou le Pampres Blanc 2018 (27 bouteilles), se retrouvent en tête du classement, suggérant un **fort attrait pour les cuvées à bon rapport qualité-prix.**

- N'intègre pas le chiffre d'affaires ni la marge, donc **vision partielle** de la performance produit.

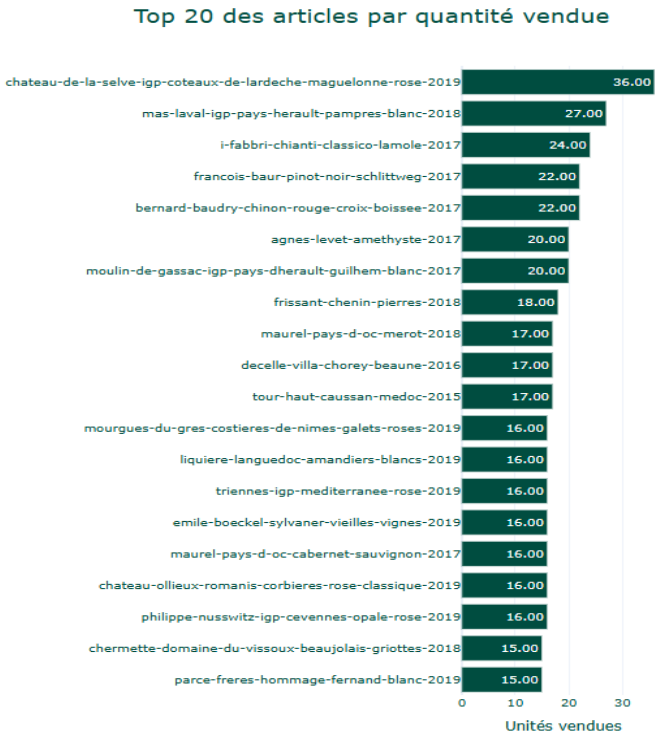

3) Vérification de la Loi de Pareto : 20 % des produits génèrent 80 % des ventes

- Méthodes employées :
  - ✓ Calcul du **total des unités vendues** (total_sales) dans le catalogue.
  - ✓ Pour chaque produit, calcul de sa **part dans les ventes** (en %).
  - ✓ **Cumul progressif** de ces parts pour repérer les produits les plus vendus.
  - ✓ **Filtrage** des produits jusqu'à atteindre 80 % des ventes cumulées.
  - ✓ Décompte du nombre de produits concernés et calcul de leur **proportion dans le catalogue**.

- Résultats en termes de part du CA et de quantités vendues :
  - ✓ Part du CA : 433 produits sont responsables de 80% du chiffre d'affaires
  - ✓ Part des quantités vendues : 432 produits sont responsables de 80 % des ventes en volume.
  - ✓ Ces articles représentent environ 60% du catalogue total (713 produits).

- Interprétation :
  - ✓ Contrairement à la loi de Pareto classique, ici 60 % du catalogue est nécessaire pour générer 80 % du CA et des ventes.
  - ✓ Cela montre que le catalogue est moins polarisé que prévu : les ventes sont plus réparties, il n'y a pas seulement une poignée de produits stars qui font toute la performance.

Analyses complémentaires
CA, quantités, stocks, taux de marge et correlations

4) Analyse des stocks

- Méthode employée :
  Rotation de stock (stock_quantity / total_sales) et Flop 20

- Les produits affichés sont des champagnes, vins ou spiritueux **haut de gamme.**

- La rotation **dépasse 14 mois** pour tous, atteignant jusqu'à 31,25 mois pour le Champagne Gosset Grand Millésime 2006.

- Ces produits sont très qualitatifs mais souffrent probablement d'un **positionnement trop haut de gamme** ou d'un **manque de visibilité commerciale.**

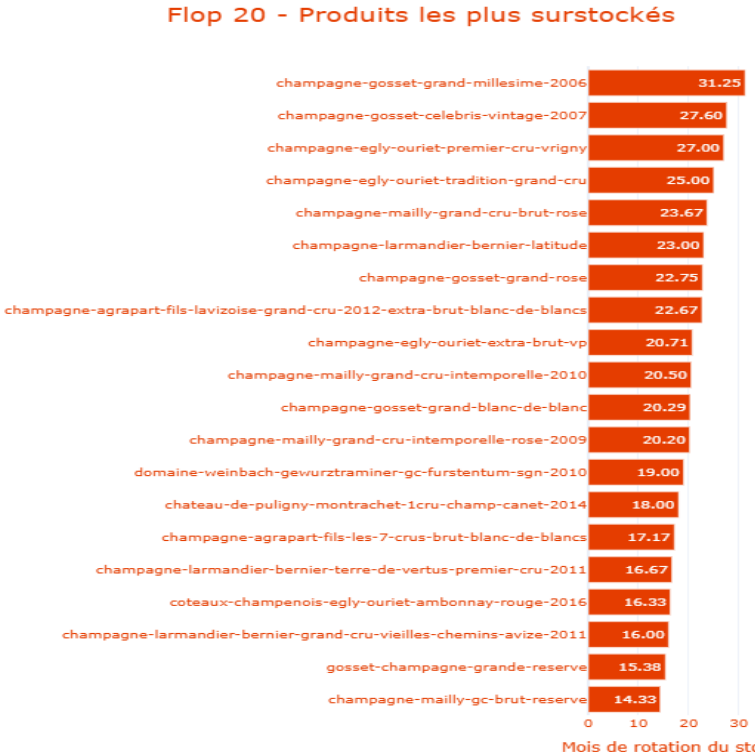

5) Analyse du taux de marge

- Méthode employée :

Taux de marge = ((prix_ht - prix_achat) / prix_ht) * 100

- Les spiritueux (Cognac, Gin, Whisky) dominent en termes de rentabilité relative. Le Champagne montre une marge bien plus faible.

- Dans la catégorie Vin, certains produits peuvent avoir une forte marge, et d'autres une marge très faible.

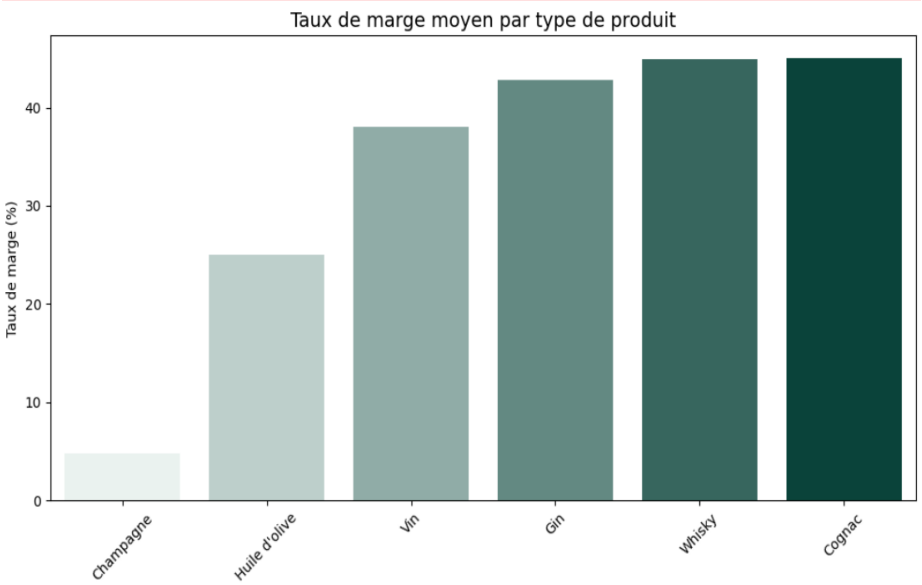

6) Corrélations entre stocks, ventes et prix

- Méthode employée : Visualisation par **heatmap de corrélation** des variables **stock_quantity, total_sales et price**
- **Ventes et stock sont liés (corrélation positive) :** les produits avec plus de stock sont généralement ceux qui se vendent le plus.
- **Prix et ventes sont inversement liés (corrélation négative nette) :** Les produits les plus chers se vendent en plus faibles quantités. Mais le fait qu'un produit soit cher ne cause pas forcément la baisse de ses ventes (**corrélation n'est pas causalité**).
- **Lien faible entre prix et stock (légère corrélation négative)** : Les produits chers sont moins stockés.

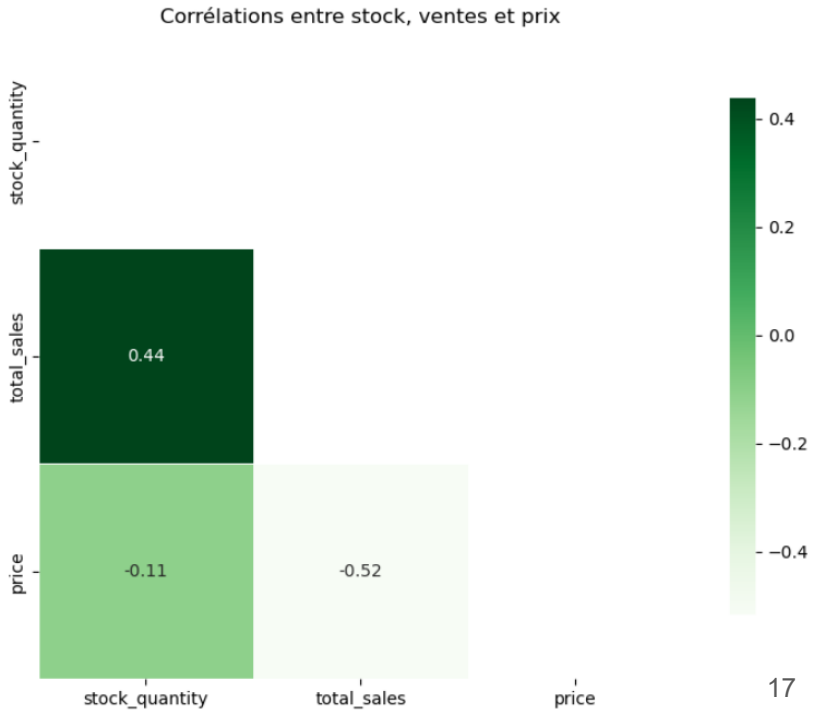

Actions pour la suite

1) Recommandations pour optimiser la gestion des données

- Création d'un dictionnaire de données :
  - ✓ Produire un dictionnaire de données listant chaque variable, son type, son origine, sa signification.
  - ✓ Utile pour vous mais aussi pour d'éventuels audits ou intégrations futures (BI).

- Gestion des types de données :
  - ✓ Mettre en place une logique d'intégration de données fiable pour uniformiser le type de données attendu par variable (Exemple : SKU ne doit contenir que des données type integer)

- Nettoyage systématique des valeurs aberrantes :
  - ✓ Prix et stock négatifs transformés en absolus
  - ✓ Stock_status recalculé via quantité (0 → "outofstock", >0 → "instock")

- Gestion des valeurs manquantes ou en doublon :
  - ✓ Repérer les cellules contenant des valeurs manquantes pour savoir quelles actions prendre (imputation, suppression, etc.)
  - ✓ Supprimer les doublons attachment pour ne conserver qu'une seule ligne product par sku

Actions pour la suite

2) Recommandations pour optimiser la gestion de stock

- Identifier les produits à risque de surstock ou de rupture en se basant sur une segmentation simple :
  - ✓ Stock important / faibles ventes : surstock (à écouler rapidement).
  - ✓ Stock faible / fortes ventes : risque de rupture (à surveiller de près pour réapprovisionner).
  - ✓ Stock faible / faibles ventes : produits à liquider ou n'en garder qu'une très faible quantité.
  - ✓ Stock important / fortes ventes : produits à surveiller en priorité.

- Réduire le stock des produits à faible rotation :
  - ✓ Réduire ou réorganiser les références qui se vendent peu et encombrent le stock.
  - ✓ Envisager de ne plus réapprovisionner ces produits.

- Passer à une analyse dynamique dans le temps avec un outil d'analyse BI :
  - ✓ Détection des tendances (baisse régulière, saisonnalité…).
  - ✓ Dashboard BI avec indicateurs clés : taux de rotation, valeur immobilisée, ruptures potentielles…
  - ✓ Seuils d'alerte et revue périodique (trimestrielle par exemple) pour ajuster les politiques d'achat et de pricing.

Point sur les compétences apprises

1) Qu'est-ce qui s'est bien passé pour vous dans ce travail de nettoyage ?

- L'approche « étape par étape » du notebook qui a facilité le suivi des corrections et la relecture de chaque transformation.
- L'utilisation fréquente de méthodes (describe(), .info() par exemple) qui m'ont permis de repérer assez rapidement les prix et stocks négatifs, les valeurs manquantes et les doublons.
- Le repérage de valeurs problématiques (doublons, valeurs manquantes)
- Les jointures que je comprends de mieux en mieux

2) Qu'est-ce que vous avez trouvé le plus difficile ?

- L'apport théorique de nouvelles méthodes statistiques et de nouveaux concepts marketing
- Les nombreux « SettingWithCopyWarning » qui ont soulevé la question de l'application sûre des correctifs (utiliser .loc ou des copies explicites).

3) Sur quelles tâches est-ce que vous pensez avoir besoin de plus d'entraînement ?

- L'application des méthodes statistiques qui impliquent des calculs comme la médiane et l'écart-type.
- L'interprétation de graphiques plus complexes comme le boxplot et le heatmap.