# Rake_Anthony_1_notebook_092025_v2

September 11, 2025

Analysez les ventes d'une librairie avec Python

## 1 BRIEF ANABELLE

Nous souhaitons élaborer différents graphiques autour du chiffre d'affaires comme par exemples l'évolution dans le temps du : chiffre d'affaires avec la moyenne mobile (tu pourras choisir la période : jour, semaine, mois, etc.), chiffre d'affaires par catégorie, nombre de clients par mois, nombre de transactions, nombre de produits vendus, etc. Il serait également intéressant de faire un zoom sur les références : les tops, les flops, la répartition par catégorie, etc. Enfin, j'aimerais avoir quelques informations sur les profils de nos clients : répartition du chiffre d'affaires pour les clients BtoB, courbe de Lorenz, etc. Après, toutes les informations et tous graphiques qui apporteraient de l'information pertinente sont les bienvenus !

## 2 COMPLEMENT JULIE

5 corrélations : le lien entre le genre d'un client et les catégories des livres achetés, le lien entre l'âge des clients et le montant total des achats, le lien entre l'âge des clients et la fréquence d'achat, le lien entre l'âge des clients et la taille du panier moyen, et pour finir le lien entre l'âge des clients et la catégorie des livres achetés.

Etape 1 - Importation des librairies et chargement des fichiers

1.1 - Importation des librairies

[8]:
```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
import plotly.express as px
import seaborn as sns
import matplotlib.colors as mcolors
from scipy.stats import pearsonr
```

[9]:
```
!pip install scikit-posthocs
```

```
Requirement already satisfied: scikit-posthocs in
c:\users\t_rak\anaconda3\lib\site-packages (0.11.4)
Requirement already satisfied: numpy in c:\users\t_rak\anaconda3\lib\site-
packages (from scikit-posthocs) (1.26.4)
Requirement already satisfied: scipy>=1.9.0 in
```

```
c:\users\t_rak\anaconda3\lib\site-packages (from scikit-posthocs) (1.13.1)
Requirement already satisfied: statsmodels in c:\users\t_rak\anaconda3\lib\site-
packages (from scikit-posthocs) (0.14.2)
Requirement already satisfied: pandas>=0.20.0 in
c:\users\t_rak\anaconda3\lib\site-packages (from scikit-posthocs) (2.2.2)
Requirement already satisfied: seaborn in c:\users\t_rak\anaconda3\lib\site-
packages (from scikit-posthocs) (0.13.2)
Requirement already satisfied: matplotlib in c:\users\t_rak\anaconda3\lib\site-
packages (from scikit-posthocs) (3.9.2)
Requirement already satisfied: python-dateutil>=2.8.2 in
c:\users\t_rak\anaconda3\lib\site-packages (from pandas>=0.20.0->scikit-
posthocs) (2.9.0.post0)
Requirement already satisfied: pytz>=2020.1 in
c:\users\t_rak\anaconda3\lib\site-packages (from pandas>=0.20.0->scikit-
posthocs) (2024.1)
Requirement already satisfied: tzdata>=2022.7 in
c:\users\t_rak\anaconda3\lib\site-packages (from pandas>=0.20.0->scikit-
posthocs) (2023.3)
Requirement already satisfied: contourpy>=1.0.1 in
c:\users\t_rak\anaconda3\lib\site-packages (from matplotlib->scikit-posthocs)
(1.2.0)
Requirement already satisfied: cycler>=0.10 in
c:\users\t_rak\anaconda3\lib\site-packages (from matplotlib->scikit-posthocs)
(0.11.0)
Requirement already satisfied: fonttools>=4.22.0 in
c:\users\t_rak\anaconda3\lib\site-packages (from matplotlib->scikit-posthocs)
(4.51.0)
Requirement already satisfied: kiwisolver>=1.3.1 in
c:\users\t_rak\anaconda3\lib\site-packages (from matplotlib->scikit-posthocs)
(1.4.4)
Requirement already satisfied: packaging>=20.0 in
c:\users\t_rak\anaconda3\lib\site-packages (from matplotlib->scikit-posthocs)
(24.1)
Requirement already satisfied: pillow>=8 in c:\users\t_rak\anaconda3\lib\site-
packages (from matplotlib->scikit-posthocs) (10.4.0)
Requirement already satisfied: pyparsing>=2.3.1 in
c:\users\t_rak\anaconda3\lib\site-packages (from matplotlib->scikit-posthocs)
(3.1.2)
Requirement already satisfied: patsy>=0.5.6 in
c:\users\t_rak\anaconda3\lib\site-packages (from statsmodels->scikit-posthocs)
(0.5.6)
Requirement already satisfied: six in c:\users\t_rak\anaconda3\lib\site-packages
(from patsy>=0.5.6->statsmodels->scikit-posthocs) (1.16.0)
```

1.2 - Chargements des fichiers

[11]:
```python
import os
print(os.getcwd())
```

```
C:\Users\t_rak\Documents
```

[12]:
```python
#Importation datasets
df_products = pd.read_csv("p9_products.csv", sep=";")
df_customers = pd.read_csv("p9_customers.csv", sep=";")
df_transactions = pd.read_csv("p9_Transactions.csv", sep=";")
```

```
C:\Users\t_rak\AppData\Local\Temp\ipykernel_28132\1415768471.py:4: DtypeWarning:
Columns (0,1,2,3) have mixed types. Specify dtype option on import or set
low_memory=False.
  df_transactions = pd.read_csv("p9_Transactions.csv", sep=";")
```

Etape 2 - Analyse exploratoire et pré-traitement des datasets

2.1 - Dataset products

[15]:
```python
#Dimensions
print("Le tableau comporte {} observation(s) ou article(s)".format(df_products.
 ↪shape[0]))
print("Le tableau comporte {} colonne(s)".format(df_products.shape[1]))
```

```
Le tableau comporte 3286 observation(s) ou article(s)
Le tableau comporte 3 colonne(s)
```

[16]:
```python
#aperçu df
df_products.head(5)
```

[16]:

| | id_prod | price | categ |
|---|---|---|---|
| 0 | 0_1421 | 19.99 | 0 |
| 1 | 0_1368 | 5.13 | 0 |
| 2 | 0_731 | 17.99 | 0 |
| 3 | 1_587 | 4.99 | 1 |
| 4 | 0_1507 | 3.99 | 0 |

[17]:
```python
#résumé global
df_products.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3286 entries, 0 to 3285
Data columns (total 3 columns):
 #   Column   Non-Null Count  Dtype
---  ------   --------------  -----
 0   id_prod  3286 non-null   object
 1   price    3286 non-null   float64
 2   categ    3286 non-null   int64
dtypes: float64(1), int64(1), object(1)
memory usage: 77.1+ KB
```

[18]:
```python
#COLONNE PRICE résumé stats
df_products['price'].describe()
```

[18]:
```
count    3286.000000
mean       21.863597
std        29.849786
min         0.620000
25%         6.990000
50%        13.075000
75%        22.990000
max       300.000000
Name: price, dtype: float64
```

[19]:
```python
#COLONNE PRICE prix min vs prix max
print("Le prix minimum est : {} euros".format(df_products['price'].min()))
print("Le prix minimum est : {} euros".format(df_products['price'].max()))
```

```
Le prix minimum est : 0.62 euros
Le prix minimum est : 300.0 euros
```

[20]:
```python
#COLONNE CATEG valeurs uniques
df_products['categ'].unique()
```

[20]:
```
array([0, 1, 2], dtype=int64)
```

[21]:
```python
#COLONNE CATEG à quoi correspondent ces catégories ? Pas à des segments de prix.
↪ Creuser sur le df final
df_products.groupby("categ")["price"].agg(min_price=("min"), max_price=("max"),␣
↪mean_price=("mean")).reset_index()
```

[21]:

| | categ | min_price | max_price | mean_price |
|---|---|---|---|---|
| 0 | 0 | 0.62 | 40.99 | 11.732795 |
| 1 | 1 | 2.00 | 80.99 | 25.531421 |
| 2 | 2 | 30.99 | 300.00 | 108.354686 |

[22]:
```python
#COLONNE ID verif doublons
doublons_products = df_products[df_products.duplicated(subset='id_prod',␣
↪keep=False)]
doublons_products
```

[22]:
```
Empty DataFrame
Columns: [id_prod, price, categ]
Index: []
```

[23]:
```python
#COLONNE ID double verif doublons
print(f"Nb de valeurs uniques dans 'id_prod' : {df_products['id_prod'].
↪nunique()} vs Nb de lignes dans le dataset : {len(df_products)}")
```

```
Nb de valeurs uniques dans 'id_prod' : 3286 vs Nb de lignes dans le dataset :
3286
```

2.2 - Dataset customers

[25]:
```
#Dimensions
print("Le tableau comporte {} observation(s) ou article(s)".format(df_customers.
 ↪shape[0]))
print("Le tableau comporte {} colonne(s)".format(df_customers.shape[1]))
```

```
Le tableau comporte 8621 observation(s) ou article(s)
Le tableau comporte 3 colonne(s)
```

[26]:
```
#Aperçu
df_customers.head()
```

[26]:

| | client_id | sex | birth |
|---|---|---|---|
| 0 | c_4410 | f | 1967 |
| 1 | c_7839 | f | 1975 |
| 2 | c_1699 | f | 1984 |
| 3 | c_5961 | f | 1962 |
| 4 | c_5320 | m | 1943 |

[27]:
```
#résumé global
df_customers.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8621 entries, 0 to 8620
Data columns (total 3 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   client_id  8621 non-null   object
 1   sex        8621 non-null   object
 2   birth      8621 non-null   int64
dtypes: int64(1), object(2)
memory usage: 202.2+ KB
```

[28]:
```
#COLONNE BIRTH verif année min et max
print("ADN min : {}".format(df_customers['birth'].min()))
print("ADN max : {}".format(df_customers['birth'].max()))
```

```
ADN min : 1929
ADN max : 2004
```

[29]:
```
#COLONNE BIRTH calcul colonne Age pour visualisation segmentation age
from datetime import datetime

# Récupérer l'année actuelle
annee_actuelle = datetime.now().year

# Calculer l'âge
df_customers['Age'] = annee_actuelle - df_customers['birth']
df_customers
```

[29]:

| | client_id | sex | birth | Age |
|---|---|---|---|---|
| 0 | c_4410 | f | 1967 | 58 |
| 1 | c_7839 | f | 1975 | 50 |
| 2 | c_1699 | f | 1984 | 41 |
| 3 | c_5961 | f | 1962 | 63 |
| 4 | c_5320 | m | 1943 | 82 |
| … | … | .. | … | … |
| 8616 | c_7920 | m | 1956 | 69 |
| 8617 | c_7403 | f | 1970 | 55 |
| 8618 | c_5119 | m | 1974 | 51 |
| 8619 | c_5643 | f | 1968 | 57 |
| 8620 | c_84 | f | 1982 | 43 |

[8621 rows x 4 columns]

[30]:

```
#COLONNE AGE dataviz repartition
plt.figure(figsize=(10, 6))
sns.histplot(df_customers['Age'], bins=15, kde=True, color='skyblue')
plt.title("Distribution des âges des clients")
plt.xlabel("Âge")
plt.ylabel("Nombre de clients")
plt.show()
```

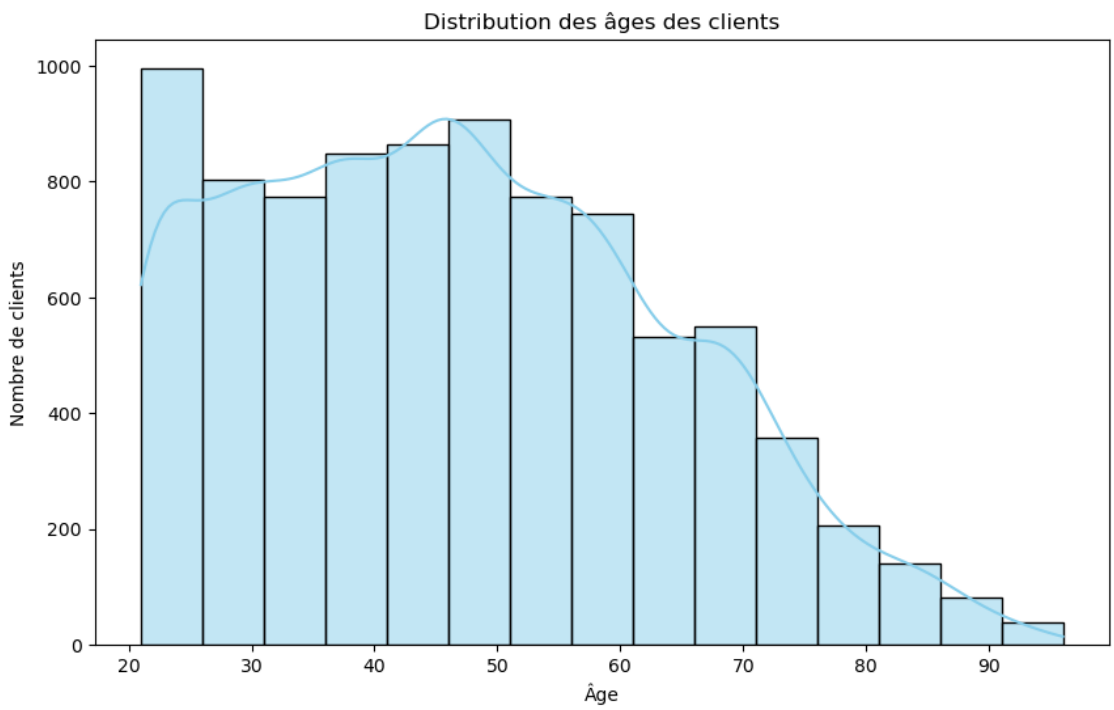

[31]:
```python
#COLONNE SEX verif valeurs uniques
df_customers['sex'].unique()
```

[31]:
```
array(['f', 'm'], dtype=object)
```

[32]:
```python
#COLONNE SEX répartition hommes femmes
# Comptage des occurrences
counts = df_customers['sex'].value_counts()
total = len(df_customers)

# Calcul des pourcentages
pourcentage_femmes = (counts.get('f', 0) / total) * 100
pourcentage_hommes = (counts.get('m', 0) / total) * 100

# Affichage
print(f"Pourcentage de femmes : {pourcentage_femmes:.2f}%")
print(f"Pourcentage d'hommes : {pourcentage_hommes:.2f}%")
```

```
Pourcentage de femmes : 52.08%
Pourcentage d'hommes : 47.92%
```

[33]:
```python
# SEX AGE dataviz distribution
# Style
sns.set(style="whitegrid")

# Création du boxplot avec hue et palette personnalisée
plt.figure(figsize=(8, 6))
ax = sns.boxplot(x='sex', y='Age', hue='sex', data=df_customers,
                 palette={'f': '#ff69b4', 'm': '#1f77b4'}, legend=False)

# Calcul et annotation des âges médians
medians = df_customers.groupby('sex')['Age'].median()
for i, sex in enumerate(medians.index):
    median_val = medians[sex]
    ax.text(i, median_val + 1, f'Médiane : {median_val}', ha='center',
            fontsize=10, color='black', weight='semibold')

# Titres et axes
plt.title('Distribution des âges par sexe')
plt.xlabel('Sexe')
plt.ylabel('Âge')
plt.show()
```

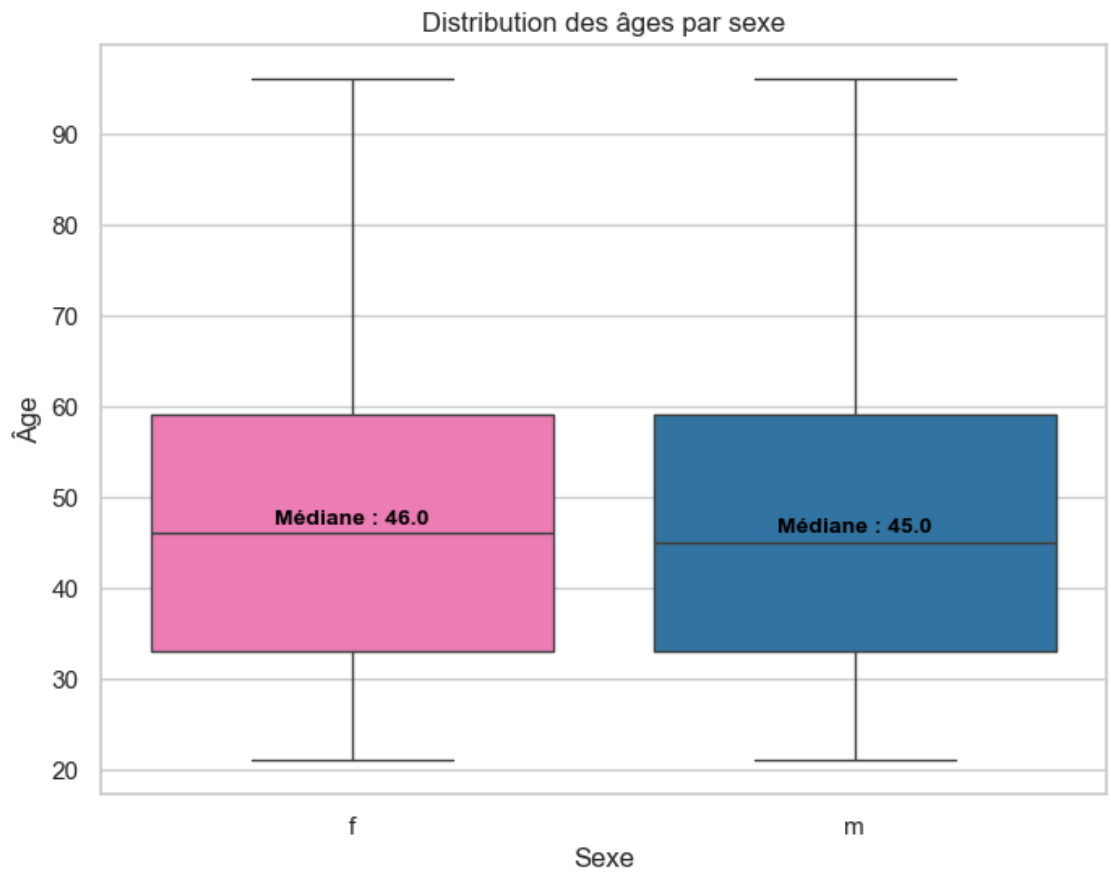


[34]:
```
#COLONNE ID CLIENTS verif doublons
doublons_customers = df_customers[df_customers.duplicated(subset='client_id',␣
↪keep=False)]
doublons_customers
```

[34]:
```
Empty DataFrame
Columns: [client_id, sex, birth, Age]
Index: []
```

[35]:
```
#COLONNE ID CLIENTS double verif doublons
print(f"Nb de valeurs uniques dans 'client_id' : {df_customers['client_id'].
↪nunique()} vs Nb de lignes dans le dataset : {len(df_customers)}")
```

```
Nb de valeurs uniques dans 'client_id' : 8621 vs Nb de lignes dans le dataset :
8621
```

2.3 - Dataset transactions

[37]:
```
#Dimensions
```

```
print("Le tableau comporte {} observation(s) ou article(s)".
 ↪format(df_transactions.shape[0]))
print("Le tableau comporte {} colonne(s)".format(df_transactions.shape[1]))
```

```
Le tableau comporte 1048575 observation(s) ou article(s)
Le tableau comporte 4 colonne(s)
```

[38]:
```
#Aperçu
df_transactions.head()
```

[38]:

| | id_prod | date | session_id | client_id |
|---|---|---|---|---|
| 0 | 0_1259 | 2021-03-01 00:01:07.843138 | s_1 | c_329 |
| 1 | 0_1390 | 2021-03-01 00:02:26.047414 | s_2 | c_664 |
| 2 | 0_1352 | 2021-03-01 00:02:38.311413 | s_3 | c_580 |
| 3 | 0_1458 | 2021-03-01 00:04:54.559692 | s_4 | c_7912 |
| 4 | 0_1358 | 2021-03-01 00:05:18.801198 | s_5 | c_2033 |

[39]:
```
#résumé global
df_transactions.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1048575 entries, 0 to 1048574
Data columns (total 4 columns):
 #   Column      Non-Null Count   Dtype
---  ------      --------------   -----
 0   id_prod     687534 non-null  object
 1   date        687534 non-null  object
 2   session_id  687534 non-null  object
 3   client_id   687534 non-null  object
dtypes: object(4)
memory usage: 32.0+ MB
```

[40]:
```
#Controles des cellules vides par colonne
colonnes = ['id_prod', 'date', 'session_id', 'client_id']

# Comptage des NaN
nan_counts = df_transactions[colonnes].isna().sum()

# Affichage
for col in colonnes:
    print(f"Nombre de valeurs manquantes dans '{col}' : {nan_counts[col]}")
```

```
Nombre de valeurs manquantes dans 'id_prod' : 361041
Nombre de valeurs manquantes dans 'date' : 361041
Nombre de valeurs manquantes dans 'session_id' : 361041
Nombre de valeurs manquantes dans 'client_id' : 361041
```

[41]:
```python
#Controle des lignes entièrement vides
colonnes = ['id_prod', 'date', 'session_id', 'client_id']

# Filtrer les lignes où toutes les colonnes sont NaN
nb_lignes_nan_total = df_transactions[colonnes].isna().all(axis=1).sum()

print(f"Nombre de lignes où les 4 colonnes sont NaN : {nb_lignes_nan_total}")
```

```
Nombre de lignes où les 4 colonnes sont NaN : 361041
```

[42]:
```python
# Supprimer les lignes où les 4 colonnes sont toutes NaN
df_transactions = df_transactions[~df_transactions[colonnes].isna().all(axis=1)]
```

[43]:
```python
#Controles des cellules vides par colonne APRES SUPPRESSION LIGNES NAN
colonnes = ['id_prod', 'date', 'session_id', 'client_id']

# Comptage des NaN
nan_counts = df_transactions[colonnes].isna().sum()

# Affichage
for col in colonnes:
    print(f"Nombre de valeurs manquantes dans '{col}' : {nan_counts[col]}")
```

```
Nombre de valeurs manquantes dans 'id_prod' : 0
Nombre de valeurs manquantes dans 'date' : 0
Nombre de valeurs manquantes dans 'session_id' : 0
Nombre de valeurs manquantes dans 'client_id' : 0
```

[44]:
```python
#COLONNE DATE verif du format des valeurs date
import re

# Définir le motif attendu
pattern = r"^\d{4}-\d{2}-\d{2} \d{2}:\d{2}:\d{2}\.\d{6}$"

# Vérifier chaque valeur
invalid_dates = df_transactions['date'].dropna().apply(lambda x: not bool(re.
 ↪match(pattern, str(x))))

# Compter les valeurs non conformes
nb_invalid = invalid_dates.sum()
print(f"Nombre de dates non conformes : {nb_invalid}")
```

```
Nombre de dates non conformes : 87
```

[45]:
```python
#COLONNE DATE affichage des dates non conformes pour trouver le problème
# Motif attendu
pattern = r"^\d{4}-\d{2}-\d{2} \d{2}:\d{2}:\d{2}\.\d{6}$"

# Filtrer les lignes non conformes
```

```
invalid_date_rows = df_transactions[df_transactions['date'].dropna().
 ↪apply(lambda x: not bool(re.match(pattern, str(x))))]

# Afficher les lignes concernées
invalid_date_rows
```

[45]:

```
       id_prod                       date session_id client_id
196092   1_111  2021-10-01 05:13:9.438723    s_98272    c_6695
196335   1_612  2021-10-01 09:53:6.991197    s_98355    c_4554
196355   1_225  2021-10-01 10:22:3.713025    s_98364    c_4958
196575   1_426  2021-10-01 14:38:1.424583    s_98464    c_1326
196577   1_445  2021-10-01 14:38:7.604429    s_98464    c_1326
…          …                          …         …         …
222494   1_661  2021-10-28 17:04:9.314938   s_111409    c_4343
222974   1_413  2021-10-29 03:57:6.330350   s_111626    c_7757
223244   1_553  2021-10-29 10:36:8.146248   s_111761    c_3347
223867   1_267  2021-10-30 00:14:9.552439   s_112042    c_1063
225491   1_365  2021-10-31 14:24:6.984395   s_112761     c_691

[87 rows x 4 columns]
```

Non conforme car il manque un 0 dans l'unité des secondes. Extraire les années mois jour malgré cela et faire un check a posteriori

[47]:

```
#COLONNE DATE extraction année/mois/jour et conversion jour_lettre
# Conversion en datetime
df_transactions['date'] = pd.to_datetime(df_transactions['date'],␣
 ↪errors='coerce')

# Extraction
df_transactions['annee'] = df_transactions['date'].dt.year
df_transactions['mois'] = df_transactions['date'].dt.month
df_transactions['jour'] = df_transactions['date'].dt.day
df_transactions['jour_lettre'] = df_transactions['date'].dt.day_name()
df_transactions['mois_lettre'] = df_transactions['date'].dt.month_name()
df_transactions
```

[47]:

```
       id_prod                       date session_id client_id  annee  mois  \
0       0_1259 2021-03-01 00:01:07.843138        s_1     c_329   2021     3
1       0_1390 2021-03-01 00:02:26.047414        s_2     c_664   2021     3
2       0_1352 2021-03-01 00:02:38.311413        s_3     c_580   2021     3
3       0_1458 2021-03-01 00:04:54.559692        s_4    c_7912   2021     3
4       0_1358 2021-03-01 00:05:18.801198        s_5    c_2033   2021     3
…         …                          …         …         …     …    …
687529   1_508 2023-02-28 23:49:03.148402   s_348444    c_3573   2023     2
687530    2_37 2023-02-28 23:51:29.318531   s_348445      c_50   2023     2
687531   1_695 2023-02-28 23:53:18.929676   s_348446     c_488   2023     2
687532  0_1547 2023-02-28 23:58:00.107815   s_348447    c_4848   2023     2
```

```
687533  0_1398 2023-02-28 23:58:30.792755   s_348435    c_3575   2023     2

        jour jour_lettre mois_lettre
0          1      Monday       March
1          1      Monday       March
2          1      Monday       March
3          1      Monday       March
4          1      Monday       March
…        …          …          …
687529    28     Tuesday    February
687530    28     Tuesday    February
687531    28     Tuesday    February
687532    28     Tuesday    February
687533    28     Tuesday    February

[687534 rows x 9 columns]
```

[48]:
```
#COLONNE JOUR LETTRE Traduction manuelle des jours en français
jours_fr = {
    'Monday': 'Lundi',
    'Tuesday': 'Mardi',
    'Wednesday': 'Mercredi',
    'Thursday': 'Jeudi',
    'Friday': 'Vendredi',
    'Saturday': 'Samedi',
    'Sunday': 'Dimanche'
}

# Extraire les jours en anglais puis traduire
df_transactions['jour_lettre'] = df_transactions['date'].dt.day_name().
 ↪map(jours_fr)
```

[49]:
```
#COLONNE MOIS LETTRE Traduction manuelle des mois en français
mois_fr = {
    'January': 'Janvier',
    'February': 'Février',
    'March': 'Mars',
    'April': 'Avril',
    'May': 'Mai',
    'June': 'Juin',
    'July': 'Juillet',
    'August': 'Août',
    'September': 'Septembre',
    'October': 'Octobre',
    'November': 'Novembre',
    'December': 'Décembre'
}
```

```
# Extraire les mois en anglais puis traduire
df_transactions['mois_lettre'] = df_transactions['date'].dt.month_name().
 ↪map(mois_fr)
```

[50]:
```
#Aperçu
df_transactions
```

[50]:
```
        id_prod                       date session_id client_id  annee  mois  \
0        0_1259 2021-03-01 00:01:07.843138        s_1     c_329   2021     3
1        0_1390 2021-03-01 00:02:26.047414        s_2     c_664   2021     3
2        0_1352 2021-03-01 00:02:38.311413        s_3     c_580   2021     3
3        0_1458 2021-03-01 00:04:54.559692        s_4    c_7912   2021     3
4        0_1358 2021-03-01 00:05:18.801198        s_5    c_2033   2021     3
…          …                          …        …       …     …   …
687529    1_508 2023-02-28 23:49:03.148402   s_348444    c_3573   2023     2
687530     2_37 2023-02-28 23:51:29.318531   s_348445      c_50   2023     2
687531    1_695 2023-02-28 23:53:18.929676   s_348446     c_488   2023     2
687532   0_1547 2023-02-28 23:58:00.107815   s_348447    c_4848   2023     2
687533   0_1398 2023-02-28 23:58:30.792755   s_348435    c_3575   2023     2

         jour jour_lettre mois_lettre
0           1       Lundi        Mars
1           1       Lundi        Mars
2           1       Lundi        Mars
3           1       Lundi        Mars
4           1       Lundi        Mars
…       …          …          …
687529     28       Mardi     Février
687530     28       Mardi     Février
687531     28       Mardi     Février
687532     28       Mardi     Février
687533     28       Mardi     Février

[687534 rows x 9 columns]
```

[51]:
```
#Aperçu
df_transactions.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 687534 entries, 0 to 687533
Data columns (total 9 columns):
 #   Column       Non-Null Count   Dtype
---  ------       --------------   -----
 0   id_prod      687534 non-null  object
 1   date         687534 non-null  datetime64[ns]
 2   session_id   687534 non-null  object
 3   client_id    687534 non-null  object
```

```
 4   annee        687534 non-null  int32
 5   mois         687534 non-null  int32
 6   jour         687534 non-null  int32
 7   jour_lettre  687534 non-null  object
 8   mois_lettre  687534 non-null  object
dtypes: datetime64[ns](1), int32(3), object(5)
memory usage: 44.6+ MB
```

[52]:
```
#Verif année première transaction et la plus récente
print("Année début transaction : {}".format(df_transactions['annee'].min()))
print("Année dernière transaction : {}".format(df_transactions['annee'].max()))
```

```
Année début transaction : 2021
Année dernière transaction : 2023
```

Etape 3 - Jonction des fichiers

Etape 3.1 - Jonction products -> transactions

[55]:
```
#Rappel dimensions
print("Le tableau comporte {} observation(s) ou article(s)".format(df_products.
 ↪shape[0]))
print("Le tableau comporte {} observation(s) ou article(s)".
 ↪format(df_transactions.shape[0]))
```

```
Le tableau comporte 3286 observation(s) ou article(s)
Le tableau comporte 687534 observation(s) ou article(s)
```

[56]:
```
#jointure EXTERNE COMPLETE AVEC INDICATEURS
df_prod_trans = df_transactions.merge(df_products, on='id_prod', how='outer',␣
 ↪indicator=True)
```

[57]:
```
#Vérification du nb de lignes ayant été appairées
df_prod_trans['_merge'].value_counts()
```

[57]:
```
_merge
both          687534
right_only        21
left_only          0
Name: count, dtype: int64
```

[58]:
```
#Verif des produits non vendus en 3 ans pour conseil gestion de stock
df_prod_trans_right_only = df_prod_trans[df_prod_trans['_merge'] ==␣
 ↪'right_only']
df_prod_trans_right_only
```

[58]:
```
        id_prod date session_id client_id  annee  mois  jour jour_lettre  \
6073     0_1014  NaT        NaN       NaN    NaN   NaN   NaN         NaN
6511     0_1016  NaT        NaN       NaN    NaN   NaN   NaN         NaN
8723     0_1025  NaT        NaN       NaN    NaN   NaN   NaN         NaN
```

```
21687   0_1062  NaT        NaN       NaN    NaN   NaN   NaN         NaN
40971   0_1119  NaT        NaN       NaN    NaN   NaN   NaN         NaN
94245   0_1318  NaT        NaN       NaN    NaN   NaN   NaN         NaN
297077  0_1620  NaT        NaN       NaN    NaN   NaN   NaN         NaN
299185  0_1624  NaT        NaN       NaN    NaN   NaN   NaN         NaN
311123  0_1645  NaT        NaN       NaN    NaN   NaN   NaN         NaN
323013  0_1780  NaT        NaN       NaN    NaN   NaN   NaN         NaN
325137  0_1800  NaT        NaN       NaN    NaN   NaN   NaN         NaN
387651  0_2308  NaT        NaN       NaN    NaN   NaN   NaN         NaN
389726   0_299  NaT        NaN       NaN    NaN   NaN   NaN         NaN
390221   0_310  NaT        NaN       NaN    NaN   NaN   NaN         NaN
390689   0_322  NaT        NaN       NaN    NaN   NaN   NaN         NaN
397070   0_510  NaT        NaN       NaN    NaN   NaN   NaN         NaN
415475     1_0  NaT        NaN       NaN    NaN   NaN   NaN         NaN
514820   1_394  NaT        NaN       NaN    NaN   NaN   NaN         NaN
685998    2_72  NaT        NaN       NaN    NaN   NaN   NaN         NaN
686501    2_86  NaT        NaN       NaN    NaN   NaN   NaN         NaN
686502    2_87  NaT        NaN       NaN    NaN   NaN   NaN         NaN

       mois_lettre   price  categ      _merge
6073           NaN    1.15      0  right_only
6511           NaN   35.06      0  right_only
8723           NaN   24.99      0  right_only
21687          NaN   20.08      0  right_only
40971          NaN    2.99      0  right_only
94245          NaN   20.92      0  right_only
297077         NaN    0.80      0  right_only
299185         NaN   24.50      0  right_only
311123         NaN    2.99      0  right_only
323013         NaN    1.67      0  right_only
325137         NaN   22.05      0  right_only
387651         NaN   20.28      0  right_only
389726         NaN   22.99      0  right_only
390221         NaN    1.94      0  right_only
390689         NaN    2.99      0  right_only
397070         NaN   23.66      0  right_only
415475         NaN   31.82      1  right_only
514820         NaN   39.73      1  right_only
685998         NaN  141.32      2  right_only
686501         NaN  132.36      2  right_only
686502         NaN  220.99      2  right_only
```

[59]:
```
#Filtre du df sur la valeur "both" (correspondance parfaite entre les id_prod)
df_prod_trans_vf = df_prod_trans[df_prod_trans['_merge'] == 'both']
```

OK. Nous retrouvons le même nb de lignes dans le df transactions initial et le df fusionné : aucune perte des transactions

[61]:
```
#Suppression colonne _merge car conflit pour prochaine fusion
df_prod_trans_vf = df_prod_trans_vf.drop(columns=['_merge'])
df_prod_trans_vf
```

[61]:
```
       id_prod                       date session_id client_id   annee  mois  \
0          0_0 2021-03-01 13:45:51.575117      s_282    c_5152  2021.0   3.0
1          0_0 2021-03-02 06:42:55.351333      s_621    c_2917  2021.0   3.0
2          0_0 2021-03-02 18:49:49.651862      s_852    c_3988  2021.0   3.0
3          0_0 2021-03-02 21:57:33.862118      s_908    c_1004  2021.0   3.0
4          0_0 2021-03-03 23:59:48.997483     s_1379     c_278  2021.0   3.0
…         …                          …        …        …     …    …
687550    2_99 2022-05-21 01:53:46.967570   s_211661    c_5828  2022.0   5.0
687551    2_99 2022-07-21 01:53:46.967570   s_241374    c_5828  2022.0   7.0
687552    2_99 2022-11-11 20:56:49.820935   s_296127    c_7135  2022.0  11.0
687553    2_99 2022-12-11 20:56:49.820935   s_310606    c_7135  2022.0  12.0
687554    2_99 2023-01-21 01:53:46.967570   s_329932    c_5828  2023.0   1.0

        jour jour_lettre mois_lettre  price  categ
0        1.0       Lundi        Mars   3.75      0
1        2.0       Mardi        Mars   3.75      0
2        2.0       Mardi        Mars   3.75      0
3        2.0       Mardi        Mars   3.75      0
4        3.0    Mercredi        Mars   3.75      0
…       …         …         …    …    …
687550  21.0      Samedi         Mai  84.99      2
687551  21.0       Jeudi     Juillet  84.99      2
687552  11.0    Vendredi    Novembre  84.99      2
687553  11.0    Dimanche    Décembre  84.99      2
687554  21.0      Samedi     Janvier  84.99      2

[687534 rows x 11 columns]
```

Etape 3.1 bis - Jonction customers -> transactions pour vérification nb de lignes finales

[63]:
```
#Rappel dimensions
print("Le tableau customers comporte {} observation(s) ou article(s)".
 ↪format(df_customers.shape[0]))
print("Le tableau transactions comporte {} observation(s) ou article(s)".
 ↪format(df_transactions.shape[0]))
```

```
Le tableau customers comporte 8621 observation(s) ou article(s)
Le tableau transactions comporte 687534 observation(s) ou article(s)
```

[64]:
```
#jointure EXTERNE COMPLETE AVEC INDICATEURS
df_cust_trans = df_transactions.merge(df_customers, on='client_id',␣
 ↪how='outer', indicator=True)
```

[65]:
```python
#Vérification du nb de lignes ayant été appairées
df_cust_trans['_merge'].value_counts()
```

[65]:
```
_merge
both          687534
right_only        21
left_only          0
Name: count, dtype: int64
```

[66]:
```python
#Verif des clients n'ayant fait aucun achat de 2021 à 2023. Conseil pour suivi␣
↪clientèle
df_cust_trans_right_only = df_cust_trans[df_cust_trans['_merge'] ==␣
↪'right_only']
df_cust_trans_right_only
```

[66]:
```
       id_prod date session_id client_id  annee  mois  jour jour_lettre  \
18399      NaN  NaT        NaN    c_1223    NaN   NaN   NaN         NaN
167262     NaN  NaT        NaN    c_2706    NaN   NaN   NaN         NaN
191551     NaN  NaT        NaN    c_3017    NaN   NaN   NaN         NaN
225851     NaN  NaT        NaN    c_3443    NaN   NaN   NaN         NaN
240172     NaN  NaT        NaN    c_3526    NaN   NaN   NaN         NaN
261001     NaN  NaT        NaN    c_3789    NaN   NaN   NaN         NaN
282271     NaN  NaT        NaN    c_4086    NaN   NaN   NaN         NaN
305952     NaN  NaT        NaN    c_4358    NaN   NaN   NaN         NaN
309172     NaN  NaT        NaN    c_4406    NaN   NaN   NaN         NaN
312791     NaN  NaT        NaN    c_4447    NaN   NaN   NaN         NaN
380504     NaN  NaT        NaN    c_5223    NaN   NaN   NaN         NaN
381688     NaN  NaT        NaN    c_5245    NaN   NaN   NaN         NaN
434945     NaN  NaT        NaN     c_587    NaN   NaN   NaN         NaN
519107     NaN  NaT        NaN    c_6735    NaN   NaN   NaN         NaN
528931     NaN  NaT        NaN    c_6862    NaN   NaN   NaN         NaN
534744     NaN  NaT        NaN    c_6930    NaN   NaN   NaN         NaN
590311     NaN  NaT        NaN    c_7584    NaN   NaN   NaN         NaN
646880     NaN  NaT        NaN    c_8253    NaN   NaN   NaN         NaN
657710     NaN  NaT        NaN    c_8381    NaN   NaN   NaN         NaN
677536     NaN  NaT        NaN     c_862    NaN   NaN   NaN         NaN
681129     NaN  NaT        NaN      c_90    NaN   NaN   NaN         NaN

       mois_lettre sex  birth  Age      _merge
18399          NaN   m   1963   62  right_only
167262         NaN   f   1967   58  right_only
191551         NaN   f   1992   33  right_only
225851         NaN   m   1959   66  right_only
240172         NaN   m   1956   69  right_only
261001         NaN   f   1997   28  right_only
282271         NaN   f   1992   33  right_only
305952         NaN   m   1999   26  right_only
```

```
309172          NaN   f   1998   27  right_only
312791          NaN   m   1956   69  right_only
380504          NaN   m   2003   22  right_only
381688          NaN   f   2004   21  right_only
434945          NaN   m   1993   32  right_only
519107          NaN   m   2004   21  right_only
528931          NaN   f   2002   23  right_only
534744          NaN   m   2004   21  right_only
590311          NaN   f   1960   65  right_only
646880          NaN   f   2001   24  right_only
657710          NaN   f   1965   60  right_only
677536          NaN   f   1956   69  right_only
681129          NaN   m   2001   24  right_only
```

OK. Nous retrouvons le même nb de lignes dans le df transactions initial et le df fusionné : aucune perte des transactions

Etape 3.2 - Jonction finale df_prod_trans_vf -> customers

[69]:
```
#Rappel dimensions
print("Le tableau customers comporte {} observation(s) ou article(s)".
 ↪format(df_customers.shape[0]))
print("Le tableau initial transactions comporte {} observation(s) ou␣
 ↪article(s)".format(df_transactions.shape[0]))
print("Le tableau fusionné produits/transactions comporte {} observation(s) ou␣
 ↪article(s)".format(df_prod_trans_vf.shape[0]))
```

```
Le tableau customers comporte 8621 observation(s) ou article(s)
Le tableau initial transactions comporte 687534 observation(s) ou article(s)
Le tableau fusionné produits/transactions comporte 687534 observation(s) ou
article(s)
```

[70]:
```
#jointure LEFT pour garder tous les produits valides même s'il n'y a pas de␣
 ↪correspondances clients
df_vf = df_prod_trans_vf.merge(df_customers, on='client_id', how='left',␣
 ↪indicator=True)
```

[71]:
```
#Verifi des lignes avec produits valides (id_prod) mais sans correspondance␣
 ↪clients
df_vf['_merge'].value_counts()
```

[71]:
```
_merge
both          687534
left_only          0
right_only         0
Name: count, dtype: int64
```

[72]:
```
df_vf.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 687534 entries, 0 to 687533
Data columns (total 15 columns):
 #   Column       Non-Null Count   Dtype
---  ------       --------------   -----
 0   id_prod      687534 non-null  object
 1   date         687534 non-null  datetime64[ns]
 2   session_id   687534 non-null  object
 3   client_id    687534 non-null  object
 4   annee        687534 non-null  float64
 5   mois         687534 non-null  float64
 6   jour         687534 non-null  float64
 7   jour_lettre  687534 non-null  object
 8   mois_lettre  687534 non-null  object
 9   price        687534 non-null  float64
 10  categ        687534 non-null  int64
 11  sex          687534 non-null  object
 12  birth        687534 non-null  int64
 13  Age          687534 non-null  int64
 14  _merge       687534 non-null  category
dtypes: category(1), datetime64[ns](1), float64(4), int64(3), object(6)
memory usage: 74.1+ MB
```

[73]:
```
#Suppression colonne _merge
df_vf = df_vf.drop(columns=['_merge'])
```

Etape 4 - Analyses univariées

Etape 4.0 - Rappel structure df

[76]:
```
#Rappel structure df final
df_vf.columns
```

[76]:
```
Index(['id_prod', 'date', 'session_id', 'client_id', 'annee', 'mois', 'jour',
       'jour_lettre', 'mois_lettre', 'price', 'categ', 'sex', 'birth', 'Age'],
      dtype='object')
```

[77]:
```
df_vf.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 687534 entries, 0 to 687533
Data columns (total 14 columns):
 #   Column       Non-Null Count   Dtype
---  ------       --------------   -----
 0   id_prod      687534 non-null  object
 1   date         687534 non-null  datetime64[ns]
 2   session_id   687534 non-null  object
 3   client_id    687534 non-null  object
 4   annee        687534 non-null  float64
```

```
 5   mois         687534 non-null  float64
 6   jour         687534 non-null  float64
 7   jour_lettre  687534 non-null  object
 8   mois_lettre  687534 non-null  object
 9   price        687534 non-null  float64
 10  categ        687534 non-null  int64
 11  sex          687534 non-null  object
 12  birth        687534 non-null  int64
 13  Age          687534 non-null  int64
dtypes: datetime64[ns](1), float64(4), int64(3), object(6)
memory usage: 73.4+ MB
```

[78]:
```
#Aperçu df final
df_vf.head()
```

[78]:
```
  id_prod                      date session_id client_id   annee  mois  jour  \
0     0_0 2021-03-01 13:45:51.575117      s_282    c_5152  2021.0   3.0   1.0
1     0_0 2021-03-02 06:42:55.351333      s_621    c_2917  2021.0   3.0   2.0
2     0_0 2021-03-02 18:49:49.651862      s_852    c_3988  2021.0   3.0   2.0
3     0_0 2021-03-02 21:57:33.862118      s_908    c_1004  2021.0   3.0   2.0
4     0_0 2021-03-03 23:59:48.997483     s_1379     c_278  2021.0   3.0   3.0

  jour_lettre mois_lettre  price  categ sex  birth  Age
0       Lundi        Mars   3.75      0   f   1986   39
1       Mardi        Mars   3.75      0   m   1988   37
2       Mardi        Mars   3.75      0   f   1962   63
3       Mardi        Mars   3.75      0   m   1973   52
4    Mercredi        Mars   3.75      0   f   1987   38
```

Etape 4.1 - CA avec moyenne mobile

CA Mensuel

[81]:
```
# format datetime pour la colonne date (exploitable pour les data en date␣
↪intelligence comme pbi)
df_vf['date'] = pd.to_datetime(df_vf['date'])

# Création d'une colonne 'year_month' pour l'agrégation mensuelle
df_vf['year_month'] = df_vf['date'].dt.to_period('M').astype(str)

# Agrégation du chiffre d'affaires mensuel
ca_mensuel = df_vf.groupby('year_month')['price'].sum().reset_index()
ca_mensuel['price'] = ca_mensuel['price'].round(2)

# Calcul de la moyenne mobile sur 3 mois
ca_mensuel['CA_moyenne_mobile'] = ca_mensuel['price'].rolling(window=3).mean()

ca_mensuel
```

[81]:

| | year_month | price | CA_moyenne_mobile |
|---|---|---|---|
| 0 | 2021-03 | 482440.61 | NaN |
| 1 | 2021-04 | 476109.30 | NaN |
| 2 | 2021-05 | 492943.47 | 483831.126667 |
| 3 | 2021-06 | 484088.56 | 484380.443333 |
| 4 | 2021-07 | 482835.40 | 486622.476667 |
| 5 | 2021-08 | 482284.79 | 483069.583333 |
| 6 | 2021-09 | 507240.68 | 490786.956667 |
| 7 | 2021-10 | 494733.16 | 494752.876667 |
| 8 | 2021-11 | 516167.73 | 506047.190000 |
| 9 | 2021-12 | 525917.28 | 512272.723333 |
| 10 | 2022-01 | 525338.99 | 522474.666667 |
| 11 | 2022-02 | 535571.50 | 528942.590000 |
| 12 | 2022-03 | 515456.53 | 525455.673333 |
| 13 | 2022-04 | 492998.94 | 514675.656667 |
| 14 | 2022-05 | 517132.60 | 508529.356667 |
| 15 | 2022-06 | 496016.12 | 502049.220000 |
| 16 | 2022-07 | 510783.12 | 507977.280000 |
| 17 | 2022-08 | 506467.27 | 504422.170000 |
| 18 | 2022-09 | 494114.53 | 503788.306667 |
| 19 | 2022-10 | 507917.77 | 502833.190000 |
| 20 | 2022-11 | 496664.94 | 499565.746667 |
| 21 | 2022-12 | 510219.50 | 504934.070000 |
| 22 | 2023-01 | 517540.55 | 508141.663333 |
| 23 | 2023-02 | 456679.76 | 494813.270000 |

[82]:

```
# Conversion en datetime si nécessaire
ca_mensuel['year_month'] = pd.to_datetime(ca_mensuel['year_month'])
ca_mensuel['year'] = ca_mensuel['year_month'].dt.year

# Points max et min par année
max_points = ca_mensuel.loc[ca_mensuel.groupby('year')['price'].idxmax()]
min_points = ca_mensuel.loc[ca_mensuel.groupby('year')['price'].idxmin()]

# Dataviz
plt.figure(figsize=(20, 6))
plt.plot(ca_mensuel['year_month'], ca_mensuel['price'], label='CA mensuel',␣
 ↪marker='o')
plt.plot(ca_mensuel['year_month'], ca_mensuel['CA_moyenne_mobile'],␣
 ↪label='Moyenne mobile (3 mois)', linestyle='--', color='orange')

# Marqueurs extrêmes
plt.scatter(max_points['year_month'], max_points['price'], color='lightgreen',␣
 ↪s=40, label='Max annuel', zorder=5)
plt.scatter(min_points['year_month'], min_points['price'], color='red', s=40,␣
 ↪label='Min annuel', zorder=5)
```

```
# Affichage complet des dates sur l'axe X
plt.xticks(ticks=ca_mensuel['year_month'], rotation=45)

# Suppression du titre de l'axe X
plt.xlabel('')

plt.ylabel('Chiffre d\'affaires (€)')
plt.title('Évolution du CA mensuel avec moyenne mobile')
plt.legend()

ax = plt.gca()
for spine in ax.spines.values():
    spine.set_visible(False)

plt.tight_layout()
plt.grid(True, linestyle='--', linewidth=0.4, alpha=1)
plt.savefig('ca_moyenne_mobile.png')
plt.show()
```

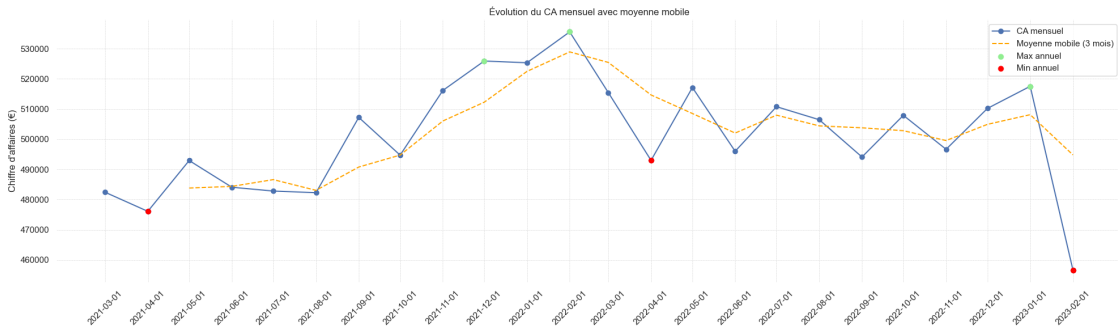


CA Quotidien

[84]:
```
# Création d'une colonne 'year_day' pour l'agrégation quotidienne
df_vf['year_day'] = df_vf['date'].dt.to_period('D').astype(str)

# Agrégation du chiffre d'affaires quotidien
ca_quotidien = df_vf.groupby('year_day')['price'].sum().reset_index()
ca_quotidien['price'] = ca_quotidien['price'].round(2)

# Calcul de la moyenne mobile sur 3 jours
ca_quotidien['CA_moyenne_mobile'] = ca_quotidien['price'].rolling(window=3).
 ↪mean()
ca_quotidien
```

[84]:

| | year_day | price | CA_moyenne_mobile |
|---|---|---|---|
| 0 | 2021-03-01 | 16565.22 | NaN |

```
1    2021-03-02  15486.45                NaN
2    2021-03-03  15198.69       15750.120000
3    2021-03-04  15196.07       15293.736667
4    2021-03-05  17471.37       15955.376667
..          …       …                 …
725  2023-02-24  15207.89       15418.653333
726  2023-02-25  15761.25       15403.726667
727  2023-02-26  16304.72       15757.953333
728  2023-02-27  19170.81       17078.926667
729  2023-02-28  18105.15       17860.226667

[730 rows x 3 columns]
```

[85]:
```
# Conversion en datetime si nécessaire
ca_quotidien['year_day'] = pd.to_datetime(ca_quotidien['year_day'])
ca_quotidien['year'] = ca_quotidien['year_day'].dt.year

# Points max et min par année
max_points = ca_quotidien.loc[ca_quotidien.groupby('year')['price'].idxmax()]
min_points = ca_quotidien.loc[ca_quotidien.groupby('year')['price'].idxmin()]

# Dataviz
plt.figure(figsize=(20, 6))
plt.plot(ca_quotidien['year_day'], ca_quotidien['price'], label='CA quotidien',␣
 ↪marker='o', markersize=3)
plt.plot(ca_quotidien['year_day'], ca_quotidien['CA_moyenne_mobile'],␣
 ↪label='Moyenne mobile (3 jours)', linestyle='--', color='orange')

# Marqueurs extrêmes
plt.scatter(max_points['year_day'], max_points['price'], color='lightgreen',␣
 ↪s=40, label='Max annuel', zorder=5)
plt.scatter(min_points['year_day'], min_points['price'], color='red', s=40,␣
 ↪label='Min annuel', zorder=5)

# Affichage complet des dates sur l'axe X (optionnel : espacer les ticks)
plt.xticks(rotation=45)

# Suppression du titre de l'axe X
plt.xlabel('')

plt.ylabel('Chiffre d\'affaires (€)')
plt.title('Évolution du CA quotidien avec moyenne mobile')
plt.legend()

# Esthétique
ax = plt.gca()
for spine in ax.spines.values():
```

```
    spine.set_visible(False)

plt.tight_layout()
plt.grid(True, linestyle='--', linewidth=0.4, alpha=1)
plt.savefig('ca_quotidien_moyenne_mobile.png')
plt.show()
```

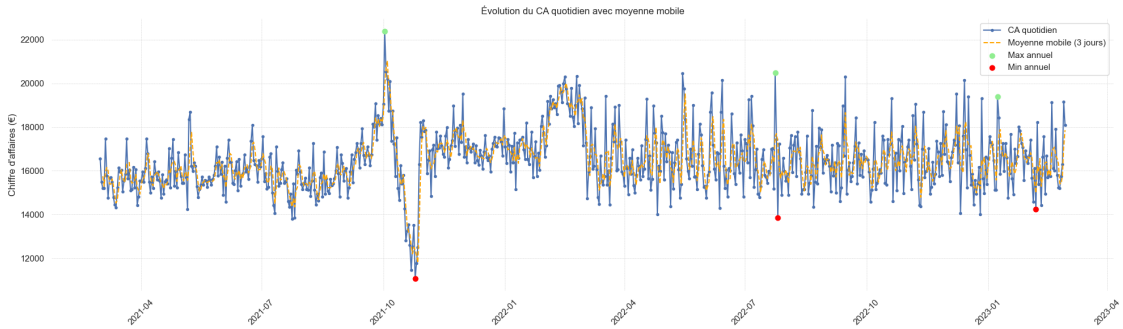


Etape 4.2 - CA mensuel par catégorie

[87]:
```
# Agrégation du CA par mois et par catégorie
ca_par_categ = df_vf.groupby(['year_month', 'categ'])['price'].sum().
 ↪reset_index()
ca_par_categ['price'] = ca_par_categ['price'].round(2)
ca_par_categ
```

[87]:

| | year_month | categ | price |
|---|---|---|---|
| 0 | 2021-03 | 0 | 193629.17 |
| 1 | 2021-03 | 1 | 186974.17 |
| 2 | 2021-03 | 2 | 101837.27 |
| 3 | 2021-04 | 0 | 205222.46 |
| 4 | 2021-04 | 1 | 156138.35 |
| .. | … | … | … |
| 67 | 2023-01 | 1 | 210104.41 |
| 68 | 2023-01 | 2 | 126153.08 |
| 69 | 2023-02 | 0 | 162457.00 |
| 70 | 2023-02 | 1 | 180347.24 |
| 71 | 2023-02 | 2 | 113875.52 |

[72 rows x 3 columns]

[88]:
```
# Pivot pour visualisation
pivot_categ = ca_par_categ.pivot(index='year_month', columns='categ',␣
 ↪values='price').fillna(0)
pivot_categ
```

[88]:

| categ | 0 | 1 | 2 |
|---|---|---|---|
| year_month | | | |
| 2021-03 | 193629.17 | 186974.17 | 101837.27 |
| 2021-04 | 205222.46 | 156138.35 | 114748.49 |
| 2021-05 | 196186.72 | 165893.40 | 130863.35 |
| 2021-06 | 167943.15 | 189162.04 | 126983.37 |
| 2021-07 | 144750.79 | 188523.27 | 149561.34 |
| 2021-08 | 167737.62 | 162991.38 | 151555.79 |
| 2021-09 | 246353.91 | 190613.78 | 70272.99 |
| 2021-10 | 199250.83 | 207696.74 | 87785.59 |
| 2021-11 | 155909.56 | 252910.39 | 107347.78 |
| 2021-12 | 206036.24 | 251026.75 | 68854.29 |
| 2022-01 | 164210.51 | 256267.92 | 104860.56 |
| 2022-02 | 183197.33 | 213120.64 | 139253.53 |
| 2022-03 | 191464.94 | 206485.26 | 117506.33 |
| 2022-04 | 174997.26 | 195263.97 | 122737.71 |
| 2022-05 | 194872.34 | 205532.63 | 116727.63 |
| 2022-06 | 183934.86 | 201912.06 | 110169.20 |
| 2022-07 | 187097.00 | 193969.72 | 129716.40 |
| 2022-08 | 177372.76 | 211360.09 | 117734.42 |
| 2022-09 | 183329.24 | 195379.54 | 115405.75 |
| 2022-10 | 187429.17 | 199609.66 | 120878.94 |
| 2022-11 | 184594.35 | 200427.99 | 111642.60 |
| 2022-12 | 180470.70 | 205945.71 | 123803.09 |
| 2023-01 | 181283.06 | 210104.41 | 126153.08 |
| 2023-02 | 162457.00 | 180347.24 | 113875.52 |

[89]:

```
#Dataviz
# Liste complète des mois pour les ticks
mois = pivot_categ.index.tolist()

# Affichage du graphique
plt.figure(figsize=(14, 7))
pivot_categ.plot(kind='line', marker='o', figsize=(14, 7))
plt.title("Évolution du CA mensuel par catégorie")
plt.xlabel("Mois")
plt.ylabel("Chiffre d'affaires (€)")
plt.xticks(ticks=range(len(mois)), labels=mois, rotation=45)
plt.grid(True, linestyle='--', linewidth=0.4, alpha=1)
plt.legend(title='Catégorie')

ax = plt.gca()
for spine in ax.spines.values():
    spine.set_visible(False)

plt.tight_layout()
plt.savefig('ca_par_categorie.png')
```

```
plt.show()
```

```
<Figure size 1400x700 with 0 Axes>
```

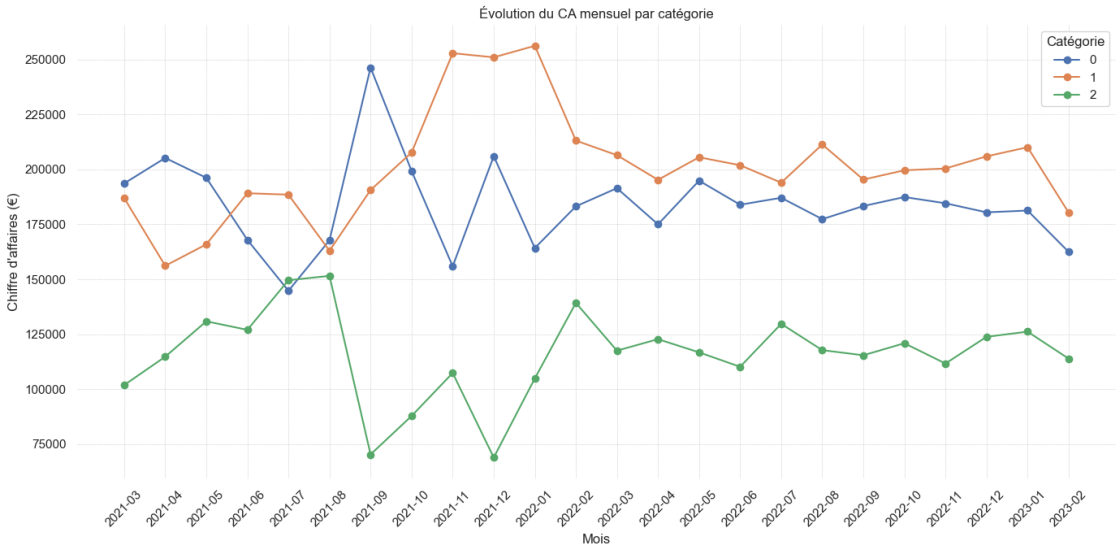


Etape 4.3 - Nombre de clients par mois

[91]:
```
# Agrégation du nb de clients par mois
clients_uniques = df_vf.groupby('year_month')['client_id'].nunique()

# Remplacement valeur f/m par Femme/Homme
df_vf['sex'] = df_vf['sex'].replace({'f': 'Femme', 'm': 'Homme'})

# Agrégation par genre
df_id_unique = df_vf.drop_duplicates(subset=['year_month', 'client_id'])
clients_par_sexe = df_id_unique.groupby(['year_month', 'sex'])['client_id'].
 ↪nunique().unstack(fill_value=0)

# Calcul pourcentage f/m
clients_par_sexe['Total'] = clients_par_sexe.sum(axis=1)
clients_pct = (clients_par_sexe.div(clients_par_sexe['Total'], axis=0) * 100).
 ↪round(1)
```

[92]:
```
#Dataviz répartition f/m + nb de clients par mois

fig, ax = plt.subplots(figsize=(12, 6))
bottom = None
colors = {'Femme': '#ff69b4', 'Homme': '#1f77b4'}

for sexe in ['Femme', 'Homme']:  # ordre d'empilement
```

```
    ax.bar(clients_par_sexe.index, clients_par_sexe[sexe], bottom=bottom,␣
↪label=sexe, color=colors[sexe])

    # Ajout des pourcentages dans la barre
    for i, val in enumerate(clients_par_sexe[sexe]):
        pct = clients_pct[sexe].iloc[i]
        y_pos = val / 2 if bottom is None else bottom.iloc[i] + val / 2
        ax.text(clients_par_sexe.index[i], y_pos, f'{pct:.1f}%', ha='center',␣
↪va='center', color='white', fontsize=7.5, fontweight='bold')

    bottom = clients_par_sexe[sexe] if bottom is None else bottom +␣
↪clients_par_sexe[sexe]

# Ajout du total au-dessus de chaque barre
for i, total in enumerate(clients_par_sexe['Total']):
    ax.text(clients_par_sexe.index[i], total + 5, f'{total}', ha='center',␣
↪va='bottom', fontsize=10, fontweight='bold')

# Mise en forme
ax.set_title('Répartition des clients uniques par mois et par sexe',␣
↪fontsize=14)
ax.set_ylabel('Nombre de clients uniques')
ax.set_xlabel('')
ax.legend(title='Genre')
plt.xticks(rotation=45)
plt.grid(True, linestyle='--', linewidth=0.2, alpha=1)
plt.tight_layout()
plt.show()
```

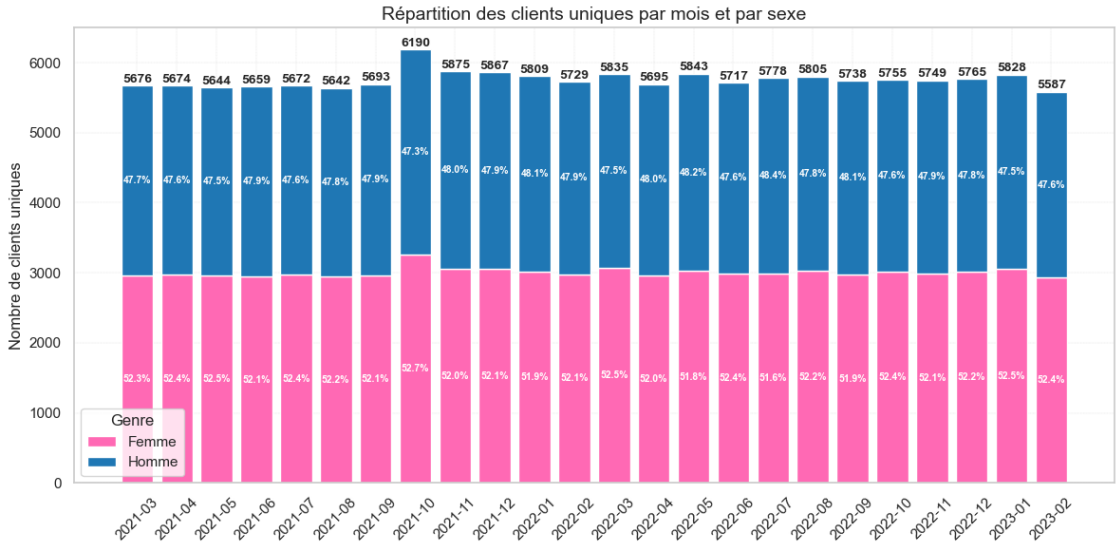

[93]:
```
#Dataviz nb de clients par mois
plt.figure(figsize=(12, 6))
plt.plot(clients_uniques.index, clients_uniques.values, marker='o',␣
↪linestyle='-', color='#1f77b4')

# Ajout des annotations
for i, value in enumerate(clients_uniques.values):
    plt.text(clients_uniques.index[i], value + 5, str(value), ha='center',␣
↪va='bottom', fontsize=8, color='darkgray')

# Mise en forme
plt.title('Nombre de clients par mois', fontsize=14)
plt.xlabel('')
plt.ylabel('')
plt.xticks(rotation=45)
plt.grid(True, linestyle='--', linewidth=0.2, alpha=1)

ax = plt.gca()
for spine in ax.spines.values():
    spine.set_visible(False)

plt.tight_layout()
plt.show()
```

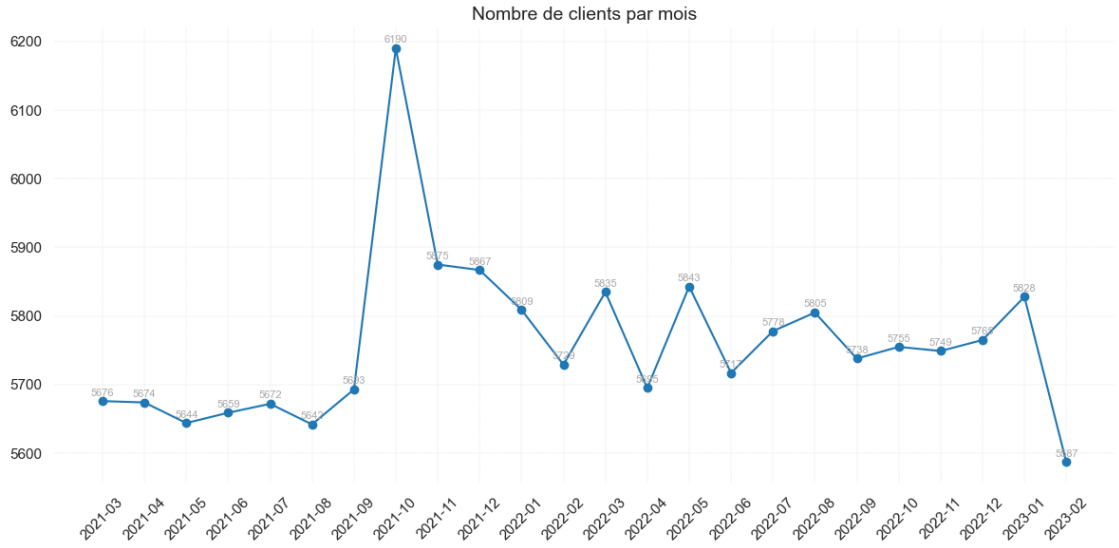


Etape 4.4 - Nombre de transactions par mois

[95]:
```
# Compter le nombre de transactions (=panier -> session_id) par mois
paniers_par_mois = df_vf.groupby('year_month')['session_id'].nunique()
```

[96]:
```
#Dataviz

plt.figure(figsize=(12, 6))
plt.plot(paniers_par_mois.index, paniers_par_mois.values, marker='o',␣
↪linestyle='-', color='#1f77b4')

# Ajout des annotations au-dessus des marqueurs
for i, value in enumerate(paniers_par_mois.values):
    plt.text(paniers_par_mois.index[i], value + 5, str(value), ha='center',␣
↪va='bottom', fontsize=8, color='darkgray')

# Mise en forme
plt.title('Nombre de transactions par mois', fontsize=14)
plt.ylabel('')
plt.xlabel('')
plt.xticks(rotation=45)
plt.grid(True, linestyle='--', linewidth=0.3, alpha=1)

ax = plt.gca()
for spine in ax.spines.values():
    spine.set_visible(False)


plt.tight_layout()
plt.show()
```

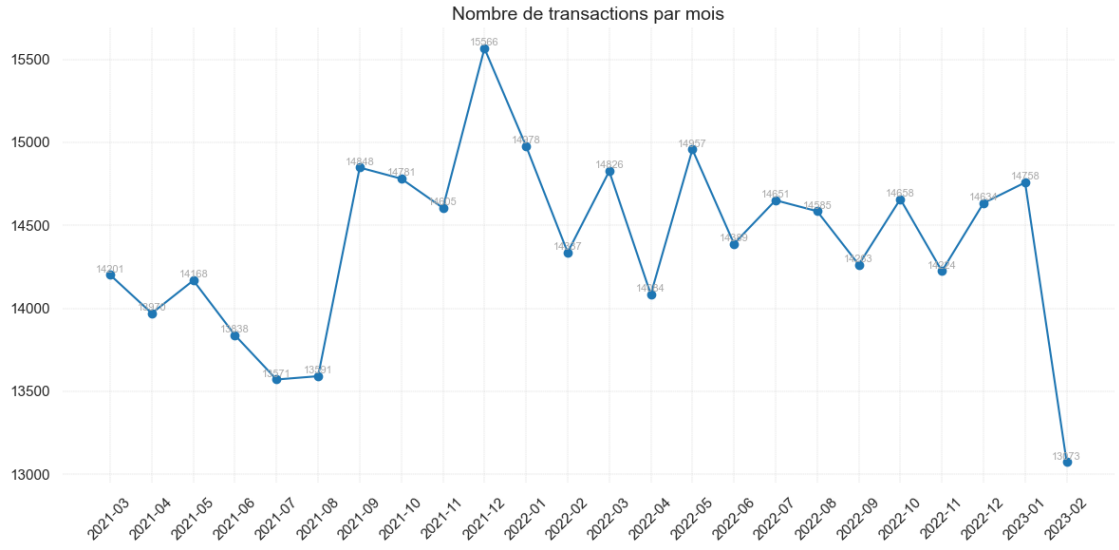


Etape 4.5 - Nombre de produits vendus par mois

[98]:
```
# Compter le nombre de produits vendus par mois
prod_par_mois = df_vf.groupby('year_month')['id_prod'].count()
```

[99]:
```
#Dataviz

plt.figure(figsize=(12, 6))
plt.plot(prod_par_mois.index, prod_par_mois.values, marker='o', linestyle='-',␣
 ↪color='#1f77b4')

# Ajout des annotations au-dessus des marqueurs
for i, value in enumerate(prod_par_mois.values):
    plt.text(prod_par_mois.index[i], value + 5, str(value), ha='center',␣
 ↪va='bottom', fontsize=8, color='darkgray')

# Mise en forme
plt.title('Nombre de produits vendus par mois', fontsize=14)
plt.ylabel('')
plt.xlabel('')
plt.xticks(rotation=45)
plt.grid(True, linestyle='--', linewidth=0.3, alpha=1)

ax = plt.gca()
for spine in ax.spines.values():
    spine.set_visible(False)

plt.tight_layout()
plt.show()
```

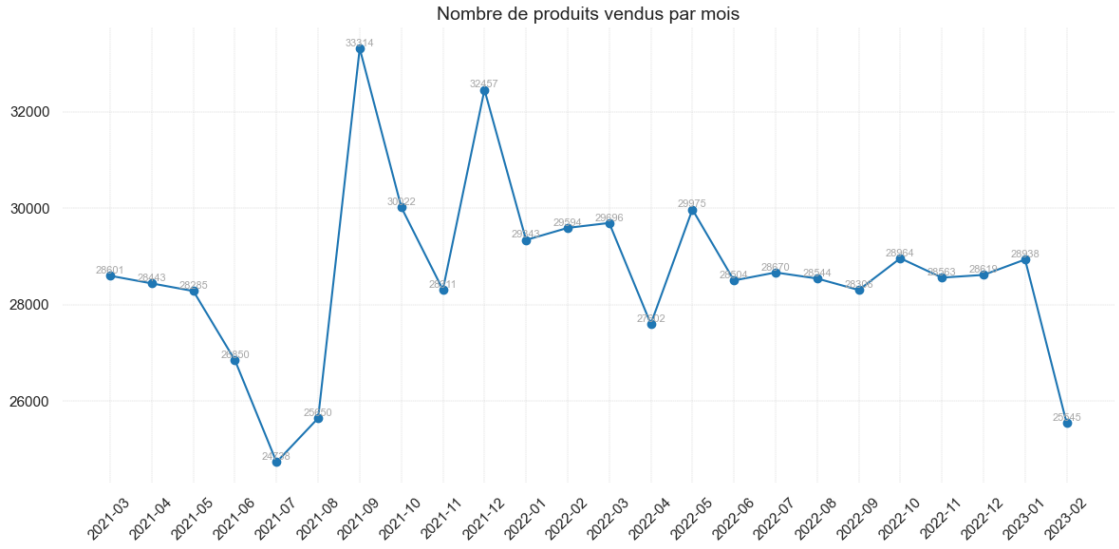


Etape 4.6 - Les tops 10

Des références par vente

[102]:
```
# Toutes catégories confondues
top_10_global = df_vf['id_prod'].value_counts().head(10)
print("Top 10 produits toutes périodes confondues :")
print(top_10_global)
```

```
Top 10 produits toutes périodes confondues :
id_prod
1_369    2340
1_417    2269
1_414    2246
1_498    2202
1_425    2163
1_403    2040
1_413    2036
1_412    2014
1_406    2003
1_407    2001
Name: count, dtype: int64
```

[103]:
```
#dataviz
# Total des ventes (toutes lignes de df_vf)
total_ventes = len(df_vf)

# Transformation en DataFrame
df_top10 = top_10_global.reset_index()
df_top10.columns = ['id_prod', 'nb_ventes']

# Calcul du pourcentage
df_top10['pourcentage'] = df_top10['nb_ventes'] / total_ventes * 100

# Création des labels avec 2 décimales
df_top10['label'] = df_top10.apply(
    lambda row: f"{row['nb_ventes']} ({row['pourcentage']:.2f}%)", axis=1
)

# Palette de verts du plus foncé au plus clair
palette_verts = [mcolors.to_hex(c) for c in plt.cm.Greens(np.linspace(0.7, 0.1,␣
 ↪10))]

# Création du graphique
fig, ax = plt.subplots(figsize=(10, 5))
bars = ax.barh(df_top10['id_prod'], df_top10['nb_ventes'], color=palette_verts)

# Suppression du cadre (spines)
for spine in ax.spines.values():
    spine.set_visible(False)
```

```
# Ajout des labels à droite des barres
for i, bar in enumerate(bars):
    ax.text(bar.get_width() + max(df_top10['nb_ventes']) * 0.01,
            bar.get_y() + bar.get_height()/2,
            df_top10['label'].iloc[i],
            va='center', fontsize=10)

# Inversion de l'ordre pour que le produit le plus vendu soit en haut
ax.invert_yaxis()

# Titres et mise en forme
ax.set_xlabel("Nombre de ventes")
ax.set_ylabel("Produits")
ax.set_title("Top 10 des produits les plus vendus")
plt.grid(True, linestyle='--', linewidth=0.3, alpha=1)
plt.tight_layout()
plt.show()
```

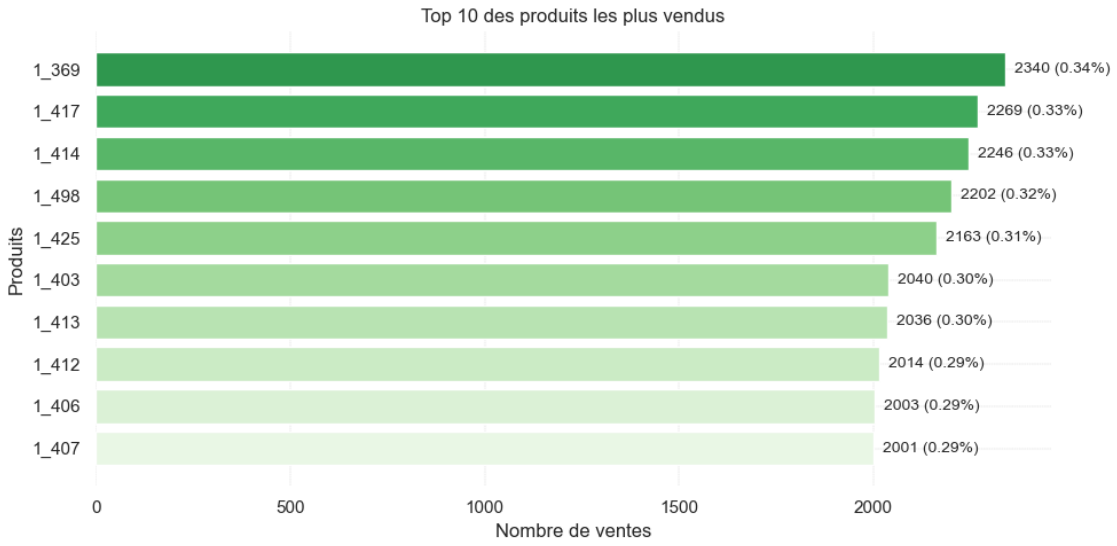


Des références par CA

[105]:
```
#dataviz
# Top 10 des produits par chiffre d'affaires
top_10_ca = df_vf.groupby('id_prod')['price'].sum().
 ↪sort_values(ascending=False).head(10)

# Chiffre d'affaires total
total_ca = df_vf['price'].sum()
```

```python
# Transformation en DataFrame
df_top10_ca = top_10_ca.reset_index()
df_top10_ca.columns = ['id_prod', 'chiffre_affaires']

# Calcul du pourcentage
df_top10_ca['pourcentage'] = df_top10_ca['chiffre_affaires'] / total_ca * 100

# Création des labels avec 2 décimales
df_top10_ca['label'] = df_top10_ca.apply(
    lambda row: f"{row['chiffre_affaires']:.0f} € ({row['pourcentage']:.2f}%)",␣
 ↪axis=1
)

# Palette de verts du plus foncé au plus clair
palette_verts = [mcolors.to_hex(c) for c in plt.cm.Greens(np.linspace(0.7, 0.1,␣
 ↪10))]

# Création du graphique
fig, ax = plt.subplots(figsize=(10, 5))
bars = ax.barh(df_top10_ca['id_prod'], df_top10_ca['chiffre_affaires'],␣
 ↪color=palette_verts)

# Suppression du cadre (spines)
for spine in ax.spines.values():
    spine.set_visible(False)

# Ajout des labels à droite des barres
for i, bar in enumerate(bars):
    ax.text(bar.get_width() + max(df_top10_ca['chiffre_affaires']) * 0.01,
            bar.get_y() + bar.get_height()/2,
            df_top10_ca['label'].iloc[i],
            va='center', fontsize=10)

# Inversion de l'ordre pour que le produit le plus rentable soit en haut
ax.invert_yaxis()

# Titres et mise en forme
ax.set_xlabel("Chiffre d'affaires (€)")
ax.set_title("Top 10 des produits par chiffre d'affaires")
plt.grid(True, linestyle='--', linewidth=0.3, alpha=1)
plt.tight_layout()
plt.show()
```

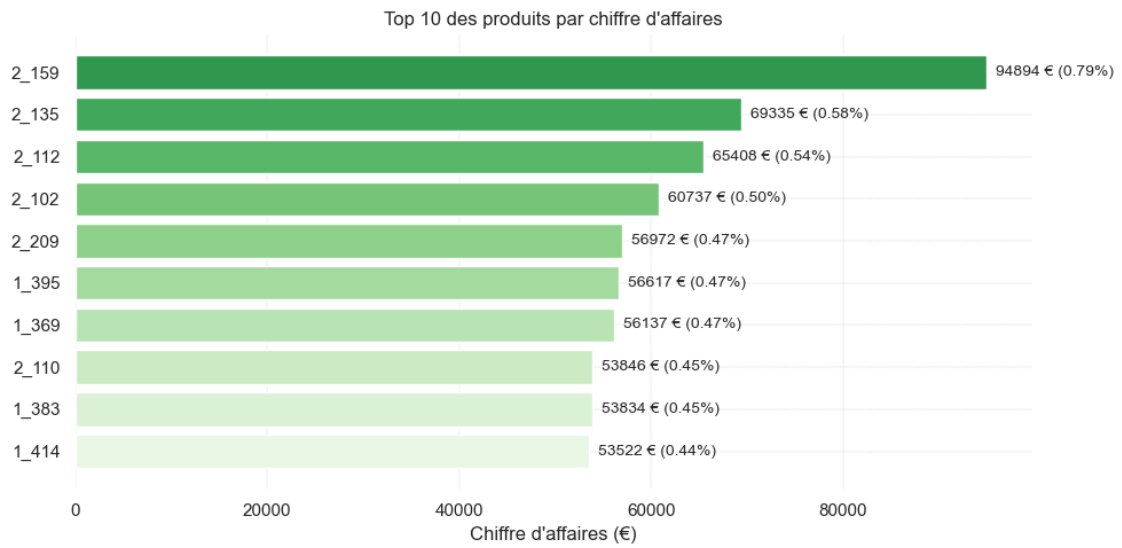


Par catégorie

Catégorie 0

[108]:
```
# Prépa df filtré pour la catégorie 0
df_categ_0 = df_vf[df_vf['categ'] == 0]
```

[109]:
```
# PAR NB DE REFERENCES VENDUES

# Calcul du top 10 des produits vendus dans cette catégorie
top_10_categ_0 = df_categ_0['id_prod'].value_counts().head(10)

# Total des ventes dans la catégorie 0
total_ventes_categ_0 = len(df_categ_0)

# Transformation en DataFrame
df_top10 = top_10_categ_0.reset_index()
df_top10.columns = ['id_prod', 'nb_ventes']

# Calcul du pourcentage
df_top10['pourcentage'] = df_top10['nb_ventes'] / total_ventes_categ_0 * 100

# Création des labels avec 2 décimales
df_top10['label'] = df_top10.apply(
    lambda row: f"{row['nb_ventes']} ({row['pourcentage']:.2f}%)", axis=1
)

# Palette de verts du plus foncé au plus clair
```

```python
palette_verts = [mcolors.to_hex(c) for c in plt.cm.Blues(np.linspace(0.7, 0.1,␣
↪10))]

# Création du graphique
fig, ax = plt.subplots(figsize=(7, 6))
bars = ax.barh(df_top10['id_prod'], df_top10['nb_ventes'], color=palette_verts)

# Suppression du cadre (spines)
for spine in ax.spines.values():
    spine.set_visible(False)

# Ajout des labels à droite des barres
for i, bar in enumerate(bars):
    ax.text(bar.get_width() + max(df_top10['nb_ventes']) * 0.01,
            bar.get_y() + bar.get_height()/2,
            df_top10['label'].iloc[i],
            va='center', fontsize=10)

# Inversion de l'ordre pour que le produit le plus vendu soit en haut
ax.invert_yaxis()

# Titres et mise en forme
ax.set_xlabel("Nombre de ventes")
ax.set_title("Top 10 des produits les plus vendus - Catégorie 0")
plt.grid(True, linestyle='--', linewidth=0.3, alpha=1)
plt.tight_layout()
plt.show()
```

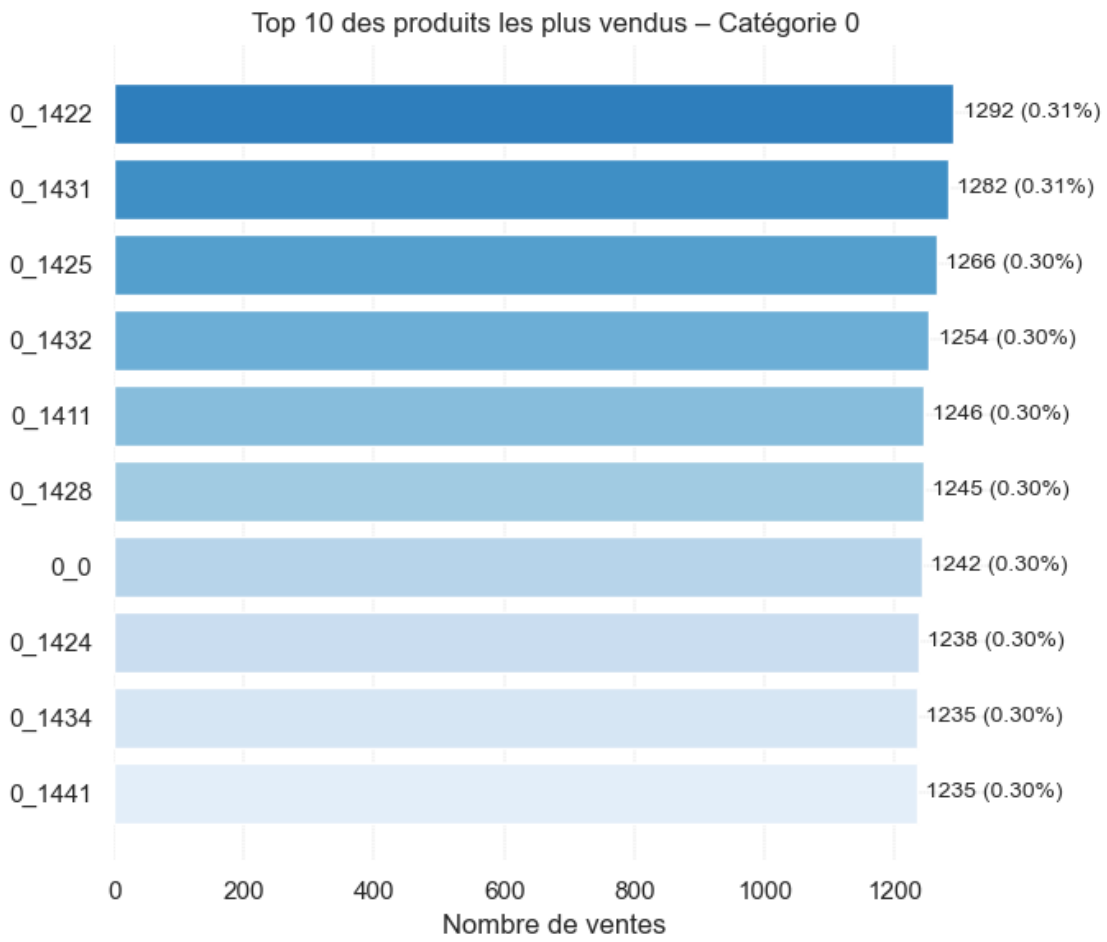


[110]:
```
# PAR CA

# Calcul du top 10 des produits par chiffre d'affaires dans cette catégorie
top_10_ca_categ_0 = df_categ_0.groupby('id_prod')['price'].sum().
 ↪sort_values(ascending=False).head(10)

# Total du CA dans la catégorie 0
total_ca_categ_0 = df_categ_0['price'].sum()

# Transformation en DataFrame
df_top10_0 = top_10_ca_categ_0.reset_index()
df_top10_0.columns = ['id_prod', 'chiffre_affaires']

# Calcul du pourcentage
df_top10_0['pourcentage'] = df_top10_0['chiffre_affaires'] / total_ca_categ_0 *␣
 ↪100
```

```python
# Création des labels avec 2 décimales
df_top10_0['label'] = df_top10_0.apply(
    lambda row: f"{row['chiffre_affaires']:.2f}€ ({row['pourcentage']:.2f}%)",␣
 ↪axis=1
)

# Palette de verts du plus foncé au plus clair
palette_verts = [mcolors.to_hex(c) for c in plt.cm.Blues(np.linspace(0.7, 0.1,␣
 ↪10))]

# Création du graphique
fig, ax = plt.subplots(figsize=(7, 6))
bars = ax.barh(df_top10_0['id_prod'], df_top10_0['chiffre_affaires'],␣
 ↪color=palette_verts)

# Suppression du cadre (spines)
for spine in ax.spines.values():
    spine.set_visible(False)

# Ajout des labels à droite des barres
for i, bar in enumerate(bars):
    ax.text(bar.get_width() + max(df_top10_0['chiffre_affaires']) * 0.01,
            bar.get_y() + bar.get_height()/2,
            df_top10_0['label'].iloc[i],
            va='center', fontsize=10)

# Inversion de l'ordre pour que le produit le plus vendu soit en haut
ax.invert_yaxis()

# Titres et mise en forme
ax.set_xlabel("Chiffre d'affaires (€)")
ax.set_title("Top 10 des produits par CA - Catégorie 0")
plt.grid(True, linestyle='--', linewidth=0.3, alpha=1)
plt.tight_layout()
plt.show()
```

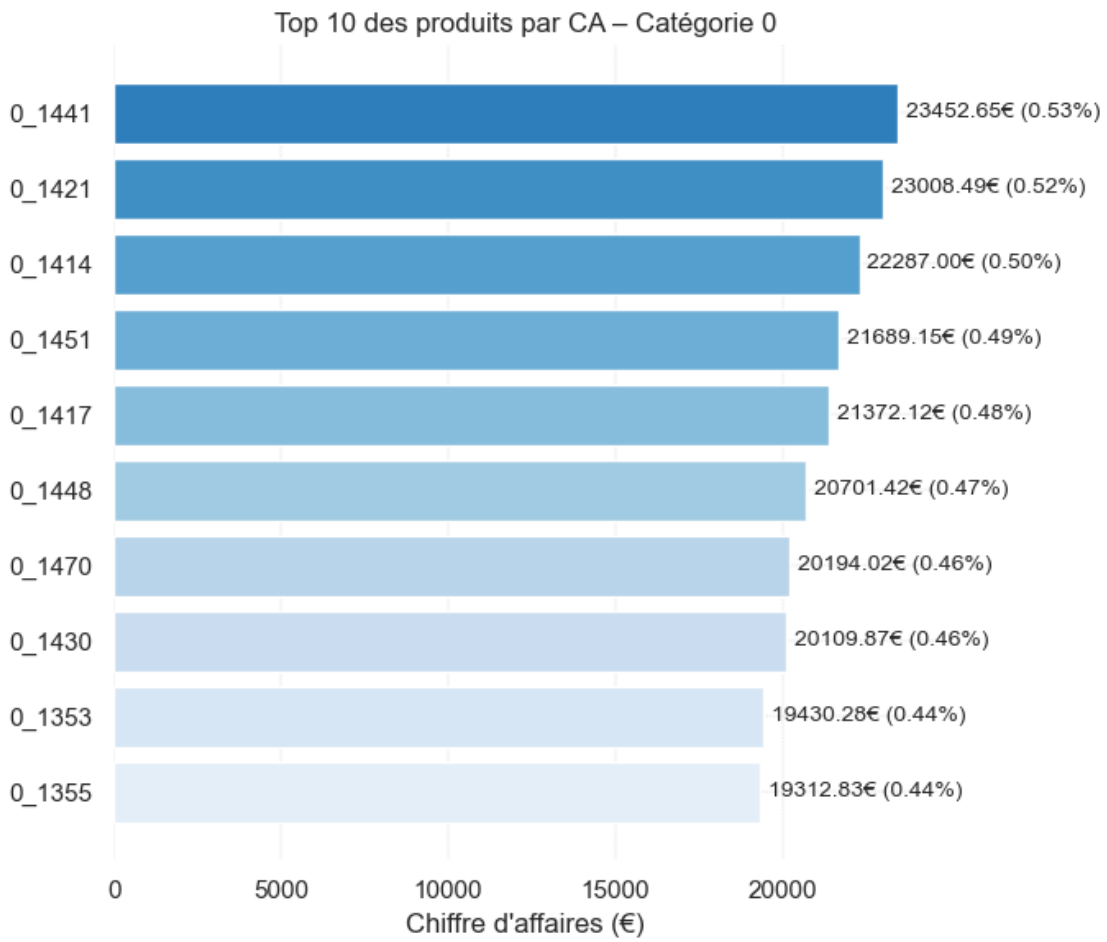


Catégorie 1

[112]:
```
# Prépa df filtré pour la catégorie 1
df_categ_1 = df_vf[df_vf['categ'] == 1]
```

[113]:
```
# PAR NB DE REFERENCES VENDUES

# Calcul du top 10 des produits vendus dans cette catégorie
top_10_categ_1 = df_categ_1['id_prod'].value_counts().head(10)

# Total des ventes dans la catégorie 1
total_ventes_categ_1 = len(df_categ_1)

# Transformation en DataFrame
df_top10_1 = top_10_categ_1.reset_index()
df_top10_1.columns = ['id_prod', 'nb_ventes']

# Calcul du pourcentage
```

```python
df_top10_1['pourcentage'] = df_top10_1['nb_ventes'] / total_ventes_categ_1 * 100

# Création des labels avec 2 décimales
df_top10_1['label'] = df_top10_1.apply(
    lambda row: f"{row['nb_ventes']} ({row['pourcentage']:.2f}%)", axis=1
)

# Palette de verts du plus foncé au plus clair
palette_verts = [mcolors.to_hex(c) for c in plt.cm.Oranges(np.linspace(0.7, 0.
 ↪1, 10))]

# Création du graphique
fig, ax = plt.subplots(figsize=(7, 6))
bars = ax.barh(df_top10_1['id_prod'], df_top10_1['nb_ventes'],␣
 ↪color=palette_verts)

# Suppression du cadre (spines)
for spine in ax.spines.values():
    spine.set_visible(False)

# Ajout des labels à droite des barres
for i, bar in enumerate(bars):
    ax.text(bar.get_width() + max(df_top10_1['nb_ventes']) * 0.01,
            bar.get_y() + bar.get_height()/2,
            df_top10_1['label'].iloc[i],
            va='center', fontsize=10)

# Inversion de l'ordre pour que le produit le plus vendu soit en haut
ax.invert_yaxis()

# Titres et mise en forme
ax.set_xlabel("Nombre de ventes")
ax.set_title("Top 10 des produits les plus vendus - Catégorie 1")
plt.grid(True, linestyle='--', linewidth=0.3, alpha=1)
plt.tight_layout()
plt.show()
```

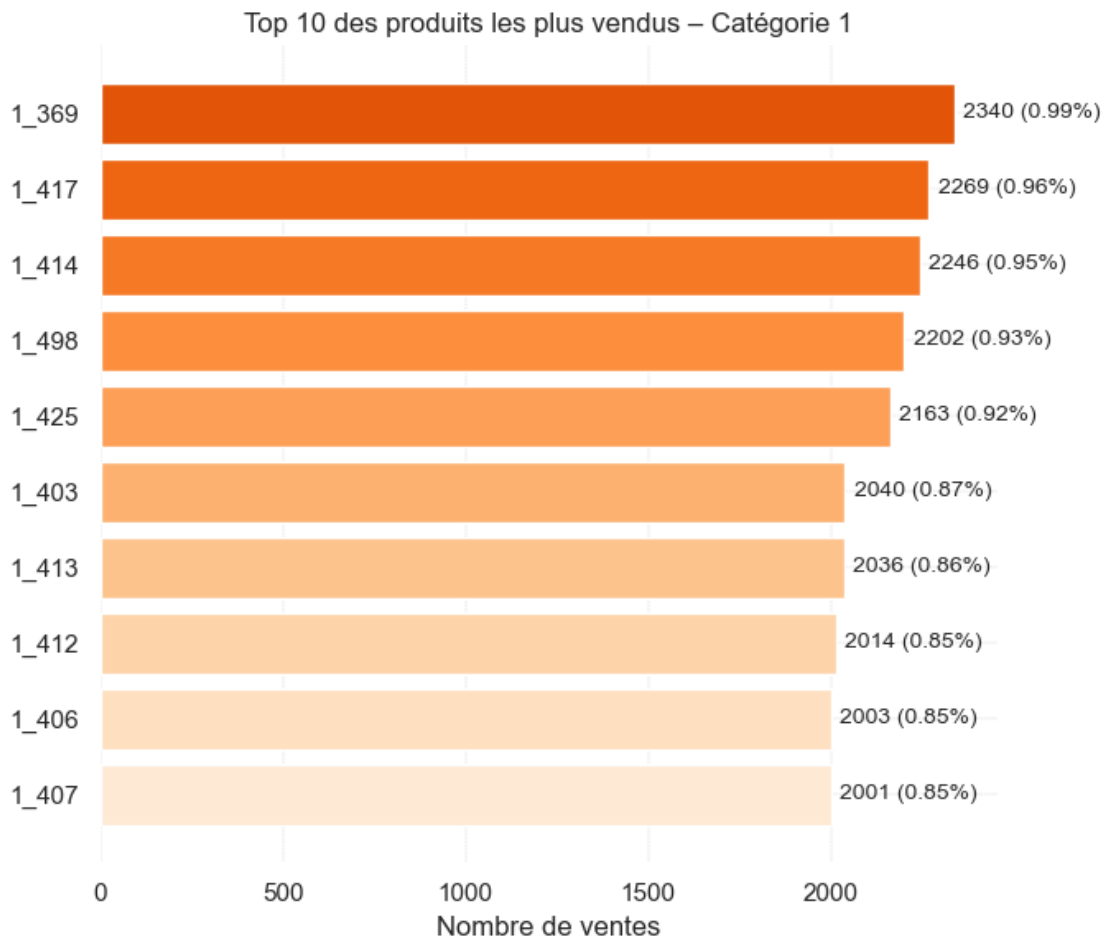


[114]:
```
# PAR CA

# Calcul du top 10 des produits par chiffre d'affaires dans cette catégorie
top_10_ca_categ_1 = df_categ_1.groupby('id_prod')['price'].sum().
 ↪sort_values(ascending=False).head(10)

# Total du CA dans la catégorie 1
total_ca_categ_1 = df_categ_1['price'].sum()

# Transformation en DataFrame
df_top10_2 = top_10_ca_categ_1.reset_index()
df_top10_2.columns = ['id_prod', 'chiffre_affaires']

# Calcul du pourcentage
df_top10_2['pourcentage'] = df_top10_2['chiffre_affaires'] / total_ca_categ_1 *␣
 ↪100
```

```python
# Création des labels avec 2 décimales
df_top10_2['label'] = df_top10_2.apply(
    lambda row: f"{row['chiffre_affaires']:.2f}€ ({row['pourcentage']:.2f}%)",␣
 ↪axis=1
)

# Palette de verts du plus foncé au plus clair
palette_verts = [mcolors.to_hex(c) for c in plt.cm.Oranges(np.linspace(0.7, 0.
 ↪1, 10))]

# Création du graphique
fig, ax = plt.subplots(figsize=(7, 6))
bars = ax.barh(df_top10_2['id_prod'], df_top10_2['chiffre_affaires'],␣
 ↪color=palette_verts)

# Suppression du cadre (spines)
for spine in ax.spines.values():
    spine.set_visible(False)

# Ajout des labels à droite des barres
for i, bar in enumerate(bars):
    ax.text(bar.get_width() + max(df_top10_2['chiffre_affaires']) * 0.01,
            bar.get_y() + bar.get_height()/2,
            df_top10_2['label'].iloc[i],
            va='center', fontsize=10)

# Inversion de l'ordre pour que le produit le plus vendu soit en haut
ax.invert_yaxis()

# Titres et mise en forme
ax.set_xlabel("Chiffre d'affaires (€)")
ax.set_title("Top 10 des produits par CA - Catégorie 1")
plt.grid(True, linestyle='--', linewidth=0.3, alpha=1)
plt.tight_layout()
plt.show()
```

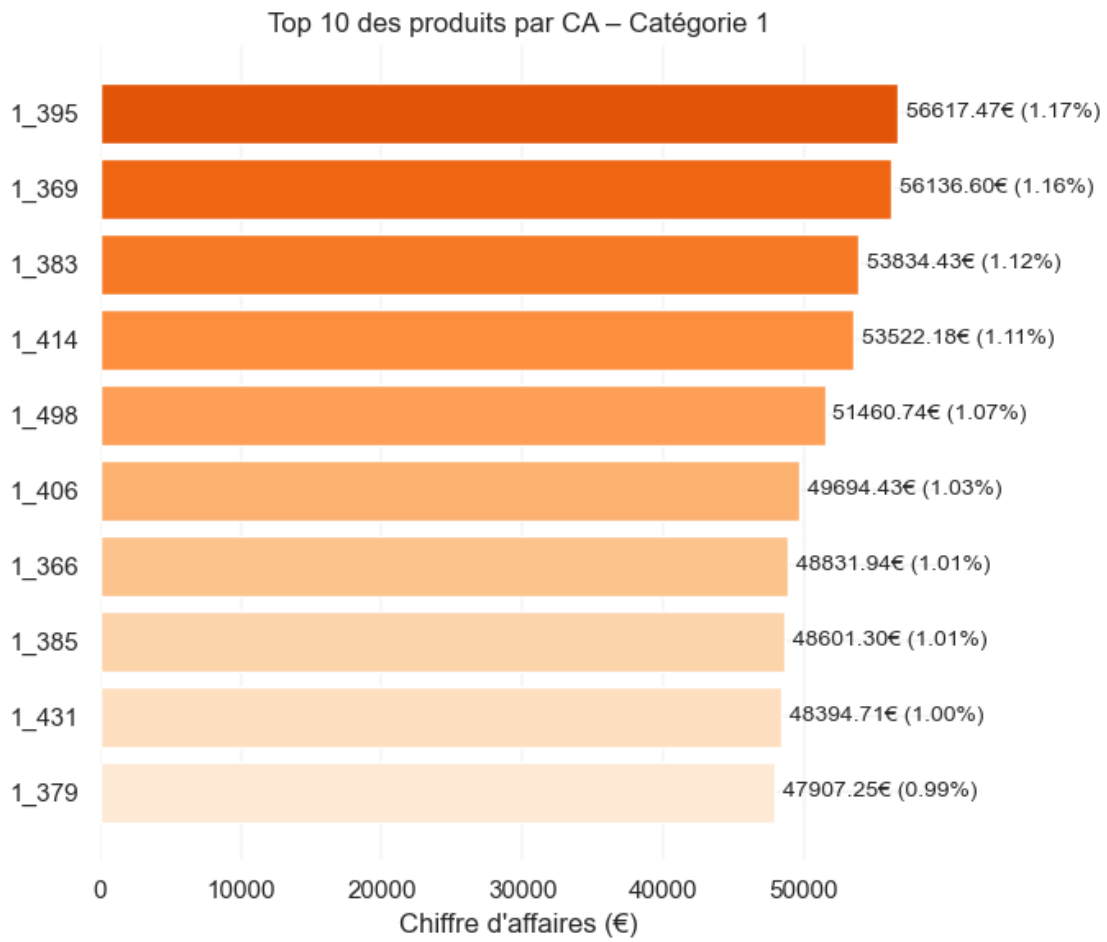


[115]:
```
# Prépa df filtré pour la catégorie 2
df_categ_2 = df_vf[df_vf['categ'] == 2]
```

[116]:
```
# PAR NB DE REFERENCES VENDUES

# Calcul du top 10 des produits vendus dans cette catégorie
top_10_categ_2 = df_categ_2['id_prod'].value_counts().head(10)

# Total des ventes dans la catégorie 2
total_ventes_categ_2 = len(df_categ_2)

# Transformation en DataFrame
df_top10_3 = top_10_categ_2.reset_index()
df_top10_3.columns = ['id_prod', 'nb_ventes']

# Calcul du pourcentage
df_top10_3['pourcentage'] = df_top10_3['nb_ventes'] / total_ventes_categ_2 * 100
```

```python
# Création des labels avec 2 décimales
df_top10_3['label'] = df_top10_3.apply(
    lambda row: f"{row['nb_ventes']} ({row['pourcentage']:.2f}%)", axis=1
)

# Palette de verts du plus foncé au plus clair
palette_verts = [mcolors.to_hex(c) for c in plt.cm.Purples(np.linspace(0.7, 0.
 ↪1, 10))]

# Création du graphique
fig, ax = plt.subplots(figsize=(7, 6))
bars = ax.barh(df_top10_3['id_prod'], df_top10_3['nb_ventes'],␣
 ↪color=palette_verts)

# Suppression du cadre (spines)
for spine in ax.spines.values():
    spine.set_visible(False)

# Ajout des labels à droite des barres
for i, bar in enumerate(bars):
    ax.text(bar.get_width() + max(df_top10_3['nb_ventes']) * 0.01,
            bar.get_y() + bar.get_height()/2,
            df_top10_3['label'].iloc[i],
            va='center', fontsize=10)

# Inversion de l'ordre pour que le produit le plus vendu soit en haut
ax.invert_yaxis()

# Titres et mise en forme
ax.set_xlabel("Nombre de ventes")
ax.set_title("Top 10 des produits les plus vendus - Catégorie 2")
plt.grid(True, linestyle='--', linewidth=0.3, alpha=1)
plt.tight_layout()
plt.show()
```

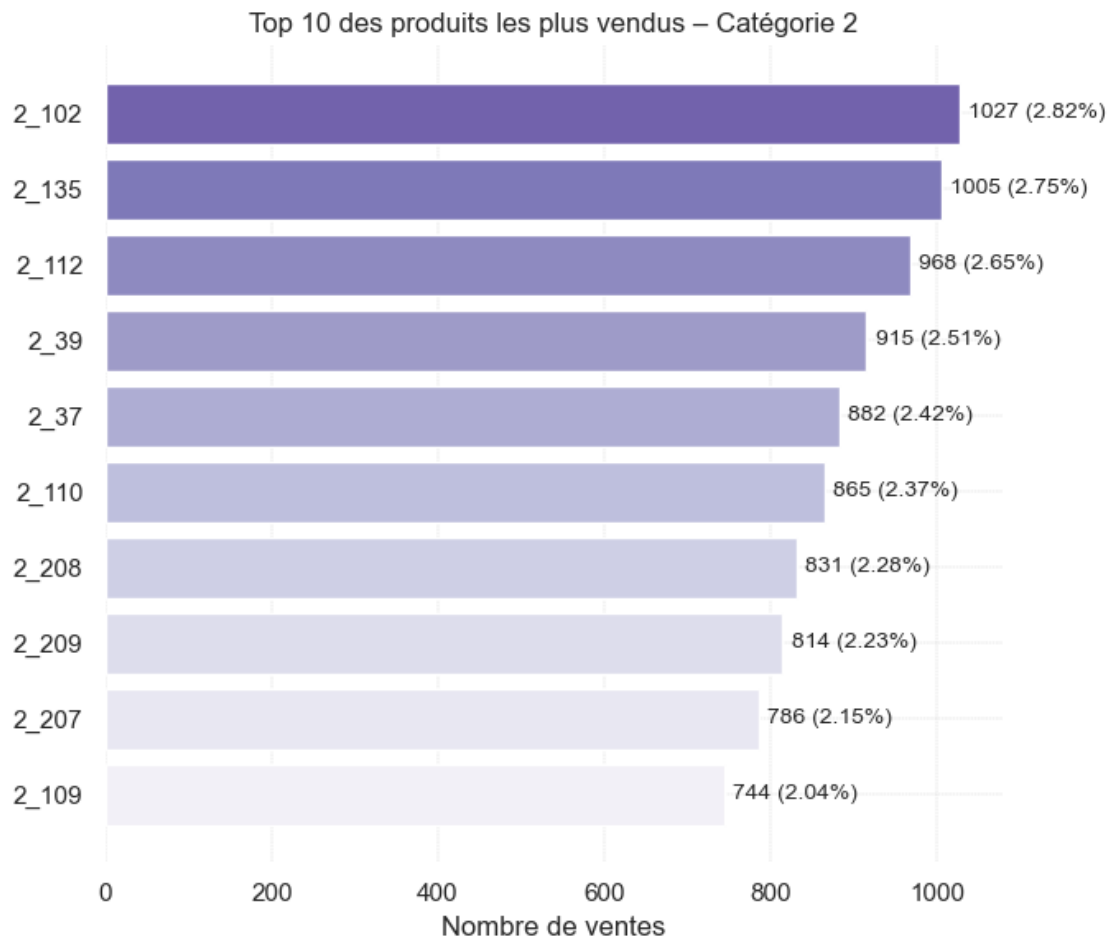


[117]:
```
# PAR CA

# Calcul du top 10 des produits par chiffre d'affaires dans cette catégorie
top_10_ca_categ_2 = df_categ_2.groupby('id_prod')['price'].sum().
 ↪sort_values(ascending=False).head(10)

# Total du CA dans la catégorie 1
total_ca_categ_2 = df_categ_2['price'].sum()

# Transformation en DataFrame
df_top10_5 = top_10_ca_categ_2.reset_index()
df_top10_5.columns = ['id_prod', 'chiffre_affaires']

# Calcul du pourcentage
df_top10_5['pourcentage'] = df_top10_5['chiffre_affaires'] / total_ca_categ_2 *␣
 ↪100
```

```python
# Création des labels avec 2 décimales
df_top10_5['label'] = df_top10_5.apply(
    lambda row: f"{row['chiffre_affaires']:.2f}€ ({row['pourcentage']:.2f}%)",␣
 ↪axis=1
)

# Palette de verts du plus foncé au plus clair
palette_verts = [mcolors.to_hex(c) for c in plt.cm.Purples(np.linspace(0.7, 0.
 ↪1, 10))]

# Création du graphique
fig, ax = plt.subplots(figsize=(7, 6))
bars = ax.barh(df_top10_5['id_prod'], df_top10_5['chiffre_affaires'],␣
 ↪color=palette_verts)

# Suppression du cadre (spines)
for spine in ax.spines.values():
    spine.set_visible(False)

# Ajout des labels à droite des barres
for i, bar in enumerate(bars):
    ax.text(bar.get_width() + max(df_top10_5['chiffre_affaires']) * 0.01,
            bar.get_y() + bar.get_height()/2,
            df_top10_5['label'].iloc[i],
            va='center', fontsize=10)

# Inversion de l'ordre pour que le produit le plus vendu soit en haut
ax.invert_yaxis()

# Titres et mise en forme
ax.set_xlabel("Chiffre d'affaires (€)")
ax.set_title("Top 10 des produits par CA - Catégorie 2")
plt.grid(True, linestyle='--', linewidth=0.3, alpha=1)
plt.tight_layout()
plt.show()
```

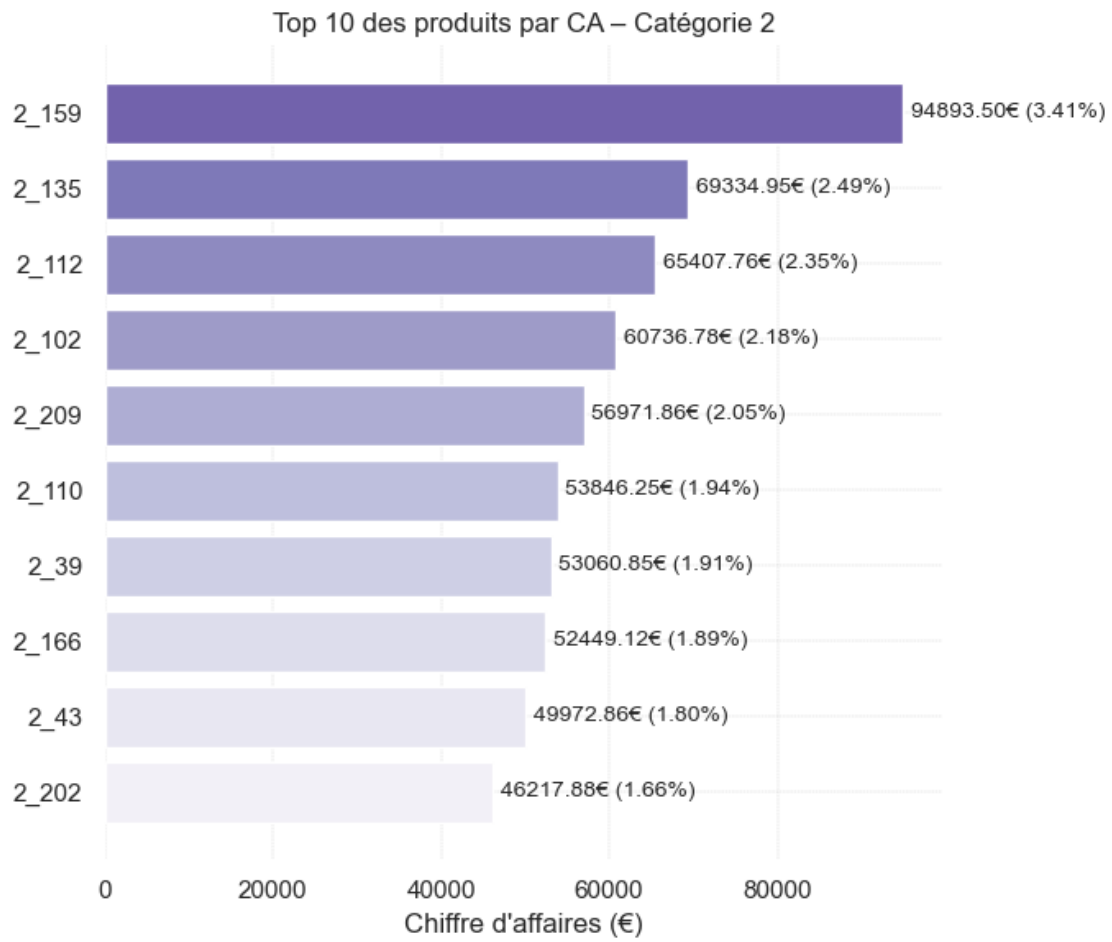


Etape 4.7 - Les flops 10

[119]:
```
# Toutes catégories confondues
flop_10_global = df_vf['id_prod'].value_counts().tail(10)
print("Flop 10 produits toutes périodes confondues :")
print(flop_10_global)
```

```
Flop 10 produits toutes périodes confondues :
id_prod
0_1539    1
0_1151    1
0_1728    1
2_81      1
0_2201    1
0_549     1
0_886     1
0_1498    1
0_541     1
```

```
0_1284    1
Name: count, dtype: int64
```

[120]:
```python
import matplotlib.colors as mcolors

# Total des ventes (toutes lignes de df_vf)
total_ventes = len(df_vf)

# Transformation en DataFrame
df_flop10 = flop_10_global.reset_index()
df_flop10.columns = ['id_prod', 'nb_ventes']

# Calcul du pourcentage
df_flop10['pourcentage'] = df_flop10['nb_ventes'] / total_ventes * 100

# Création des labels avec 2 décimales
df_flop10['label'] = df_flop10.apply(
    lambda row: f"{row['nb_ventes']} ({row['pourcentage']:.2f}%)", axis=1
)

# Palette orangée du plus foncé au plus clair
palette_orange = [mcolors.to_hex(c) for c in plt.cm.Oranges(np.linspace(0.1, 0.
 ↪7, 10))]

# Création du graphique
fig, ax = plt.subplots(figsize=(10, 5))
bars = ax.barh(df_flop10['id_prod'], df_flop10['nb_ventes'],␣
 ↪color=palette_orange)

# Suppression du cadre (spines)
for spine in ax.spines.values():
    spine.set_visible(False)

# Ajout des labels à droite des barres
for i, bar in enumerate(bars):
    ax.text(bar.get_width() + max(df_flop10['nb_ventes']) * 0.01,
            bar.get_y() + bar.get_height()/2,
            df_flop10['label'].iloc[i],
            va='center', fontsize=10)

# Titres et mise en forme
ax.set_xlabel("Nombre de ventes")
ax.set_ylabel("Produits")
ax.set_title("Flop 10 des produits les moins vendus")
plt.grid(True, linestyle='--', linewidth=0.3, alpha=1)
plt.tight_layout()
plt.show()
```

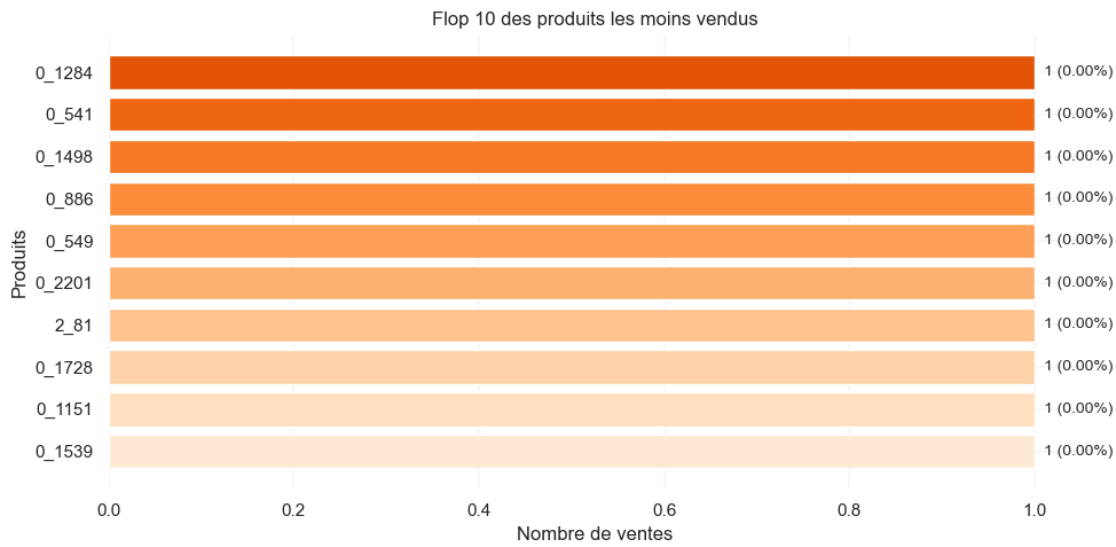


[121]:
```
import matplotlib.colors as mcolors
import numpy as np
import matplotlib.pyplot as plt

# Flop 10 des produits par chiffre d'affaires
flop_10_ca = df_vf.groupby('id_prod')['price'].sum().
 ↪sort_values(ascending=True).head(10)

# Chiffre d'affaires total
total_ca = df_vf['price'].sum()

# Transformation en DataFrame
df_flop10_ca = flop_10_ca.reset_index()
df_flop10_ca.columns = ['id_prod', 'chiffre_affaires']

# Calcul du pourcentage
df_flop10_ca['pourcentage'] = df_flop10_ca['chiffre_affaires'] / total_ca * 100

# Création des labels avec 2 décimales
df_flop10_ca['label'] = df_flop10_ca.apply(
    lambda row: f"{row['chiffre_affaires']:.0f} € ({row['pourcentage']:.2f}%)",␣
 ↪axis=1
)

# Palette orangée du plus foncé au plus clair
palette_orange = [mcolors.to_hex(c) for c in plt.cm.Oranges(np.linspace(0.1, 0.
 ↪7, 10))]
```

```python
# Création du graphique
fig, ax = plt.subplots(figsize=(10, 5))
bars = ax.barh(df_flop10_ca['id_prod'], df_flop10_ca['chiffre_affaires'],␣
↪color=palette_orange)

# Suppression du cadre (spines)
for spine in ax.spines.values():
    spine.set_visible(False)

# Ajout des labels à droite des barres
for i, bar in enumerate(bars):
    ax.text(bar.get_width() + max(df_flop10_ca['chiffre_affaires']) * 0.01,
            bar.get_y() + bar.get_height()/2,
            df_flop10_ca['label'].iloc[i],
            va='center', fontsize=10)

# Ici, pas besoin d'inverser l'ordre : on veut voir le moins rentable en haut
# Si tu veux garder la cohérence visuelle avec le top (barre la plus claire en␣
↪bas),
# tu peux activer : ax.invert_yaxis()

# Titres et mise en forme
ax.set_xlabel("Chiffre d'affaires (€)")
ax.set_title("Flop 10 des produits par chiffre d'affaires")
plt.grid(True, linestyle='--', linewidth=0.3, alpha=1)
plt.tight_layout()
plt.show()
```

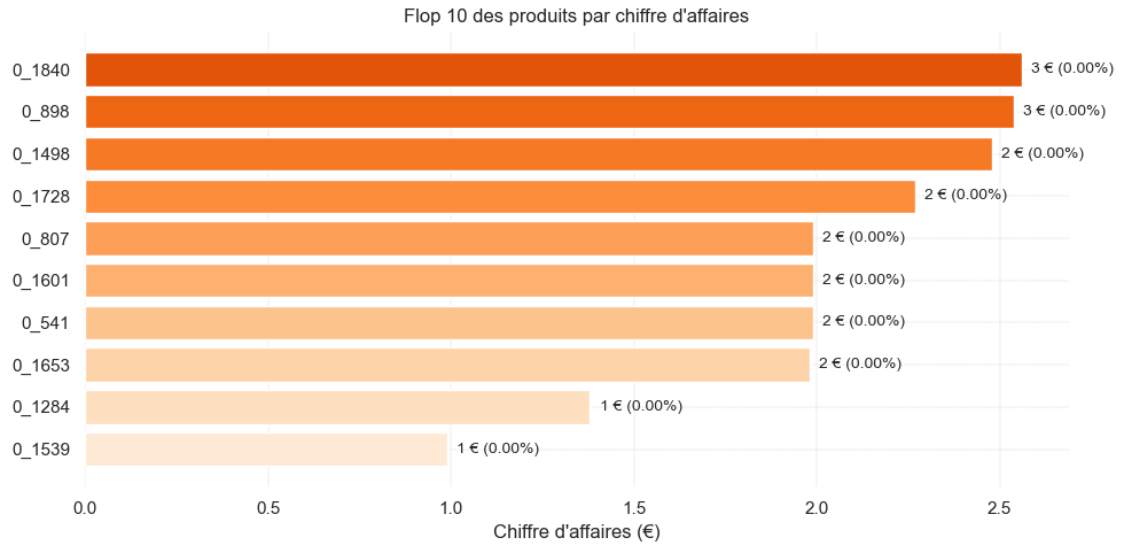


Etape 4.8 - Répartition par catégorie

[123]:
```python
# PAR NOMBRE DE VENTES
repartition_nb = df_vf['categ'].value_counts().reset_index()
repartition_nb.columns = ['categ', 'nb_ventes']
repartition_nb['pourcentage'] = repartition_nb['nb_ventes'] / len(df_vf) * 100
```

[124]:
```python
# dataviz camembert
# Définir les couleurs par catégorie
couleurs = {0: 'darkblue', 1: 'orange', 2: 'purple'}
colors = [couleurs[c] for c in repartition_nb['categ']]

# Fonction pour afficher les pourcentages en blanc
def make_autopct_white():
    def autopct(pct):
        return f'{pct:.1f}%' if pct > 0 else ''
    return lambda pct: f'{autopct(pct)}'

# Création du camembert
plt.figure(figsize=(4, 4))
wedges, texts, autotexts = plt.pie(
    repartition_nb['pourcentage'],
    labels=repartition_nb['categ'],
    autopct=make_autopct_white(),
    startangle=140,
    colors=colors  # Couleurs personnalisées ici
)

# Appliquer la couleur blanche aux textes de pourcentage
for autotext in autotexts:
    autotext.set_color('white')
    autotext.set_fontweight('bold')

plt.title("Répartition des ventes par catégorie (%)", fontsize=14)
plt.axis('equal')
plt.tight_layout()
plt.show()
```

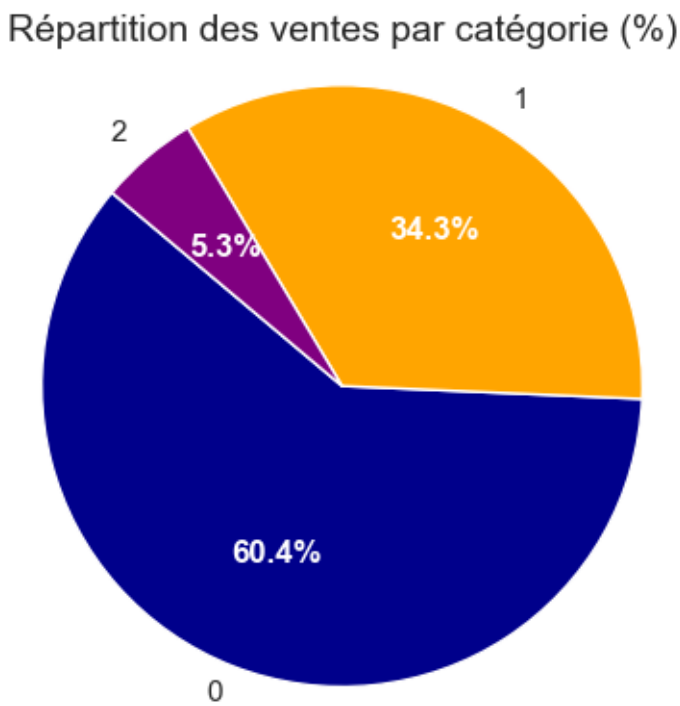


[125]:
```
# PAR CA
repartition_ca = df_vf.groupby('categ')['price'].sum().reset_index()
repartition_ca.columns = ['categ', 'chiffre_affaires']
repartition_ca['pourcentage'] = repartition_ca['chiffre_affaires'] /␣
↪df_vf['price'].sum() * 100
```

[126]:
```
#dataviz camembert
# Couleurs personnalisées par catégorie
couleurs = {0: 'darkblue', 1: 'orange', 2: 'purple'}
colors = [couleurs[c] for c in repartition_ca['categ']]

# Fonction pour formater les pourcentages
def make_autopct_white():
    def autopct(pct):
        return f'{pct:.1f}%' if pct > 0 else ''
    return lambda pct: f'{autopct(pct)}'

# Création du camembert
plt.figure(figsize=(4, 4))
wedges, texts, autotexts = plt.pie(
    repartition_ca['pourcentage'],
    labels=repartition_ca['categ'],
    autopct=make_autopct_white(),
```

```
    startangle=140,
    colors=colors
)

# Style des pourcentages en blanc
for autotext in autotexts:
    autotext.set_color('white')
    autotext.set_fontweight('bold')

plt.title("Répartition du chiffre d'affaires par catégorie (%)", fontsize=14)
plt.axis('equal')
plt.tight_layout()
plt.show()
```

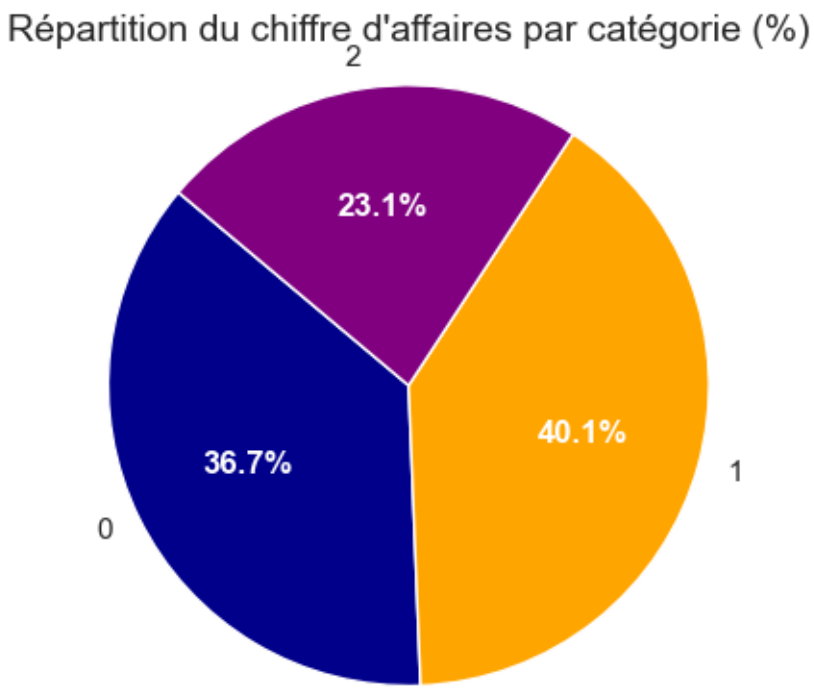


Etape 5 - Analyses des clients

Etape 5.1 - Répartition du CA pour les clients BtoB

Identification des clients BtoB

[130]:
```
# 1. Calcul du CA par client (df dédié ca_clients)
ca_clients = df_vf.groupby('client_id')['price'].sum().reset_index()
ca_clients.columns = ['client_id', 'CA_total']

# 2. Visualisation des outliers (VISUALISATION BOXPLOT)
```

```
plt.figure(figsize=(5, 6))
sns.boxplot(data=ca_clients, y='CA_total', color='skyblue')

plt.title("Distribution du chiffre d'affaires par client", fontsize=14)
plt.ylabel("CA (€)")
plt.xlabel("")
plt.tight_layout()
plt.show()
```

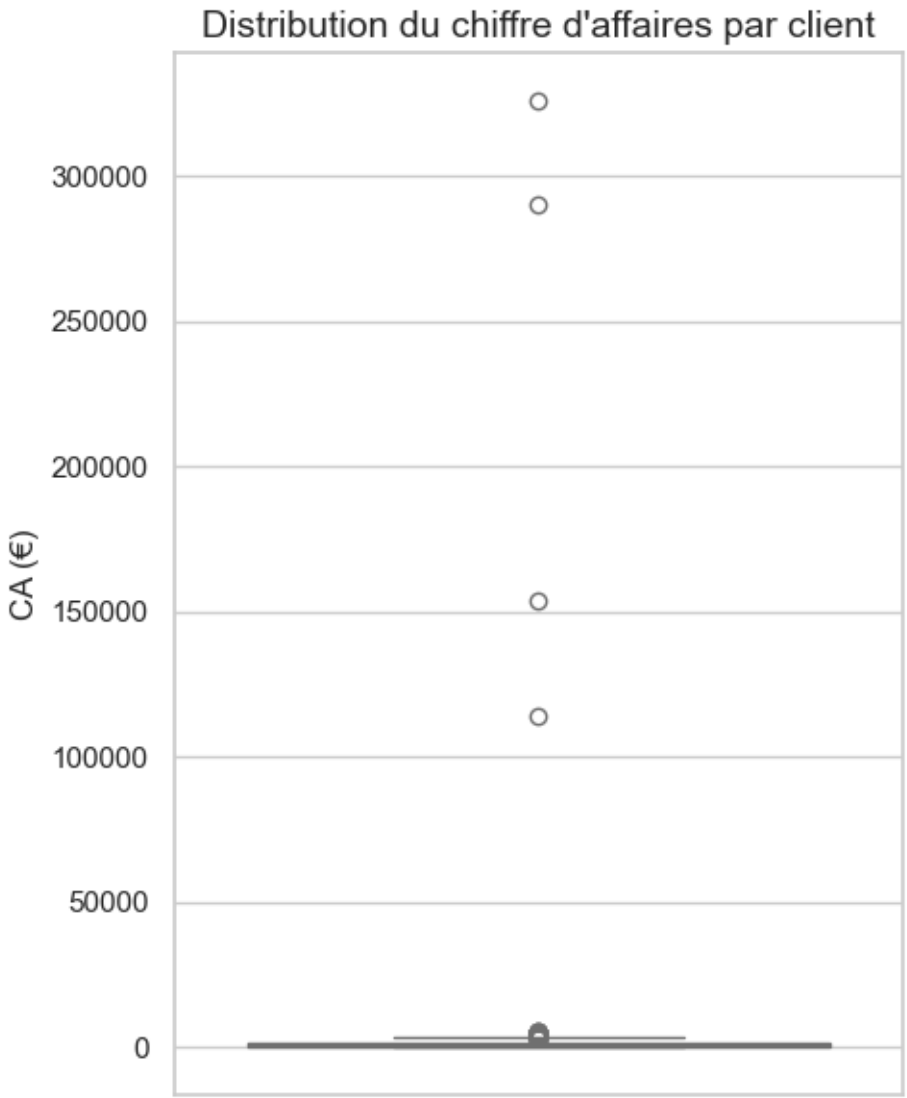


En se basasant sur le graphique, 4 outliers se détachent. Déduction : les B2B représentent un CA > 100k euros

[132]:
```python
# Filtrer les clients dont le CA dépasse 100 000 €
clients_b2b = ca_clients[ca_clients['CA_total'] > 100000].
↪sort_values('CA_total', ascending=False)

# Calcul du CA total des clients B2B
total_b2b = clients_b2b['CA_total'].sum()

# Ajout d'une colonne 'pct_CA' avec le pourcentage
clients_b2b['%_CA'] = (clients_b2b['CA_total'] / clients_b2b['CA_total'].sum()␣
↪* 100).round(0).astype(int).astype(str) + '%'
clients_b2b
```

[132]:
```
     client_id   CA_total %_CA
677     c_1609  326039.89  37%
4388    c_4958  290227.03  33%
6337    c_6714  153918.60  17%
2724    c_3454  114110.57  13%
```

[133]:
```python
# Prépa df pour analyse
# 1. Création col B2B dans df principal pour identifier ces clients
df_vf['type_client'] = df_vf['client_id'].isin(clients_b2b['client_id'])
```

[134]:
```python
# 2. Extraction transactions BtoB
df_b2b = df_vf[df_vf['type_client']]
df_b2b
```

[134]:
```
       id_prod                       date session_id client_id   annee  mois  \
7          0_0 2021-03-10 06:43:31.234015     s_4266    c_6714  2021.0   3.0
9          0_0 2021-03-10 15:40:09.343729     s_4428    c_6714  2021.0   3.0
31         0_0 2021-03-22 23:37:09.874830    s_10114    c_1609  2021.0   3.0
54         0_0 2021-04-08 15:29:10.605154    s_17758    c_1609  2021.0   4.0
79         0_0 2021-04-17 20:09:37.561114    s_21987    c_1609  2021.0   4.0
…         …                          …        …        …      …    …
687489    2_96 2023-02-07 10:49:20.233426   s_338157    c_4958  2023.0   2.0
687502    2_96 2023-02-21 04:43:48.843506   s_344668    c_6714  2023.0   2.0
687503    2_96 2023-02-21 20:23:52.060094   s_344997    c_4958  2023.0   2.0
687514    2_97 2021-06-12 06:27:05.794886    s_47520    c_4958  2021.0   6.0
687521    2_97 2022-08-12 06:27:05.794886   s_252106    c_4958  2022.0   8.0

        jour jour_lettre mois_lettre   price  categ    sex  birth  Age  \
7       10.0    Mercredi        Mars    3.75      0  Femme   1968   57
9       10.0    Mercredi        Mars    3.75      0  Femme   1968   57
31      22.0       Lundi        Mars    3.75      0  Homme   1980   45
54       8.0       Jeudi       Avril    3.75      0  Homme   1980   45
79      17.0      Samedi       Avril    3.75      0  Homme   1980   45
…      …          …          …      …     …    …     …    …
687489   7.0       Mardi     Février   47.91      2  Homme   1999   26
```

```
687502  21.0       Mardi     Février   47.91      2  Femme   1968   57
687503  21.0       Mardi     Février   47.91      2  Homme   1999   26
687514  12.0      Samedi        Juin  160.99      2  Homme   1999   26
687521  12.0    Vendredi        Août  160.99      2  Homme   1999   26

       year_month    year_day  type_client
7         2021-03  2021-03-10         True
9         2021-03  2021-03-10         True
31        2021-03  2021-03-22         True
54        2021-04  2021-04-08         True
79        2021-04  2021-04-17         True
…           …         …           …
687489    2023-02  2023-02-07         True
687502    2023-02  2023-02-21         True
687503    2023-02  2023-02-21         True
687514    2021-06  2021-06-12         True
687521    2022-08  2022-08-12         True

[46800 rows x 17 columns]
```

Répartition du CA par client et par catégorie

[136]:
```python
# Agrégation du CA par client et catégorie
df_grouped = df_b2b.groupby(['client_id', 'categ'])['price'].sum().reset_index()

# Pivot pour barres empilées
df_pivot = df_grouped.pivot(index='client_id', columns='categ', values='price').
 ↪fillna(0)

# CA total par client
ca_client = df_pivot.sum(axis=1)

# CA total global
ca_global = ca_client.sum()

# Création du graphique
fig, ax = plt.subplots(figsize=(10, 6))
x_pos = range(len(df_pivot.index))
bottom = [0] * len(df_pivot)

# Suppression du cadre (spines)
for spine in ax.spines.values():
    spine.set_visible(False)

colors = {0: '#e07a5f', 1: '#ffd166', 2: '#118ab2'}  # couleurs personnalisées

for cat in sorted(df_pivot.columns):
```

```
    bars = ax.bar(x_pos, df_pivot[cat], bottom=bottom, label=f'Catégorie␣
↪{cat}', color=colors[cat])

    # Ajout du double affichage dans chaque segment
    for i, bar in enumerate(bars):
        val = df_pivot.iloc[i][cat]
        if val > 0:
            pct_client = round(val / ca_client.iloc[i] * 100)
            pct_global = round(val / ca_global * 100)
            ax.text(bar.get_x() + bar.get_width()/2,
                    bar.get_y() + bar.get_height()/2,
                    f"{pct_client}%\n({int(val)}€ | {pct_global}%)",
                    ha='center', va='center',
                    color='#212529', fontsize=10, fontweight='normal')

    bottom = [i + j for i, j in zip(bottom, df_pivot[cat])]

# Axe X
ax.set_xticks(x_pos)
ax.set_xticklabels(df_pivot.index, rotation=30, ha='right', fontsize=12,␣
↪fontweight='bold')

# Personnalisation
ax.set_ylabel("CA (€)", fontsize=12)
ax.set_title("CA par client B2B, réparti par catégorie", fontsize=14)
ax.legend(title="Catégories", loc='upper right')
plt.grid(True, linestyle='--', linewidth=0.3, alpha=1)
plt.tight_layout()
plt.show()
```

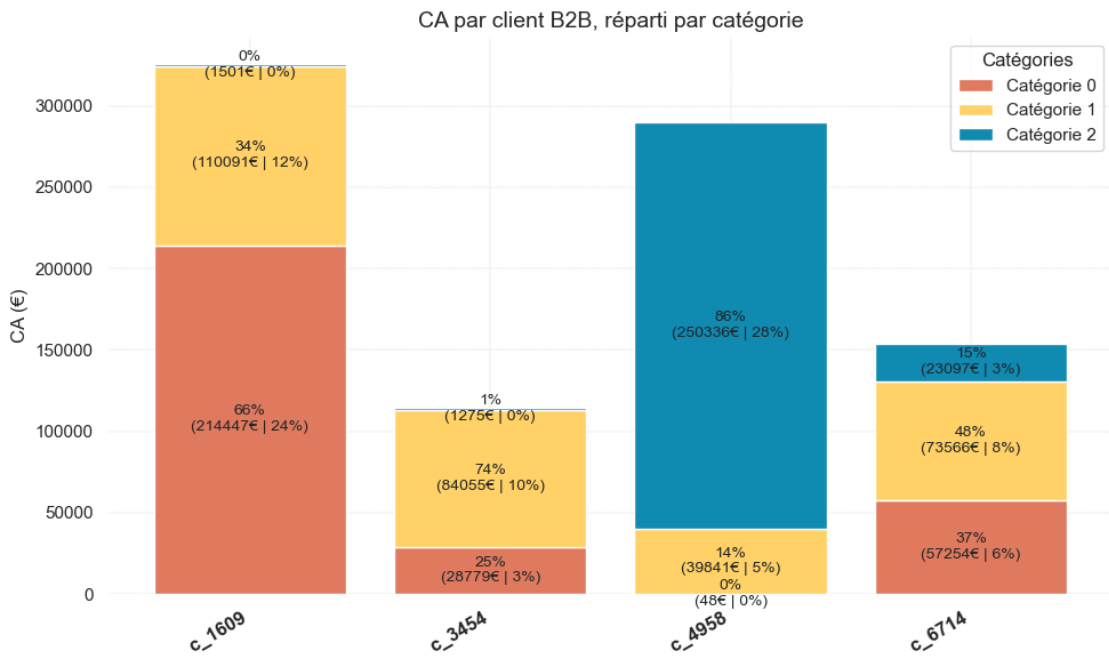


Etape 5.2 - Courbe de Lorenz pour les particuliers

[138]:
```
# Étape 1 : filtrer les clients particuliers
clients_particuliers = df_vf[~df_vf['client_id'].isin(clients_b2b['client_id'])]

# Étape 2 : calcul du CA total par client particulier
ca_particuliers = clients_particuliers.groupby('client_id')['price'].sum().
 ↪reset_index()
ca_particuliers = ca_particuliers.sort_values('price')  # tri croissant

# Étape 3 : calcul des parts cumulées
ca_values = ca_particuliers['price'].values
ca_total = ca_values.sum()
ca_cum = np.cumsum(ca_values) / ca_total
clients_cum = np.arange(1, len(ca_values)+1) / len(ca_values)

# Étape 4 : ajout du point (0,0)
ca_cum = np.insert(ca_cum, 0, 0)
clients_cum = np.insert(clients_cum, 0, 0)

# Étape 5 : tracé de la courbe
fig, ax = plt.subplots(figsize=(8, 6))
ax.plot(clients_cum, ca_cum, label='Courbe de Lorenz', color='#25a18e',␣
 ↪linewidth=2)
ax.plot([0, 1], [0, 1], label='Égalité parfaite', color='gray', linestyle='--')
```

```python
# Personnalisation
ax.set_title("Courbe de Lorenz - Clients Particuliers", fontsize=14)
ax.set_xlabel("Part cumulée des clients", fontsize=12)
ax.set_ylabel("Part cumulée du CA", fontsize=12)
ax.legend()
ax.grid(True)

plt.tight_layout()
plt.show()
```

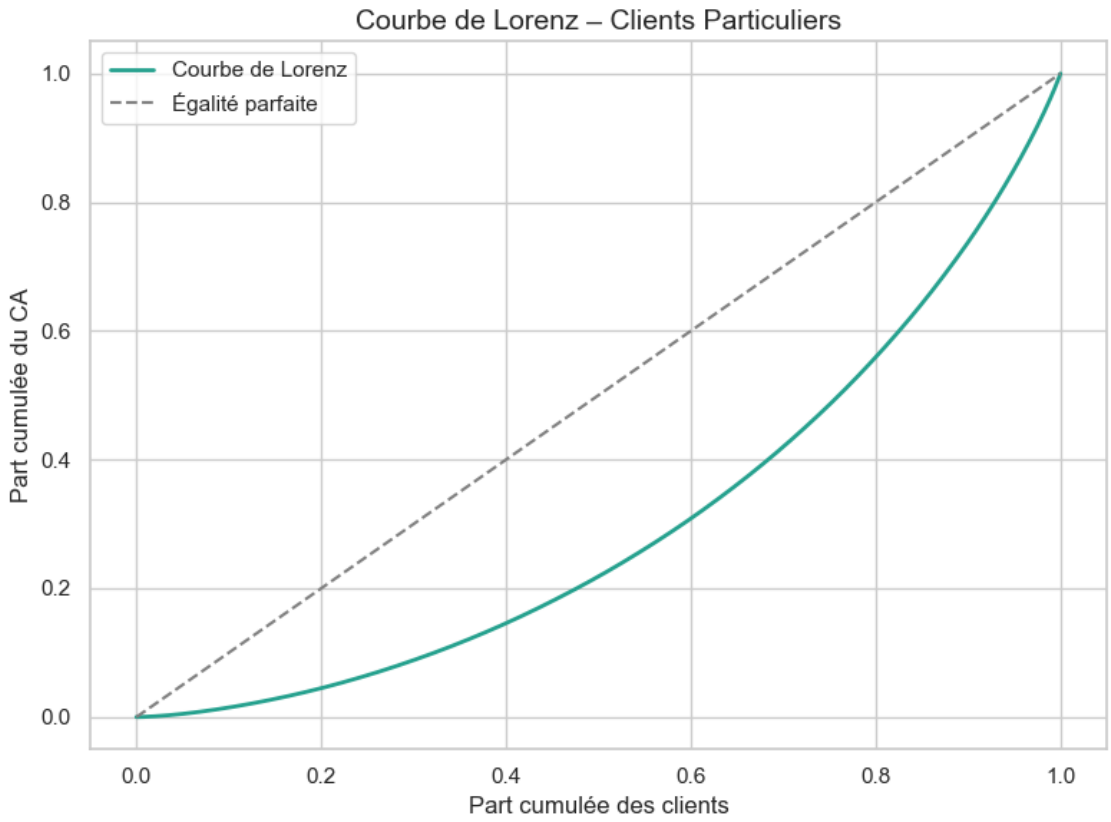


Courbe de Lorenz : - sert à mesure la répartition des ressources (ici le CA) entre des individus (ici les clients) - La diagonale grise ("égalité parfaite") correspond à une situation où chaque client contribue exactement de manière proportionnelle : par ex. 20% des clients = 20% du CA.

Analyse : - la courbe est en dessous de la diagonale -> inégalité de contribution au CA : une majorité de clients contribue peu au CA (donc une minorité contribue bcp) - Quand on est vers 40% des clients (en bas sur l'axe des x), on est seulement vers 15–20% du CA (axe des y). - Cela veut dire que 40% des plus petits clients n'apportent qu'environ 20% du revenu. - Symétriquement, donc, une minorité de clients (les 20% les plus gros) génèrent la majorité du CA (effet Pareto 80/20).

La courbe montre une forte concentration du CA sur une minorité de clients. C'est une situation très classique en commerce, qui se rapproche de la règle du Pareto (80/20) : 20% des clients font

environ 80% du CA.

Recommandations : - Stratégie marketing : plus d'efforts à mettre sur la fidélisation de ces clients stratégiques. - Gestion des petits clients : réfléchir à leur potentiel (cross-selling, upselling) ou voir s'ils coûtent plus qu'ils ne rapportent (Un client peut coûter plus qu'il ne rapporte si les coûts de logistique, d'acquisition et de service dépassent sa contribution au chiffre d'affaires.).

Analyses complémentaires : - Métrique associée : indice de Gini (surface entre la courbe de Lorenz et la ligne d'égalité, divisée par la surface totale sous la ligne d'égalité.) 0=égalité parfaite (tout le monde a la même part) / 1= inégalité totale

[143]:
```
#Indice de Gini -> calcule l'aire entre la courbe et la diagonale
def gini(array):
    array = np.sort(array)
    n = len(array)
    cumvals = np.cumsum(array)
    return (n + 1 - 2 * np.sum(cumvals) / cumvals[-1]) / n

gini_index = gini(ca_values)
print(f"Coefficient de Gini : {gini_index:.2f}")
```

```
Coefficient de Gini : 0.40
```

Etape 6 - Analyse des corrélations

Etape 6.1- Genre des clients et catégories des livres achetés

1. Formulation des hypothèses

- H0 : le genre du client et la catégorie du livre acheté sont indépendants (pas de lien).
- H1 : le genre du client et la catégorie du livre acheté sont associés (il y a un lien).

2. Choix du test : Comme les deux variables sont catégorielles (quali/quali), on utilise :

- Test du Chi² d'indépendance -> détermine s'il y a une relation mais pas sa force. Va servir à calculer la p-value. Si p-value>0.05 alors on garde H0. Si p-value<0.05, on rejette H0.
- pour mesurer la force de l'association, calculer le V de Cramer -> détermine la force de la relation

3. Visualisation

- Tableau de contingence (pd.crosstab)
- Graphique nuage de points (scatter plot)

[147]:
```
from scipy.stats import chi2_contingency

# 1. Tableau de contingence
contingence = pd.crosstab(df_vf['sex'], df_vf['categ'])
print("Tableau de contingence :\n", contingence)

# 2. Test du Chi² d'indépendance
chi2, p, dof, expected = chi2_contingency(contingence)
print(f"\nTest du Chi² :")
```

```python
print(f"Chi² = {chi2:.2f}")
print(f"p-value = {p:.4f}")
print(f"Degrés de liberté = {dof}")

# 3. Interprétation de l'hypothèse
if p < 0.05:
    print("On rejette H0 : association significative entre le genre et la␣
 ↪catégorie achetée")
else:
    print("On ne rejette pas H0 : pas de preuve de lien significatif")

# 4. V de Cramer (force de l'association)
n = contingence.to_numpy().sum()
phi2 = chi2 / n
r, k = contingence.shape
cramers_v = np.sqrt(phi2 / min(k - 1, r - 1))
print(f"\n  V de Cramer = {cramers_v:.3f} (force de l'association)")
```

```
Tableau de contingence :
 categ       0       1      2
sex
Femme  206103  119307  17283
Homme  209356  116285  19200

Test du Chi² :
Chi² = 158.25
p-value = 0.0000
Degrés de liberté = 2
On rejette H0 : association significative entre le genre et la catégorie achetée

  V de Cramer = 0.015 (force de l'association)
```

La p-value est nettement inférieure à 0.05. Il y a donc un lien entre ces 2 variables. Par contre, le V de cramer (0.015) montre que cette relation n'est pas forte -> donc pas structurant dans les comportements d'achats

[149]:
```python
# Étape 1 : Comptage des transactions par sexe et catégorie
df_counts = df_vf.groupby(['categ', 'sex']).size().unstack(fill_value=0)

# Étape 2 : Définir les couleurs personnalisées
custom_colors = {'Femme': '#ff69b4', 'Homme': '#1f77b4'}

# Étape 3 : Tracé des barres empilées
ax = df_counts.plot(kind='bar', stacked=True, figsize=(6, 6),␣
 ↪color=[custom_colors[sex] for sex in df_counts.columns])

# Étape 4 : Ajout des annotations
for idx, row in df_counts.iterrows():
```

```
    y_offset = 0
    for sex in df_counts.columns:
        count = row[sex]
        if count > 0:
            ax.text(
                x=idx,
                y=y_offset + count / 2,
                s=str(count),
                ha='center',
                va='center',
                fontsize=9,
                color='black'
            )
            y_offset += count

# Personnalisation
plt.title("Répartition des transactions par sexe et catégorie de livres")
plt.xlabel("Catégorie de livres")
plt.ylabel("Nombre de transactions")
plt.legend(title="Sexe")
plt.grid(axis='y')
plt.tight_layout()
plt.show()
```

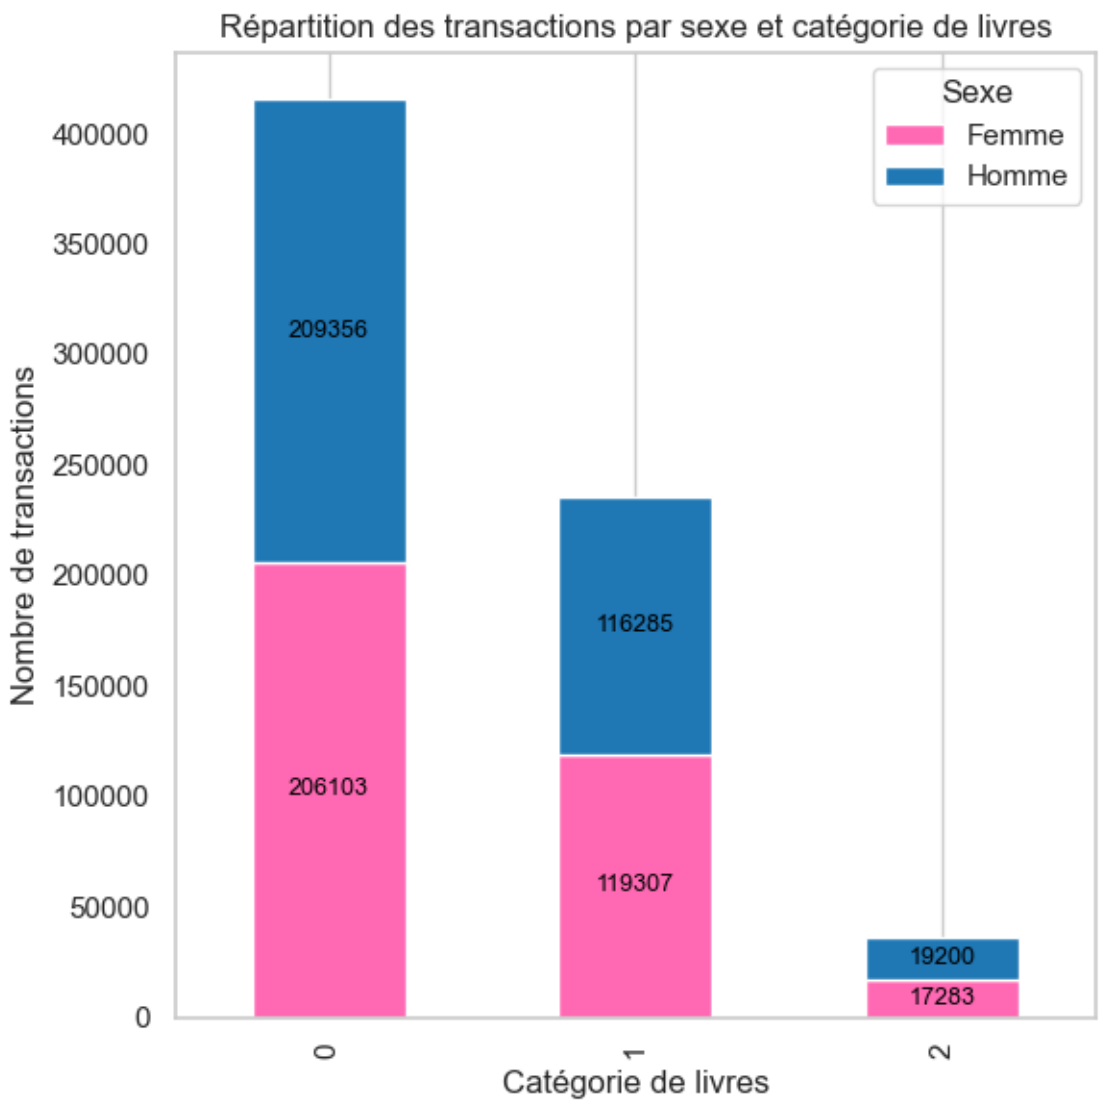


Etape 6.2 - Âge des clients et montant total des achats

1. Formulation des hypothèses

- H0 : Il n'y a pas de relation linéaire entre l'âge du client et le montant des achats.
- H1 : Il y a une relation linéaire significative entre l'âge du client et le montant des achats.

2. Choix du test : Comme les deux variables sont quantitatives, on utilise :

- Coefficient de corrélation de Pearson (r) → mesure la force et la direction de la relation linéaire.
- p-value associée à r → permet de savoir si cette relation est statistiquement significative.
- Si p < 0.05 → on rejette H0 → il y a un lien significatif.
- Si p  0.05 → on ne rejette pas H0 → pas de preuve suffisante d'un lien.

3. Visualisation recommandée Pour ce type d'analyse, le nuage de points (scatter plot) est

parfaitement adapté :

- Il permet de visualiser la tendance entre les deux variables.
- On peut y ajouter une droite de régression linéaire pour illustrer la corrélation.

[152]:
```
# 1. Filtrage des données valides
df_corr = df_vf[['Age', 'price']].dropna()

# 2. Calcul du coefficient de corrélation de Pearson et de la p-value
r, p_value = pearsonr(df_corr['Age'], df_corr['price'])
print(f"  Coefficient de corrélation de Pearson : {r:.3f}")
print(f"p-value : {p_value:.4f}")

# 3. Interprétation
if p_value < 0.05:
    print("On rejette H0 : il existe une relation linéaire significative entre␣
 ↪l'âge et le montant des achats.")
else:
    print("On ne rejette pas H0 : pas de preuve suffisante d'une relation␣
 ↪linéaire.")

# 4. Visualisation : scatter plot avec droite de régression
plt.figure(figsize=(8, 6))
sns.regplot(x='Age', y='price', data=df_corr, ci=None, line_kws={"color":␣
 ↪"red"})
plt.title("Relation entre l'âge du client et le montant des achats")
plt.xlabel("Âge du client")
plt.ylabel("Montant des achats (€)")
plt.grid(True)
plt.tight_layout()
plt.show()
```

```
  Coefficient de corrélation de Pearson : -0.207
p-value : 0.0000
On rejette H0 : il existe une relation linéaire significative entre l'âge et le
montant des achats.
```

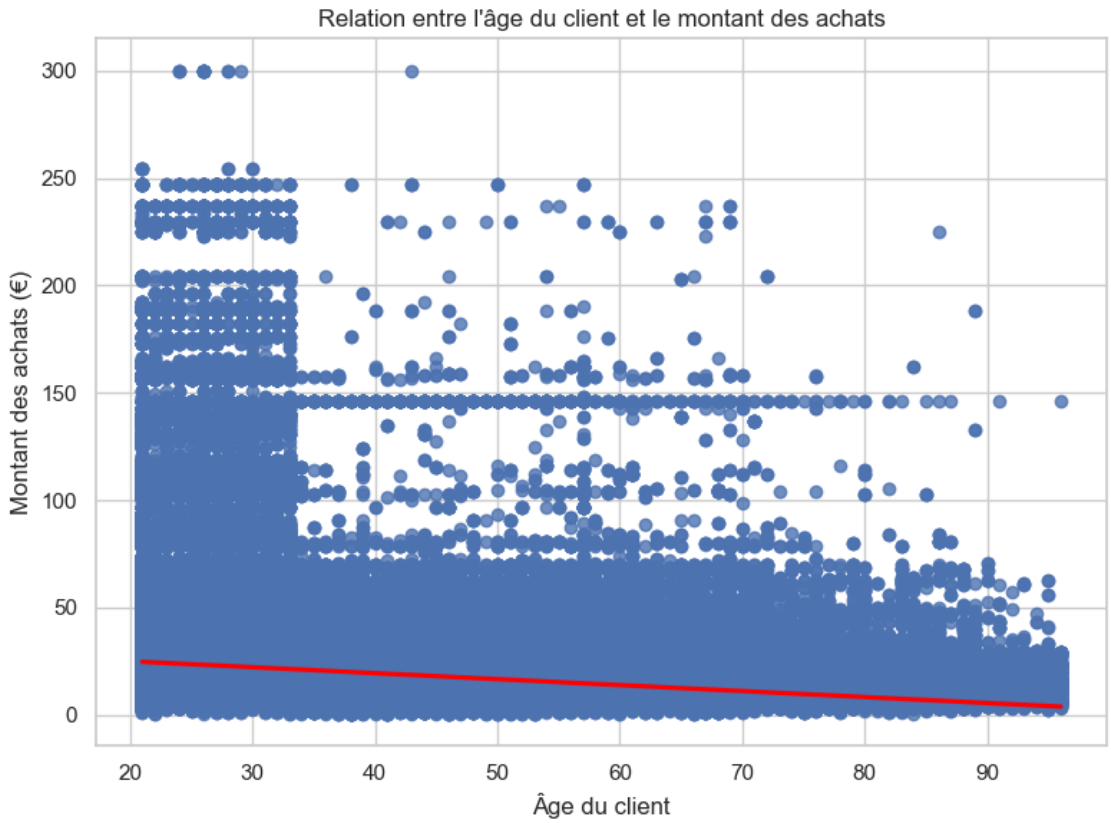


[153]:
```
# 4. Visualisation : scatter plot avec lissage local (check spearman)
plt.figure(figsize=(8, 6))
sns.regplot(x='Age', y='price', data=df_corr, ci=None, line_kws={"color":␣
↪"red"}, lowess=True)
plt.title("Relation entre l'âge du client et le montant des achats")
plt.xlabel("Âge du client")
plt.ylabel("Montant des achats (€)")
plt.grid(True)
plt.tight_layout()
plt.show()
```

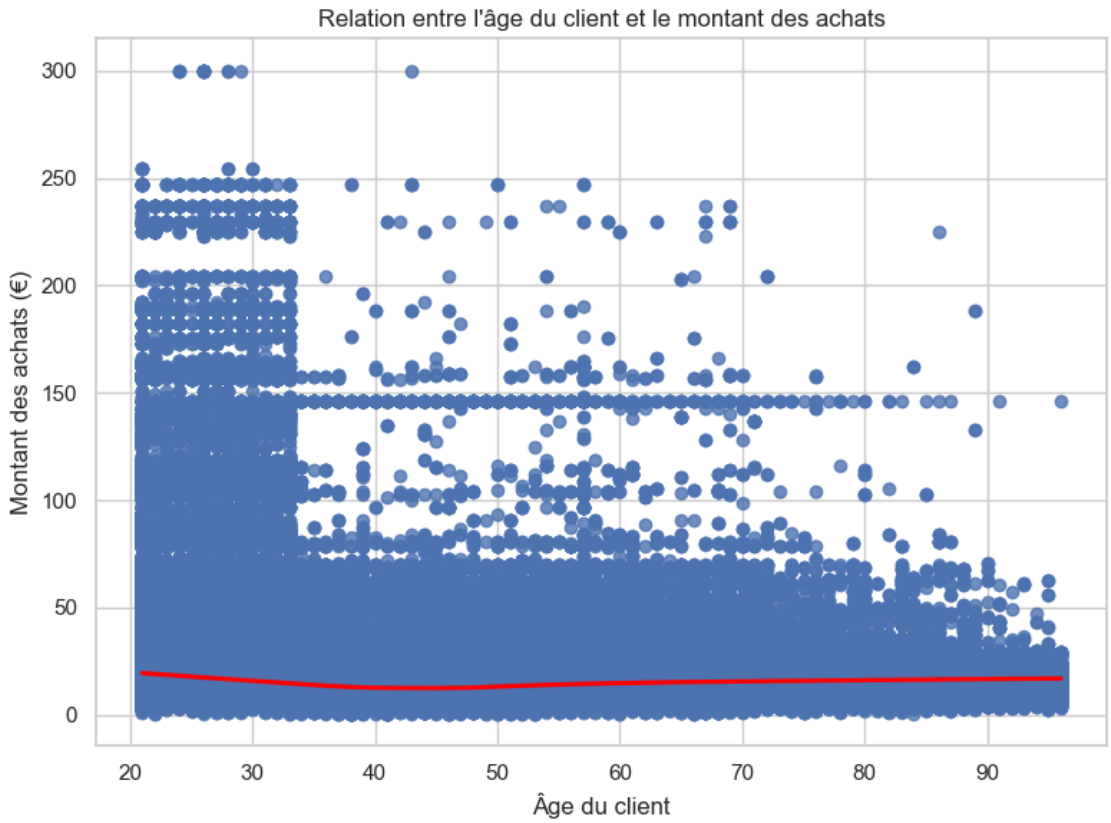


[154]:
```
from scipy.stats import spearmanr

r_spearman, p_spearman = spearmanr(df_corr['Age'], df_corr['price'])
print(f"  Coefficient de Spearman : {r_spearman:.3f}")
print(f"p-value : {p_spearman:.4f}")
```

```
  Coefficient de Spearman : -0.055
p-value : 0.0000
```

Corrélation négative : r = -0.207 - Le coefficient de Pearson est négatif, ce qui signifie que plus l'âge augmente, plus le montant des achats tend à diminuer. - La valeur -0.207 indique une corrélation faible, mais non négligeable. Ce n'est pas une relation forte, mais elle est suffisamment marquée pour être détectée statistiquement.

p-value = 0.0000 - La p-value est extrêmement faible, bien en dessous du seuil de 0.05. - Cela signifie que la probabilité que cette corrélation soit due au hasard est quasi nulle. - Donc, on rejette l'hypothèse nulle (H0) : il y a bien une relation linéaire significative entre l'âge et le montant des achats

Etape 6.3 - Âge des clients et fréquence d'achat

1. Formulation des hypothèses

- H0 (hypothèse nulle) : Il n'y a pas de relation linéaire entre l'âge du client (age) et le montant des achats (montant_achats).
- H1 (hypothèse alternative) : Il y a une relation linéaire significative entre l'âge du client et le montant des achats.

2. Choix du test statistique : Comme les deux variables sont quantitatives, on utilise :

- Le coefficient de corrélation de Pearson (r) : Il mesure la force et la direction de la relation linéaire. Il varie entre -1 (corrélation négative parfaite) et +1 (corrélation positive parfaite).
- La p-value associée :
- Elle indique si la corrélation est statistiquement significative.
- Seuil de décision :
- Si p < 0.05 → on rejette H0 → il y a un lien significatif.
- Si p  0.05 → on ne rejette pas H0 → pas de preuve suffisante d'un lien

[158]:
```
# AVEC CLIENTS B2B

# Étape 1 : Calcul du nombre de transactions par client
df_freq = df_vf.groupby('client_id').agg({
    'Age': 'first',  # âge supposé constant par client
    'session_id': 'count'  # nombre de transactions
}).rename(columns={'session_id': 'nb_transactions'}).reset_index()

# Étape 2 : Corrélation de Pearson
r, p_value = pearsonr(df_freq['Age'], df_freq['nb_transactions'])
print(f"  Coefficient de corrélation de Pearson : {r:.3f}")
print(f"p-value : {p_value:.4f}")

if p_value < 0.05:
    print("On rejette H0 : il existe une relation linéaire significative entre␣
 ↪l'âge et la fréquence d'achat.")
else:
    print("On ne rejette pas H0 : pas de preuve suffisante d'une relation␣
 ↪linéaire.")

# Étape 3 : Visualisation
plt.figure(figsize=(8, 6))
sns.regplot(x='Age', y='nb_transactions', data=df_freq, ci=None,␣
 ↪line_kws={"color": "red"})
plt.title("Relation entre l'âge du client et sa fréquence d'achat")
plt.xlabel("Âge du client")
plt.ylabel("Nombre de transactions")
plt.grid(True)
plt.tight_layout()
plt.show()
```

```
 Coefficient de corrélation de Pearson : 0.007
p-value : 0.5353
On ne rejette pas H0 : pas de preuve suffisante d'une relation linéaire.
```

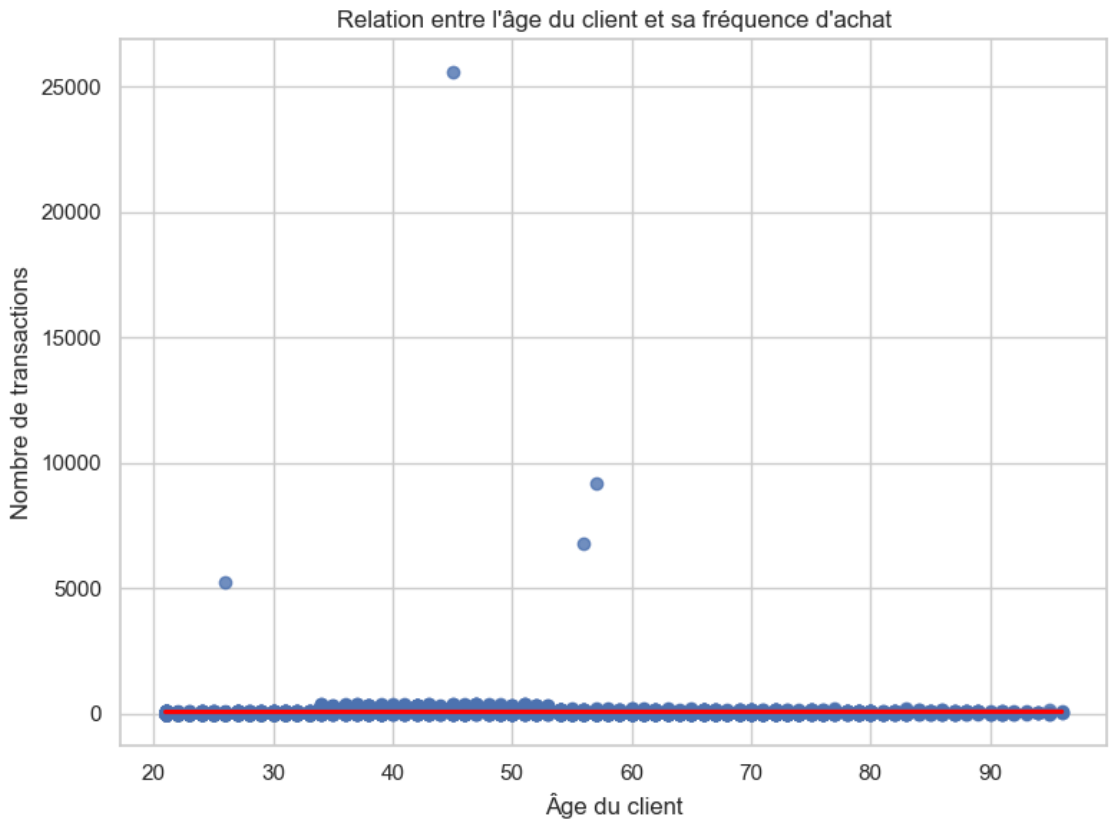


[159]:
```python
df_vf['type_client'].unique()
```

[159]:
```
array([False,  True])
```

[160]:
```python
df_vf_particuliers = df_vf[df_vf['type_client'] == False]
```

[161]:
```python
# SANS CLIENTS B2B
# Étape 1 : Calcul du nombre de transactions par client
df_freq = df_vf_particuliers.groupby('client_id').agg({
    'Age': 'first',  # âge supposé constant par client
    'session_id': 'count'  # nombre de transactions
}).rename(columns={'session_id': 'nb_transactions'}).reset_index()

# Étape 2 : Corrélation de Pearson
r, p_value = pearsonr(df_freq['Age'], df_freq['nb_transactions'])
print(f"  Coefficient de corrélation de Pearson : {r:.3f}")
print(f"p-value : {p_value:.4f}")
```

```python
if p_value < 0.05:
    print("On rejette H0 : il existe une relation linéaire significative entre␣
 ↪l'âge et la fréquence d'achat.")
else:
    print("On ne rejette pas H0 : pas de preuve suffisante d'une relation␣
 ↪linéaire.")

# Étape 3 : Visualisation avec droite de régression (check pearson)
plt.figure(figsize=(8, 6))
sns.regplot(x='Age', y='nb_transactions', data=df_freq, ci=None,␣
 ↪line_kws={"color": "red"})
plt.title("Relation entre l'âge du client et sa fréquence d'achat")
plt.xlabel("Âge du client")
plt.ylabel("Nombre de transactions")
plt.grid(True)
plt.tight_layout()
plt.show()
```

```
 Coefficient de corrélation de Pearson : 0.030
p-value : 0.0049
On rejette H0 : il existe une relation linéaire significative entre l'âge et la
fréquence d'achat.
```

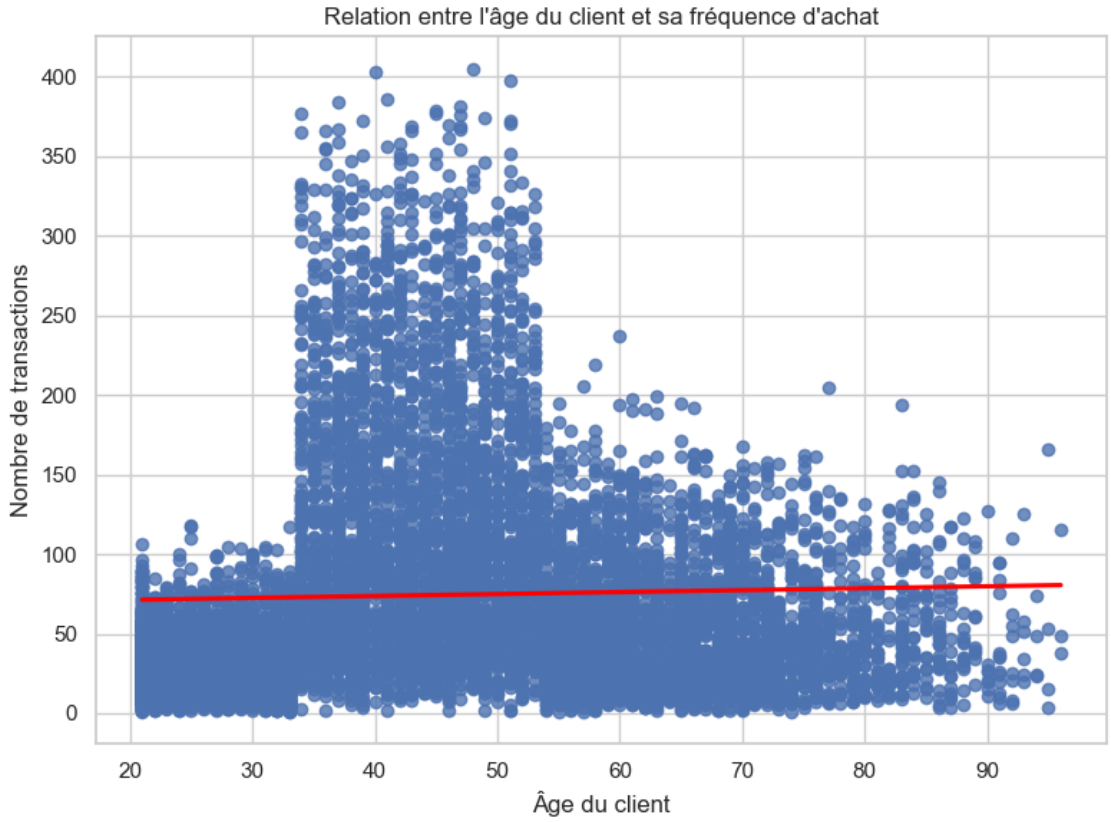

[162]:
```python
from scipy.stats import spearmanr

# Application du test
r_spearman, p_spearman = spearmanr(df_freq['Age'], df_freq['nb_transactions'])

# Affichage des résultats
print(f"  Coefficient de Spearman : {r_spearman:.3f}")
print(f"p-value : {p_spearman:.4f}")

# Interprétation
if p_spearman < 0.05:
    print("On rejette H0 : relation monotone significative entre l'âge et la␣
 ↪fréquence d'achat.")
else:
    print("On ne rejette pas H0 : pas de preuve suffisante d'une relation␣
 ↪monotone.")
```

```
  Coefficient de Spearman : 0.128
p-value : 0.0000
On rejette H0 : relation monotone significative entre l'âge et la fréquence
d'achat.
```

[163]:
```python
# Étape 3 : Visualisation avec droite lissée localement (check spearman)
plt.figure(figsize=(8, 6))
sns.regplot(x='Age', y='nb_transactions', data=df_freq, lowess=True,␣
 ↪line_kws={"color": "red"})
plt.title("Relation entre l'âge du client et sa fréquence d'achat")
plt.xlabel("Âge du client")
plt.ylabel("Nombre de transactions")
plt.grid(True)
plt.tight_layout()
plt.show()
```

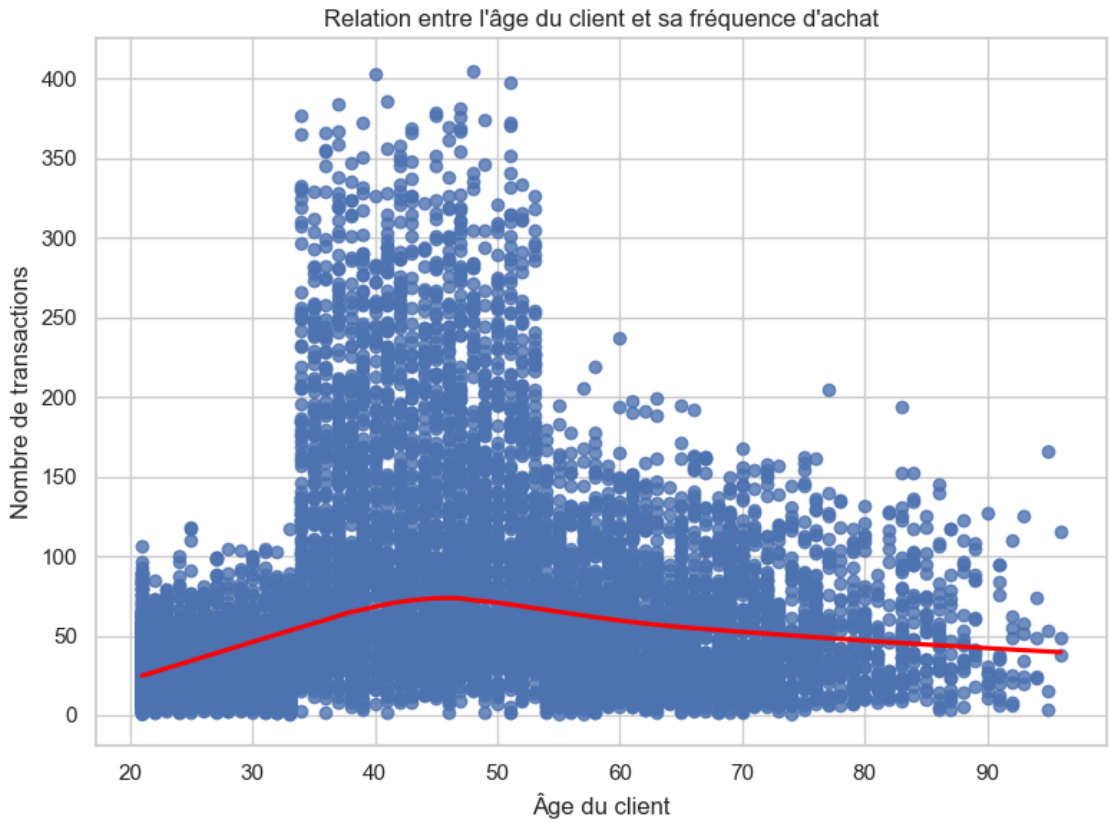


Interprétation des résultats - r = 0.030 → Le coefficient de corrélation est très faible et positif. - Cela signifie qu'il existe une relation linéaire, mais elle est quasiment négligeable en termes de force. - En clair : quand l'âge augmente, le montant des achats a tendance à augmenter très légèrement, mais ce n'est pas une tendance forte. - p-value = 0.0049 → Elle est inférieure à 0.05, donc : - Statistiquement significatif : on rejette H0. - Mais attention : significatif ne veut pas dire important. La relation est détectable, mais elle n'est pas puissante.

Etape 6.4 - Âge des clients et taille du panier moyen

1. Formulation des hypothèses

- H0 : Il n'y a pas de relation linéaire entre l'âge du client et la taille moyenne de son panier.
- H1 : Il existe une relation linéaire significative entre l'âge du client et la taille moyenne de son panier.

2. Choix du test : Comme les deux variables sont quantitatives continues, on utilise :

- Le coefficient de corrélation de Pearson (r)
- La p-value associée

[167]:
```
# Calcul de la taille moyenne du panier par clien
# Étape 1 : calculer la taille du panier par session
panier_par_session = df_vf.groupby('session_id').size().
 ↪reset_index(name='taille_panier')
```

```
# Étape 2 : récupérer les infos client (client_id et Age) associées à chaque␣
↪session
df_sessions = df_vf[['session_id', 'client_id', 'Age']].drop_duplicates()

# Étape 3 : fusionner les deux pour associer chaque session à son client et sa␣
↪taille de panier
df_panier_client = pd.merge(panier_par_session, df_sessions, on='session_id')

# Étape 4 : calculer la taille moyenne du panier par client
panier_moyen_par_client = df_panier_client.groupby(['client_id',␣
↪'Age'])['taille_panier'].mean().reset_index(name='panier_moyen')
```

[168]:
```
#Test de correlation
from scipy.stats import pearsonr

r, p_value = pearsonr(panier_moyen_par_client['Age'],␣
↪panier_moyen_par_client['panier_moyen'])

print(f"Coefficient de corrélation de Pearson : {r:.3f}")
print(f"p-value : {p_value:.5f}")
```

```
Coefficient de corrélation de Pearson : -0.212
p-value : 0.00000
```

[169]:
```
from scipy.stats import spearmanr

# Application du test
r_spearman, p_spearman = spearmanr(
    panier_moyen_par_client['Age'],
    panier_moyen_par_client['panier_moyen']
)

# Affichage des résultats
print(f"  Coefficient de Spearman : {r_spearman:.3f}")
print(f"p-value : {p_spearman:.5f}")
```

```
 Coefficient de Spearman : -0.207
p-value : 0.00000
```

[170]:
```
#visualisation avec droite de régression linéaire (check pearson)
plt.figure(figsize=(8, 6))
sns.regplot(x='Age', y='panier_moyen', data=panier_moyen_par_client,␣
↪scatter_kws={'alpha':0.5}, line_kws={'color':'red'})
plt.title("Relation entre l'âge du client et la taille moyenne du panier")
plt.xlabel("Âge du client")
plt.ylabel("Taille moyenne du panier (nombre d'articles)")
plt.grid(True)
```

```
plt.show()
```

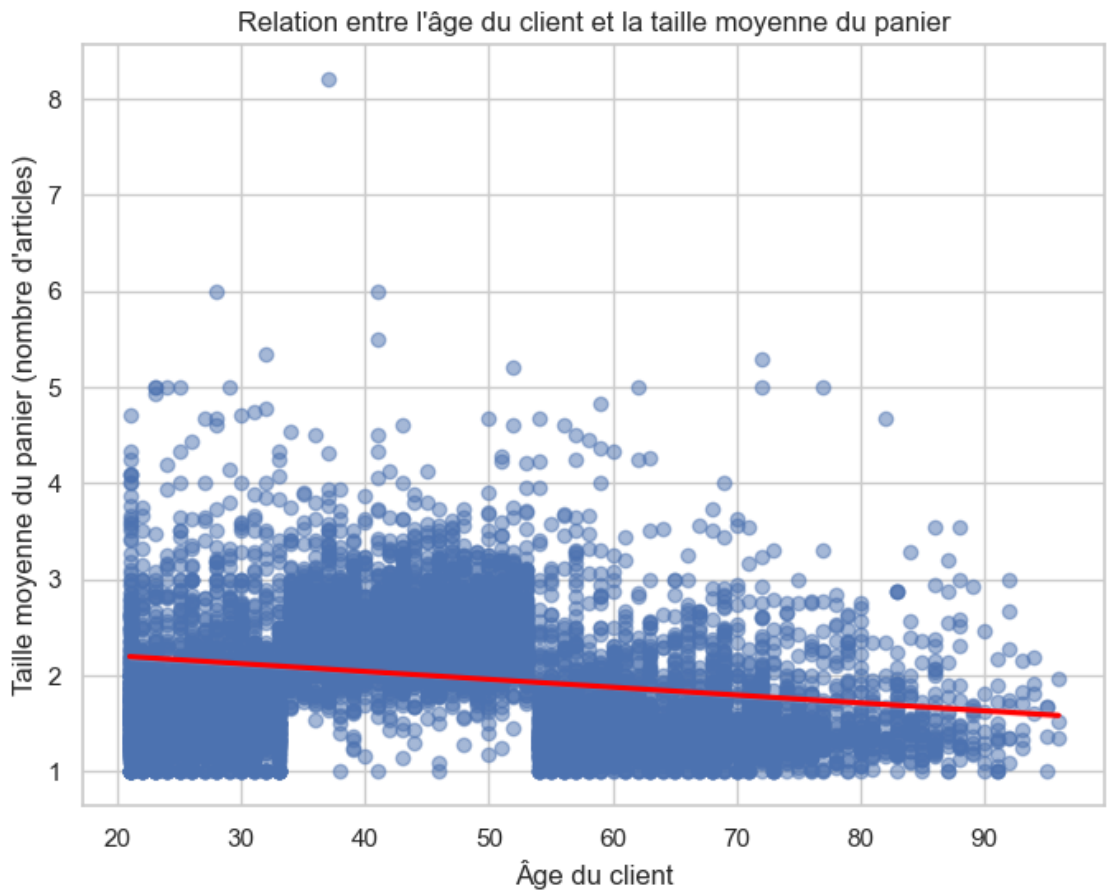


[171]:
```
#visualisation avec droite lissée localement (check spearman)
plt.figure(figsize=(8, 6))
sns.regplot(x='Age', y='panier_moyen', data=panier_moyen_par_client,␣
↪scatter_kws={'alpha':0.5}, line_kws={'color':'red'}, lowess=True)
plt.title("Relation entre l'âge du client et la taille moyenne du panier")
plt.xlabel("Âge du client")
plt.ylabel("Taille moyenne du panier (nombre d'articles)")
plt.grid(True)
plt.show()
```

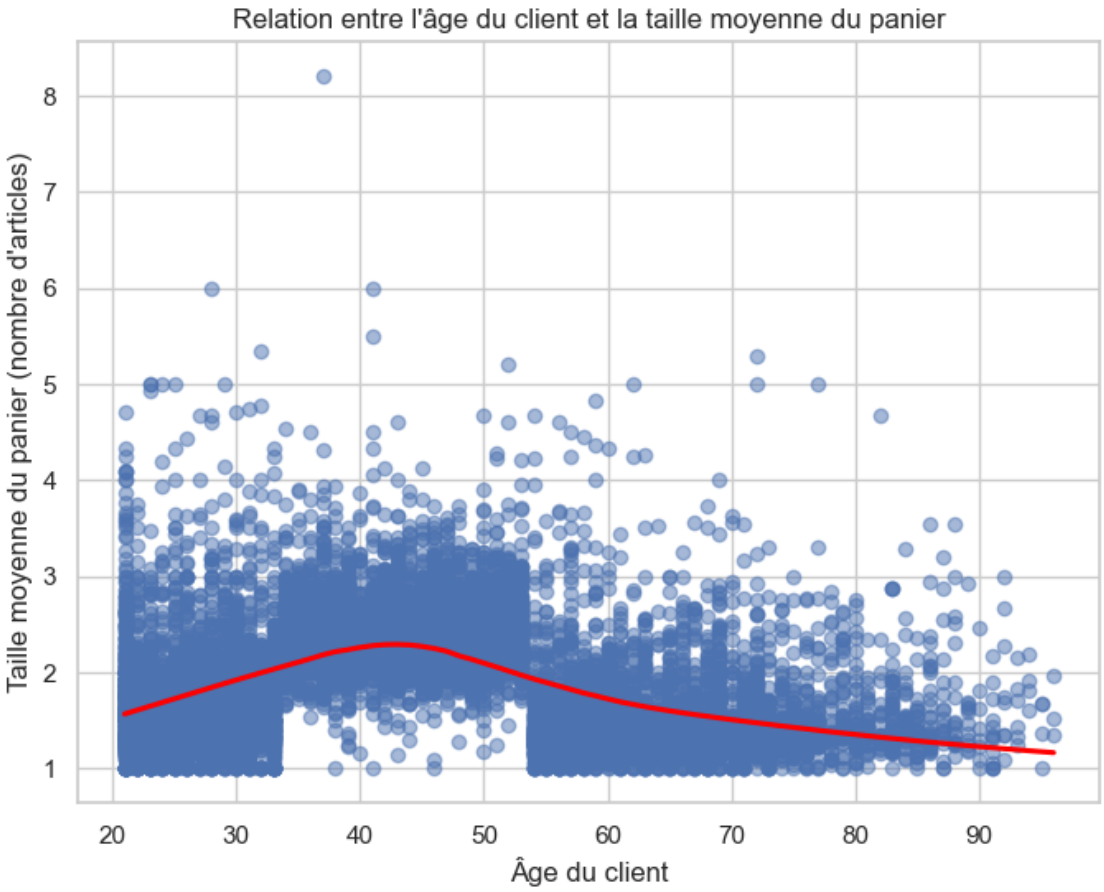


Coefficient de corrélation de Pearson : -0.212 - La corrélation est négative : plus l'âge augmente, plus la taille moyenne du panier diminue. - La valeur -0.212 indique une corrélation faible, mais non négligeable. - Cela suggère une tendance réelle, même si elle n'est pas dominante.

p-value : 0.00000 - La p-value est extrêmement faible, bien en dessous du seuil de 0.05. - Cela signifie que cette relation est statistiquement significative. - On peut donc rejeter H0 : il existe bien une relation linéaire entre l'âge et la taille moyenne du panier.

Etape 6.5 - Âge des clients et catégorie des livres achetés

1. Formulation des hypothèses : Puisque categ est une variable qualitative (valeurs 0, 1, 2), on ne cherche pas une relation linéaire mais une différence d'âge moyenne entre les groupes.

- H0 (hypothèse nulle) : Il n'y a pas de différence significative entre les âges moyens des clients selon la catégorie de livre achetée.
- H1 (hypothèse alternative) : Il existe une différence significative entre les âges moyens des clients selon la catégorie de livre achetée.

2. Choix du test statistique : Comme on compare l'âge (quantitatif) entre plusieurs groupes (catégories), on utilise :

- Test KRUSKAL-WALLIS : adéquat aux distributions asymétriques avec outliers / compare

plus de deux groupes (teste si au moins un groupe diffère des autres, sans dire lequel)

- Test de DUNN : montre quel groupe diffère des autres
- p-value associée : Pour déterminer la significativité statistique du résultat.

3. Visualisation complémentaire

- Boxplot : Pour visualiser la distribution des âges dans chaque catégorie et repérer les différences visuelles

[175]:
```
from scipy.stats import kruskal
import scikit_posthocs as sp

# 1. Préparation des groupes
groupes = [df_vf[df_vf['categ'] == cat]['Age'] for cat in df_vf['categ'].
 ↪unique()]

# 2. Test global de Kruskal-Wallis
stat, p = kruskal(*groupes)
print(f"Statistique H : {stat:.3f}")
print(f"p-value : {p:.5f}")

# 3. Si significatif, test post-hoc de Dunn
if p < 0.05:
    dunn = sp.posthoc_dunn(df_vf, val_col='Age', group_col='categ',␣
 ↪p_adjust='bonferroni')
    print("\nRésultats du test de Dunn (p-values ajustées) :")
    print(dunn)
```

```
Statistique H : 78458.438
p-value : 0.00000

Résultats du test de Dunn (p-values ajustées) :
     0    1    2
0  1.0  0.0  0.0
1  0.0  1.0  0.0
2  0.0  0.0  1.0
```

Statistique H = 78458.438 → élevée, ce qui traduit une grande différence entre les groupes.

p-value  0.00000 → bien en dessous du seuil classique (0.05). On rejette H0

[177]:
```
plt.figure(figsize=(8,6))
sns.boxplot(x='categ', y='Age', data=df_vf)
plt.title("Distribution de l'âge par catégorie de livre")
plt.xlabel("Catégorie de livre")
plt.ylabel("Âge des clients")
plt.xticks([0, 1, 2], ['Catégorie 0', 'Catégorie 1', 'Catégorie 2'])
plt.tight_layout()
plt.show()
```

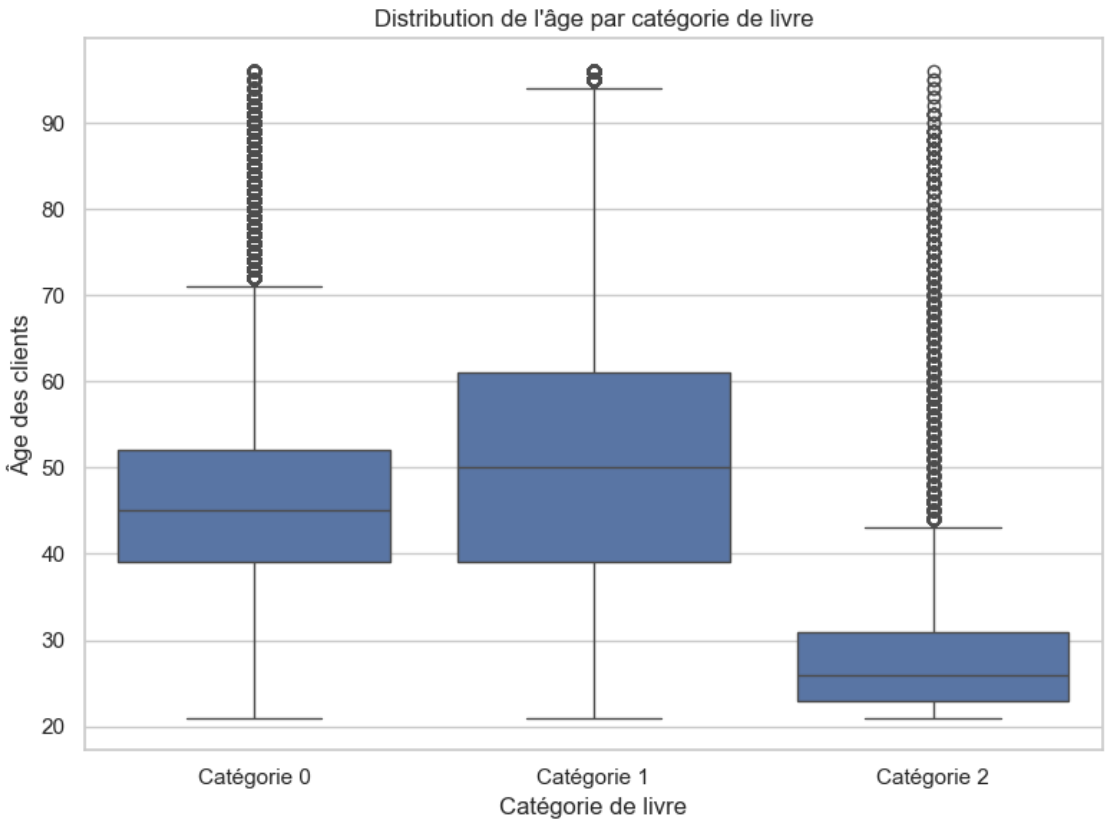


Description - Catégorie 0 : les clients ont un âge médian autour de 45 ans. Distribution assez homogène, mais avec des valeurs extrêmes (outliers) vers le haut.

- Catégorie 1 : médiane autour de 50 ans, mais beaucoup plus de dispersion (écart interquartile large, extrêmes jusqu'à 90 ans). Cette catégorie attire une clientèle plus âgée et variée.
- Catégorie 2 : médiane beaucoup plus basse (autour de 25 ans), distribution resserrée avec beaucoup d'outliers plus âgés. Cela indique que ce type de livres attire surtout un public jeune, mais pas exclusivement.

[179]:
```
plt.figure(figsize=(8,6))
sns.violinplot(x='categ', y='Age', data=df_vf, inner='box', cut=0)

plt.title("Distribution de l'âge par catégorie de livre (Violin Plot)")
plt.xlabel("Catégorie de livre")
plt.ylabel("Âge des clients")
plt.xticks([0, 1, 2], ['Catégorie 0', 'Catégorie 1', 'Catégorie 2'])
plt.tight_layout()
plt.show()
```

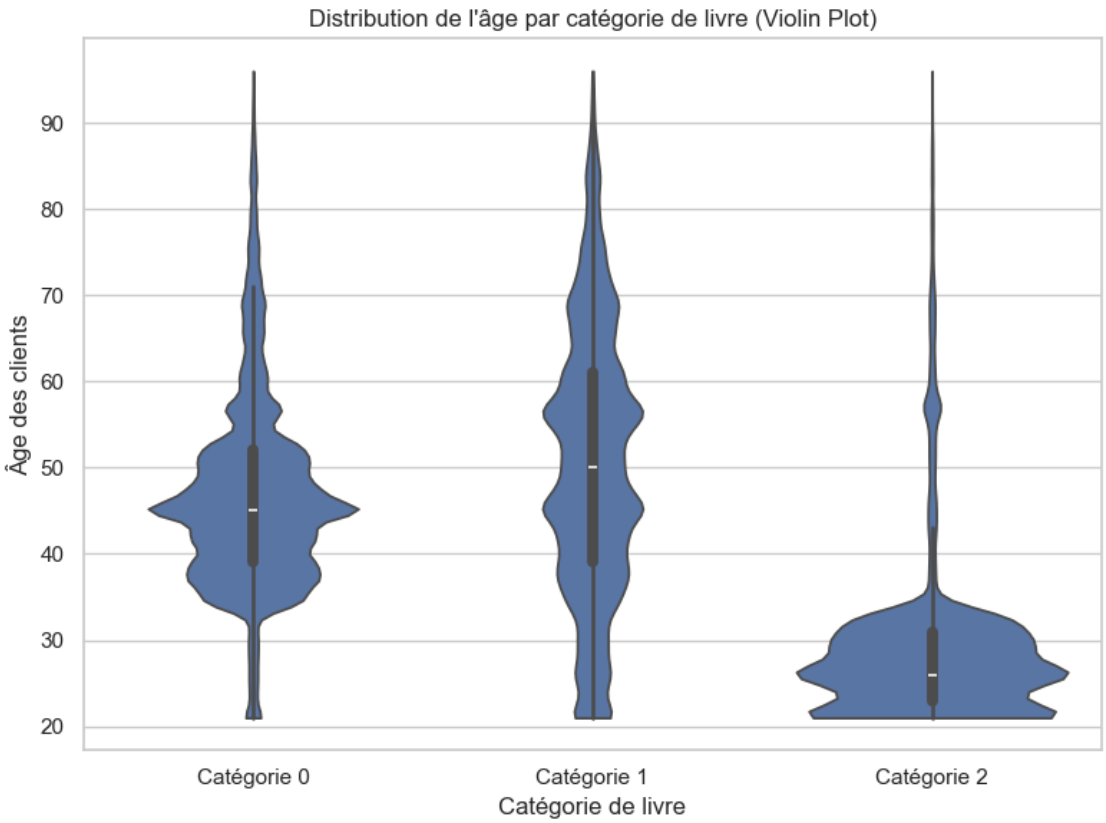
Distribution de l'âge par catégorie de livre (Violin Plot)
Âge des clients
90
80
70
60
50
40
30
20
Catégorie 0
Catégorie 1
Catégorie 2
Catégorie de livre

```
[ ]:
```